

人工智能训练师认知

时间：2025.02



CONTENTS

目录

- 人工智能训练师职业认知
- 人工智能训练师通用知识
- 人工智能算法、技术及应用
- Python 人工智能实现

01

·人工智能训练师职业认知·



"人工智能训练师的职业定义

【PDF】[人工智能训练师 国家职业技能标准](#)

文件格式: PDF/Adobe Acrobat - HTML版

2021年6月17日 [人工智能训练师 国家职业技能标准 \(2021 年版\)](#) 1.职业概况 1.1 职业名称 人工智能训练师 1.2 职业编码 4-04-05-05 1.3 职业定义 使用智能训练软件,在人工智能...

 中华人民共和国人力资源和社会保障部  党政机关

人工智能训练师的定义(职业编码4-04-05-05)

使用智能训练软件，在人工智能产品实际使用过程中进行数据库管理、算法参数设置、人机交互设计、性能测试跟踪及其他辅助作业的人员。它包括数据标注员和人工智能算法测试员两个工种，分为5个 等级：五级/初级工、四级/中级工、三级/高级工、二级/技师、一级/高级技师。

人工智能训练师 国家职业技能标准

(2021 年版)

1. 职业概况

1.1 职业名称

人工智能训练师

1.2 职业编码

4-04-05-05

1.3 职业定义

使用智能训练软件，在人工智能产品实际使用过程中进行数据库管理、算法参数设置、人机交互设计、性能测试跟踪及其他辅助作业的人员。

1.4 职业技能等级

本职业共设 5 个等级，分别为：五级/初级工、四级/中级工、三级/高级工、二级/技师、一级/高级技师。

1.5 职业环境条件

室内，常温。

1.6 职业能力特征

具有一定的学习能力、表达能力、计算能力；空间感、色觉正常。

"人工智能训练师的主要工作任务

人工智能训练师的主要工作任务是标注和加工原始数据、分析提炼专业领域特征，训练和评测人工智能产品相关的算法、功能和性能，设计交互流程和应用解决方案，监控分析管理产品应用数据、调整优化参数配置等

提供数据标注规则


通过算法聚类、标注分析等方式，从数据中提取行业特征场景，并结合行业知识，提供表达精准、逻辑清晰的数据标注规则，最终确保数据训练效果能满足产品的需求。

数据验收及管理

参与模型搭建和数据验收，并负责核心指标和数据的日常跟踪维护。

积累领域通用数据

根据细分领域的数 据应用要求，从已有数据中挑选符合要求的通用数据(适用于相同领域内的不同用户),形成数据的沉淀和积累。



"人工智能训练师的挑战与机遇

数据标注的挑战


数据标注工作面临着数据量大、标注要求高、质量控制难等问题。人工智能训练师需要不断提高自己的专业技能，以应对这些挑战。

人工智能训练师的机遇

随着人工智能技术的快速发展，对人工智能训练师的需求也在不断增长。他们有机会参与到各种创新项目中，推动技术的发展和应用。

人工智能训练师的职业规划

人工智能训练师应该根据自己的兴趣和职业目标，规划好自己的职业道路。他们可以通过参加培训、获取认证、参与项目等方式，不断提升自己的能力和价值。



人工智能训练师应具备的素质



知识与技能

人工智能基础知识

人工智能训练师需要掌握人工智能的基本原理，包括机器学习、深度学习、神经网络等，这些是构建智能系统的基础。他们应该了解不同的算法如何工作，以及它们在特定应用场景下的优势和局限性。

技术操作能力

熟练使用人工智能开发工具是训练师的基本技能。例如，Python语言因其简洁性和强大的库支持成为AI领域的主流编程语言。TensorFlow、PyTorch和PaddlePaddle等框架为训练师提供了构建和训练模型的工具。


行业领域知识

人工智能训练师应了解其技术在不同行业中的应用，如医疗、金融、教育等，以便更好地理解行业需求，设计出符合实际应用的AI模型。

沟通与协作


团队协作能力

在 multidisciplinary 团队中，人工智能训练师需要与数据科学家、软件工程师和产品经理等协作，共同推动项目向前发展。团队协作能力对于确保项目按时完成和满足质量标准至关重要。



沟通表达能力

训练师需要与不同背景的团队成员和客户沟通，清晰表达技术概念和项目进展。有效的沟通能力有助于确保项目需求被准确理解，减少误解和返工。



学习与创新



持续学习的能力

人工智能是一个快速发展的领域，训练师需要不断学习最新的技术和理论，以保持自己的专业知识更新。这可能包括参加在线课程、研讨会或阅读最新的研究论文。



创新能力

创新能力是人工智能训练师的重要素质之一。他们需要能够根据行业需求，设计新的算法或改进现有模型，以提高AI系统的性能和用户体验。

02

·人工智能训练师通用知识·



职业道德要求及职业守则





职业道德的重要性



职业行为标准

职业道德为数据标注员提供了行为标准和要求，包括诚实公正、严谨求是等原则，确保数据标注工作的质量和合规性。



社会责任

数据标注员的工作不仅影响企业的利益，也关系到社会的发展。因此，他们需要承担起相应的社会责任，确保数据的安全和隐私保护。



职业道德的实践

数据标注员在实际工作中应遵循职业道德，如保护个人隐私、确保数据真实性等，以维护企业和行业的良好形象。



对职业道德的理解



内容方面

职业道德总是要鲜明地表达职业义务、职业责任，以及职业行为上的道德准则。它不是反映社会道德和阶级道德的要求，而是反映职业、行业乃至产业特殊利益的要求；它不是在一般意义上的社会实践基础上形成的，而是在特定的职业实践的基础上形成的，因此它往往表现为某一职业特有的道德传统和道德习惯，表现为从事某一职业的人们所特有道德心理和道德品质，甚至造成从事不同职业的人们在道德品质上的差异。



表现形式

职业道德往往比较具体、灵活、多样。它总是从本职业的交流活动的实际出发，采用制度、守则、公约、承诺、誓言、条例，以至标语口号之类的形式，这些灵活的形式既易于为从业人员所接受和实行，又易于形成一种职业的道德习惯。



调节的范围

职业道德一方面用来调节从业人员内部关系，加强职业、行业内部人员的凝聚力；另一方面用来调节从业人员与其服务对象之间的关系，塑造本职业从业人员的形象。



产生的效果

职业道德与各种职业要求和职业生活结合，形成比较稳定的职业心理和职业习惯。



职业守则

严谨求是

诚实公正

遵章守法

勤勉好学

恪尽职守

追求卓越



人工智能训练师的职业守则

质量控制

职业守则要求数据标注员严格控制数据质量，通过精确的标注和反复的验证，提高数据的准确性和可靠性。

数据安全与隐私保护

数据标注员需要特别关注数据安全和隐私保护，遵守公司和行业的相关规定，确保数据的合法合规使用。

持续学习

随着技术的发展，数据标注员需要不断学习新的知识和技能，以适应行业的变化和发展需求。



数据安全与隐私保护



数据治理

数据治理是指对于数据采集、数据处理、数据清洗、数据标注到数据交付整个项目生命周期每个阶段进行识别、度量、监控、预警等一系列管理措施。



数据分割

数据分割是指将待标注数据进行最小可标注颗粒度分割，然后经由平台分发给互不知情的数据标注员来进行数据标注，平台分发回收均由接口完成。



数据安全传输

为了避免数据在数据传输过程中被窃取、复制等，必须对数据传输过程进行压缩、加密等操作。



区块链

基于区块链的数据标注平台采用强加密算法及分布式技术来确保数据安全。



技能要求

数据敏感度

数据标注员需要具备敏锐的数据敏感度，能够快速准确地识别和分类各种类型的数据。

耐心与细致

数据标注工作往往涉及大量重复性的劳动，因此需要极高的耐心和细致的工作态度，以确保标注的精确性。

学习能力

数据标注员需要具备较强的学习能力，不断更新自己的知识库，掌握新的标注工具和技术，以适应行业的发展。

相关的法律知识





相关法律知识



劳动法与劳动合同法

数据标注员需要了解劳动法和劳动合同法，以保障自己的合法权益，如合理的工作时间、休息休假、劳动报酬等。



网络安全法

网络安全法规定了网络运营者和用户的权利和义务，数据标注员需要遵守相关法律法规，保护数据安全，防止数据泄露。



知识产权法

知识产权法保护个人的智力成果，数据标注员在工作中需要尊重知识产权，避免侵犯他人的专利、著作权等。



计算机通用知识





计算机通用知识

计算机CPU选型知识
计算机GPU选型知识
计算机网络配置知识
计算机信息安全知识
Linux操作系统知识
计算机外设配置知识
计算机组成结构
WPS办公软件软件知识
即时通讯办公软件知识
杀毒软件基本知识
计算机浏览器基本知识
网络搜索引擎基本知识
电子邮件基本知识
下载工具基本知识
解压工具基本知识
图像编辑软件知识
视频编辑软件基础知识
图像标注软件基础知识

03

人工智能算法、技术及应 用



人工智能与人工智能科学



人工智能的定义与范畴

人工智能的基本概念

人工智能是指通过计算机程序模拟人类智能行为的科学。它涉及到让机器能够感知环境、推理、学习和采取行动以实现特定目标。



人工智能的跨学科特性

人工智能科学是一个跨学科领域，它结合了计算机科学、数学、逻辑学、心理学等多个学科的知识，以开发能够模拟人类智能行为的系统。

人工智能的主要应用领域



自然语言处理

自然语言处理（NLP）是人工智能的一个重要分支，它使计算机能够理解、解释和生成人类语言。NLP在机器翻译、语音识别和聊天机器人等领域有广泛应用。



机器人与自动控制

机器人技术结合了人工智能，使机器人能够执行复杂的任务，如自动驾驶汽车、工业自动化和探索未知环境。




计算机视觉

计算机视觉使计算机能够从图像或多维数据中提取信息，进行图像识别、分析和理解。这一技术在医疗影像分析、安全监控和增强现实等领域有广泛应用。

人工智能的发展历史



"人工智能的三个发展阶段



"第一阶段(20世纪50年代至80年代)"



达特茅斯会议与人工智能的起源

1956年，达特茅斯会议标志着人工智能的诞生。会议聚集了多位计算机科学家和数学家，共同探讨如何用机器模拟人类智能。这次会议确立了人工智能这一术语，并开启了人工智能研究的先河。



早期人工智能的繁荣与挑战

在20世纪50年代至80年代，人工智能经历了第一次繁荣期。可编程数字计算机的出现使得科学计算和研究成为可能，但受限于当时的计算能力，许多复杂的智能任务难以实现，导致人工智能发展遭遇瓶颈。



人工智能的低谷与复兴

随着机器翻译等项目的失败，人工智能进入了低谷期。然而，随着专家系统的兴起和神经网络的研究突破，人工智能在20世纪80年代中后期再次迎来繁荣。

"第一阶段(20世纪50年代至80年代)"


1956年，达特茅斯会议，“人工智能元年”



1966年，美国计算机学会
设立了图灵奖



图灵测试



"第二阶段(20世纪80年代至90年代末)"



专家系统

进入20世纪80年代后, 具备一定逻辑 规则推演的专家系统开始在一些特定领域盛行。



决策树和神经网络

1985年, 具有可视化效果的决策树模型和 突破早期感知机局限的多层人工神经网络出现了。



五代机计划

日本雄心勃勃推行的五代机计划也促成 了20世纪80年代中后期人工智能的繁荣。

1987年, 专家系统后继乏力, 神经网络 的研究也陷入瓶颈, LISP(list processing,表处理)机的研究也最终失败。人工智能又经历了一次从繁荣到低谷的过程。

"第三阶段(20世纪90年代末至今)"



IBM 深蓝

1997年, IBM 公司的“深蓝”战胜了国际象棋世界冠军卡斯帕罗夫, 全世界的眼光又一次被人工智能吸引。随着互联网时代的到来和计算机性能的不不断提升, 人工智能开始进入复苏期。



智慧地球、感知中国

IBM 公司提出“智慧地球”, 我国也提出“感知中国”。




机器学习、深度学习

物联网、大数据、云计算等新兴技术的快速发展, 以及大规模标注数据集的出现, 为机器学习奠定了坚实的基础, 一大批特定领域的人工智能项目纷纷取得突破性进展并落地。在深度学习算法的助推下, 人工智能被广泛应用到各行各业, 深刻地影响着人们的生活和工作。如今, 我们正处在人工智能技术爆发的风口上。

"第三阶段(20年代末至今)"

1996年5月11日，深蓝电脑以3.5-2.5击败卡斯巴罗夫，成为首个在标准比赛时限内击败国际象棋世界冠军的电脑系统。




AlphaGo是第一个战胜围棋世界冠军的人工智能机器人，由谷歌旗下DeepMind公司戴密斯·哈萨比斯领衔的团队开发。其主要工作原理是“深度学习”。



AlphaGO **Lee Se-dol**
1202 CPUs, 176 GPUs, 1 Human Brain,
100+ Scientists. 1 Coffee.

2021年7月22日，谷歌旗下的Deepmind 公司的研究团队在《自然》杂志上发表了一篇报告:该公司开发的人工智能程序“AlphaFold” 预测出了98.5%的人类蛋白质结构。




人工智能技术及其分类





通用技术



机器学习

机器学习是人工智能的核心技术之一，它通过算法使计算机能够从数据中学习并做出预测或决策。



类脑智能计算与量子智能计算

类脑智能计算模仿人脑的工作机制，旨在创建具有类似人类认知能力的智能系统。量子智能计算则利用量子计算的优势，解决传统计算机难以处理的问题。



知识图谱

知识图谱通过结构化的方式表示知识，将概念、实体及其关系以图的形式展现，有助于提高信息检索和数据挖掘的效率。



模式识别

对表征事物或现象的各种形式的信息，包括数值、文字、逻辑关系等进行处理和分析，从而对事物或现象进行描述、辨认、分类和解释的技术




领域技术



自然语言处理

自然语言处理使计算机能够理解和生成人类语言，包括语言识别、语义理解、机器翻译等，是人工智能领域的重要分支。



智能语音与计算机视觉

智能语音技术将语音转换为文本，计算机视觉则使计算机能够识别和理解图像和视频内容，两者都是人工智能应用的核心。



生物特征识别与虚拟现实

生物特征识别技术通过分析个人的生理特征进行身份验证，如指纹、面部识别等。虚拟现实技术则通过模拟环境为用户提供沉浸式体验。

人工智能应用示例





计算机视觉在工业检测中的应用

01

零件缺陷检测流程

采用深度学习技术进行零件缺陷检测，通过图像数据的清洗、标注、增强、模型训练和验证，实现自动化、精准化的缺陷检测。


02

医学影像识别疾病

医学影像识别技术通过分析医学影像数据，如X光、CT、MRI等，辅助医生进行疾病诊断。这一过程涉及到图像的预处理、特征提取、模型训练和评估，最终实现疾病的自动识别和分类。



计算机视觉在工业检测中的应用



人工智能算法基础






机器学习算法概述

机器学习的定义与过程

机器学习是一种使计算机系统利用数据来不断改进性能的技术。它涉及到从数据中提取模式，构建模型，并通过这些模型对新的数据进行预测或分类。这个过程包括数据的收集、清洗、特征选择、模型训练和评估等步骤。

机器学习的应用领域

机器学习在众多领域都有广泛的应用，包括金融风险管理、医疗诊断、自然语言处理、图像识别等。这些应用通过机器学习模型的预测能力，提高了决策的准确性和效率。





经典机器学习算法

01.

线性回归与逻辑回归

线性回归是一种预测连续数值的算法，通过拟合数据点来预测输出。逻辑回归则用于分类问题，通过sigmoid函数输出类别概率，广泛应用于信用评分和医学诊断等领域。

02.

决策树与支持向量机

决策树通过树状模型进行决策，适用于分类和回归问题。支持向量机则通过寻找最优超平面来区分不同类别的数据，是解决小样本、非线性问题的有效方法。

03.

k最近邻与人工神经网络

k最近邻算法根据距离度量选择最近的k个邻居进行分类或回归。人工神经网络通过模拟人脑神经元的连接来处理信息，适用于复杂的非线性问题。



深度学习算法

经典的机器学习过程



深度学习过程






深度学习算法


● 多层感知机与卷积神经网络

多层感知机是深度学习的基础，通过多层网络结构学习数据的高层特征。卷积神经网络则专门用于处理具有网格结构的数据，如图像，通过卷积层自动提取局部特征。






● 循环神经网络与长短时记忆网络

循环神经网络适合处理序列数据，通过循环连接传递信息。长短时记忆网络是RNN的一种，能够学习长期依赖信息，适用于语音识别和自然语言处理。



● Transformer模型

Transformer模型基于自注意力机制，能够处理序列数据中的长距离依赖问题，是当前自然语言处理领域的主流模型。



算法与数据标注的关系



"深度学习的4种形式



(有) 监督学习

监督学习通过学习已标注数据集的特征来 建立一个模型，在经过多轮的迭代训练后，这个模型可以自行识别未经标注的数据。例如，在图像分类和人脸检测等领域，标注的数据量越大，算法的性能就越好。



无监督学习

无监督学习使用未标注的数据集进行学习，通过算法自动找出数据中的隐含结构或潜在规则。这种方法适用于探索数据的内在特性，但可能不如监督学习精确。



半监督学习

半监督学习结合了监督学习和无监督学习的优点，使用少量标记数据和大量未标记数据进行模型训练。这种方法在成本和精度之间取得了平衡，但可能受到未标记数据质量的影响。



强化学习

强化学习关注智能体在与环境交互过程中的学习策略，通过回报函数来评估算法的效果。这种方法适用于没有标注数据集的场景，如游戏、机器人控制等领域。

"监督学习与数据标注




监督学习的应用

利用监督学习训练出来的模型在现实场景中的应用效果相对较好，是人工智能技术落地的首选方式。例如，在图像分类和人脸检测等领域，目前一般都采用监督学习方法。



数据标注的重要性

数据标注是监督学习的基础，高质量的数据标注对于训练出高性能的模型至关重要。数据标注员的工作直接影响到模型的准确性和可靠性。



数据标注的挑战与机遇

随着人工智能技术的快速发展，对高质量数据的需求日益增长。数据标注员面临着数据量大、标注要求高等问题，同时也有着广阔的职业发展空间。

数据标注的特点、数据标注 行业的发展前景





数据标注的特点

颗粒度细小

对文本、音频、图像、视频等进行数据标注时，先根据 实际应用场景提炼出数据标注需求，进而通过多种方法进行标注，得到预期的标注结果，再 进行算法训练。数据标注内容的颗粒度越细越好，要尽可能地覆盖所有可能性。例如，在自动驾驶领域，需要对车辆、行人、交通标志等进行精确的边界框标注。

需求量大

人工智能算法的训练一般需要训练集、测试集和验证集，三 者的比例一般为7:2:1。特定场景下的算法对标注数据的需求量非常大。例如，截至2010年，ImageNet项目(一个计算机视觉系统识别项目)已收集到167个国家的4万多名数据标 注员提供的约1400万张标注过的图像，分为2万多类。

需求迭代快

人工智能模型最终都要落地到具体的应用场景，为了使训练 模型能有更好的效果，在数据标注阶段，数据需求方可能会不断调整数据标注需求。因此， 项目管理人员要经常与数据需求方沟通，数据标注员也要及时根据变化了的数据标注规则进 行重新标注。另外，在不同阶段，数据需求方的项目不同，对数据标注的要求也会有很大的 不同。



数据标注行业的发展前景



行业需求增长

随着人工智能技术的广泛应用，数据标注行业的市场需求持续增长。企业对于高质量标注数据的需求推动了行业的快速发展。



技术优化潜力

数据标注行业正处于初级阶段，相关技术有待完善。行业内的技术创新和优化潜力巨大，为数据标注员提供了广阔的发展空间。




市场竞争与合作

数据标注行业的竞争日益激烈，企业需要不断提升技术实力和服务质量，以在市场中保持竞争力。同时，行业内部的合作也日益重要，共同推动行业发展。

人工智能训练流程



人工智能训练流程



数据准备



数据清洗与标注

数据是人工智能模型的基石。训练师需要对数据进行清洗，去除错误和不完整的数据，然后进行标注，以便模型能够从中学习。



数据集的整理与切分

训练师需要将数据集切分成训练集、验证集和测试集，以评估模型的性能并避免过拟合。



数据存储格式

选择合适的数据存储格式对于模型训练的效率至关重要。训练师需要确保数据格式与所使用的框架和工具兼容。

数据预处理与增强



数据读取与转换

在图像分析中，首先需要读取原始的图像数据，并将其转换为适合深度学习模型输入的格式。这通常涉及到数据的预处理和增强，如裁剪、旋转和翻转等操作。



数据增强的目的

数据增强是提高模型泛化能力的重要手段。通过对训练数据进行各种变换，可以增加数据的多样性，减少过拟合，并提高模型对新样本的适应能力。

模型设计与评估

模型选择与设计

根据任务目标，训练师需要选择最合适的模型架构。这可能涉及到对不同模型的性能进行比较，以找到最佳解决方案。



评估指标的确定

选择合适的评估指标对于衡量模型性能至关重要。训练师需要根据任务类型选择合适的指标，如准确率、召回率或F1分数。

模型训练与验证

模型训练

在验证集上测试模型性能，确保模型在未见数据上的表现符合预期。通过测试集的评估，训练师可以确定模型是否准备好投入实际应用。

模型验证与测试

训练过程中，训练师需要调整模型参数，使用如交叉验证等技术来优化模型性能，并防止过拟合。

深度学习网络设计与评估

01 网络结构设计

在设计深度学习网络时，需要考虑如何有效地提取特征并进行分类。例如，可以使用DenseNet作为基础网络，结合空间金字塔池化模块和全连接层来构建分类模型。

02 损失函数与优化器

损失函数是训练过程中评估模型性能的关键。选择合适的损失函数，如focal loss，可以帮助模型更好地关注难以分类的样本。同时，优化器如SGD和Adam也是影响模型训练效果的重要因素。

03 模型训练与测试

模型的训练和测试是评估模型性能的重要步骤。通过在训练集上迭代训练模型，并在测试集上评估模型的准确率，可以确定模型的最终性能。此外，保存和加载最佳模型也是模型开发过程中的一个重要环节。

04

Python 人工智能实现



Python 基础



Python 基础

Python语言概述

Python是一种高级编程语言，以其简洁的语法和强大的功能而受到广泛欢迎。在人工智能领域，Python是最主要的编程语言之一，拥有丰富的库和框架支持。




Python的基本语法

Python的基本语法包括变量、数据类型、控制结构、函数等。掌握这些基础知识是进行人工智能训练的基础。



Python在AI中的应用

Python在人工智能中的应用广泛，包括数据预处理、模型训练、结果分析等。通过学习Python，人工智能训练师可以更高效地完成工作。



Python安装

版本选择

Python有Python 2.x和 Python 3.x两个版本。因此，在安装Python时，需要慎重选择安装 Python的哪个版本。这是因为两个版本之间没有兼容性(严格地讲，是没有“向后兼容性”)，也就是说，会发生用 Python 3.x写的代码不能被Python 2.x执行的情况。建议用户使用 Python 3.x版本



安装方法选择

Anaconda发行版
Python安装包+IDE



IDE选择

Jupyter notebook
PyCharm
VSCode



Python使用

```
命令提示符 - python
Microsoft Windows [版本 10.0.19045.5011]
(c) Microsoft Corporation. 保留所有权利。

C:\Users\liming>python
Python 3.10.7 (tags/v3.10.7:6cc6b13, Sep 5 2022, 14:08:36) [MSC v.1933 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license()" for more information.
>>>
```



IDLE Shell 3.10.7


File Edit Shell Debug Options Window Help

```
Python 3.10.7 (tags/v3.10.7:6cc6b13, Sep 5 2022, 14:08:36) [MSC v.1933 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license()" for more information.
>>> |
```


Python 3.10 (64-bit)

```
Python 3.10.7 (tags/v3.10.7:6cc6b13, Sep 5 2022, 14:08:36) [MSC v.1933 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license()" for more information.
>>> _
```



Python使用



Python使用



Python使用



Python使用

注释

```
print("Hello, AI!") #输出字符串
```

```
Hello, AI!
```

```
'''  
Spyder Editor  
This is a temporary script file.  
'''
```

行与缩进

```
a = 0  
if a==0:  
    print("a为0!")  
else:  
    print("a不为0!")
```

```
a为0!
```

Python使用

算术计算

```
1-2
```

```
-1
```

```
4*5
```

```
20
```

变量

```
x=10 #初始化
```

```
print(x) #输出x
```

```
10
```

数据类型

```
type(10)
```

```
int
```

```
type(2.718)
```

```
float
```

```
type("hello")
```

```
str
```

Python使用

列表

```
a=[1,2,3,4,5] #生成列表
```

```
print(a) #输出列表的内容
```

```
[1, 2, 3, 4, 5]
```

```
len(a) #获取列表的长度
```

```
5
```

```
a[0] #访问第一个元素的值
```

```
1
```

```
a[0:2] #获取索引为0到2(不包括2)的元素
```

```
[1, 2]
```

```
a[1:] #获取从索引为1的元素到最后一个元素
```

```
[2, 3, 4, 5]
```

```
a[:3] #获取从第一个元素到索引为3(不包括3)的元素
```

```
[1, 2, 3]
```

```
a[:-1] #获取从第一个元素到最后一个元素的前一个元素之间的元素
```

```
[1, 2, 3, 4]
```

字典

```
me={'height':180} #生成字典
```

```
me['height'] #访问元素
```

```
180
```

Python使用

选择结构if 语句

```
hungry = True
if hungry:
    print("I'm hungry")
hungry = False
if hungry:
    print("I'm hungry") #使用空白字符进行缩进
else:
    print("I'm not hungry")
    print("I'm sleepy")
```

```
I'm hungry
I'm not hungry
I'm sleepy
```

循环结构for 语句

```
for i in [1,2,3]:
    print(i)
```

```
1
2
3
```

Python使用

函数

```
def hello():  
    print("Hello AI!")
```

```
hello()
```

Hello AI!

类

```
class MyClass:  
    my_attribute = 0 # 类的属性  
    def my_method(self): # 类的方法  
        print("Hello World")
```

```
my_object = MyClass() # 创建MyClass的一个实例
```

```
my_object.my_method()
```

Hello World

```
my_object.my_attribute = 1 # 设置属性值  
print(my_object.my_attribute) # 访问属性值
```

1

任务实施

根据身体质量指数(body mass index,BMI),判断某人的体重是否 正常。BMI是目前国际上常用的衡量人体胖瘦程度以及是否健康的一个指标。它的计算公式 是: $BMI = \text{体重} \div (\text{身高} \times \text{身高})$ (体重除以身高的平方),其中, 体重的单位是千克, 身高 的单位是米。中国人的BMI参考标准如下。

BMI<18.5为偏瘦;

18.5<BMI<24为正常;

24≤BMI<28 为肥胖;

BMI≥28 为肥胖。

```
mass =float(input('输入体重(公斤):'))
height =float(input('请输入身高(米)'))
```

输入体重(公斤): 75
请输入身高(米)

```
mass =float(input('输入体重(公斤):'))
height =float(input('请输入身高(米)'))
```

输入体重(公斤): 75
请输入身高(米) 1.72

```
bmi =mass/(height*height)
```

```
if bmi<18.5:
    body='偏瘦'
elif 18.5<=bmi and bmi<24:
    body='正常'
elif 24<=bmi and bmi<28:
    body='超重'
elif bmi >=28:
    body='肥胖'
```

```
print('你的bmi是: {}'.format(bmi))
print(body)
```

你的bmi是: 25.351541373715524
超重

Python机器学习工具包



NumPy 基础



NumPy简介



NumPy库简介

NumPy的数组操作是其核心功能之一，通过数组，可以高效地进行数据的存储和计算。人工智能训练师需要熟练掌握数组的创建、切片、广播等操作。



NumPy的数组操作

NumPy是Python中用于科学计算的基础库，提供了大量的数学函数和操作，特别适合进行大规模的数值计算。



NumPy在数据处理中的应用

在人工智能训练中，数据处理是一个重要环节。NumPy提供了丰富的函数和方法，可以方便地进行数据的统计、筛选、变换等操作。



NumPy安装



一般来说, 在anaconda集成环境中, numpy已经安装, 如果未安装, 则可以使用以下方式安装



pip命令行安装



File View Settings Help

```
Windows PowerShell  
版权所有 (C) Microsoft Corporation。保留所有权利。  
  
尝试新的跨平台 PowerShell https://aka.ms/pscore6  
  
PS C:\Users\liming\Documents> pip install numpy
```



如果拉取安装包的速度比较慢, 则改用清华源



pip install numpy -i <https://mirrors.tuna.tsinghua.edu.cn/pypi/web/simple>

NumPy使用

导入NumPy

```
import numpy as np
```

生成NumPy 数组

```
import numpy as np
```

```
x=np.array([1.0,2.0,3.0])  
print(x)
```

```
[1. 2. 3.]
```

```
type(x)
```

```
numpy.ndarray
```

NumPy使用

NumPy的算术运算

```
import numpy as np
```

```
x=np.array([1.0,2.0,3.0])  
y=np.array([2.0,4.0,6.0])
```

```
x+y
```

```
array([3., 6., 9.])
```

```
x*y
```

```
array([ 2.,  8., 18.])
```

```
x/y
```

```
array([0.5, 0.5, 0.5])
```

访问元素

```
import numpy as np
```

```
X=np.array([[51,55],[14,19],[0,41]])
```

```
X[0] # 第0行
```

```
array([51, 55])
```

```
X[0][1] #(0,1)的元素
```

```
55
```

NumPy使用

NumPy 的N 维数组

```
import numpy as np
```

```
A=np.array([[1,2],[3,4]])  
print(A)
```

```
[[1 2]  
 [3 4]]
```

```
A.shape
```

```
(2, 2)
```

```
A.dtype
```

```
dtype('int32')
```

```
import numpy as np
```

```
A=np.array([[1,2],[3,4]])  
B=np.array([[3,0],[0,6]])
```

```
A+B
```

```
array([[ 4,  2],  
       [ 3, 10]])
```

```
A*B
```

```
array([[ 3,  0],  
       [ 0, 24]])
```

NumPy使用

NumPy 常用函数

函 数	功 能	函 数	功 能
sum()	求和	min()	最小值
mean()	求平均值	argmin()	返回最小数的索引值
max()	最大值	argmax()	返回最大数的索引值

NumPy任务实施

先用NumPy创建两个 2×2 的数组X和Y,然后将X和Y相加得到Z,最后求出Z的最大值及索引位置。

```
import numpy as np
```

```
X=np.array([[1,2],[3,4]])  
print(X)
```

```
[[1 2]  
 [3 4]]
```

```
Y =np.array([[5,6],[7,8]])  
print(Y)
```

```
[[5 6]  
 [7 8]]
```

```
Z=X+Y  
print(Z)
```

```
[[ 6  8]  
 [10 12]]
```

```
print(Z.max())
```

```
12
```

```
print(Z.argmax())
```

```
3
```

Pandas 基础



Pandas 简介



Pandas库简介

Pandas是Python中用于数据分析的库，提供了DataFrame和Series两种主要的数据结构，非常适合处理表格数据。



Pandas的数据操作

Pandas的数据操作包括数据的读取、清洗、合并、分组等。这些操作对于人工智能训练师来说非常重要，可以帮助他们高效地处理和分析数据。



Pandas在数据预处理中的应用

在人工智能训练中，数据预处理是一个关键步骤。Pandas提供了强大的数据预处理功能，可以帮助训练师快速地清洗和准备数据。

Pandas 安装



一般来说, 在anaconda集成环境中, pandas已经安装, 如果未安装, 则可以使用以下方式安装 ▶▶▶



pip命令行安装



Jupyter

File View Settings Help

New Upload

Notebook

Terminal

Console

New File

New Folder

Windows PowerShell
版权所有 (C) Microsoft Corporation。保留所有权利。

尝试新的跨平台 PowerShell <https://aka.ms/powershell>

PS C:\Users\liming\Documents> pip install pandas



如果拉取安装包的速度比较慢, 则改用清华源 ▶▶▶

`pip install pandas -i https://mirrors.tuna.tsinghua.edu.cn/pypi/web/simple`

Pandas 读取数据

文件格式	说明	Pandas 读取方法
CSV、TXT	用逗号或 Tab 键分隔的纯文本文件	<code>pd.read_csv</code>
XLS、XLSX	电子表格文件	<code>pd.read_excel</code>
MySQL	MySQL 数据库表	<code>pd.read_sql</code>

Pandas 数据结构

Series

```
import pandas as pd
```

```
# 用数据列表产生最简单的Series
```

```
s1=pd.Series([1,'a',5.2,7])
```

```
# 创建一个具有标签索引的Series
```

```
s2=pd.Series([1,'a',5.2,7],index=['d','b','a','c'])
```

```
# 使用Python字典创建Series
```

```
sdata={'Ohio':35000,'Texas':72000,'Oregon':16000,'Utah':5000}
```

```
s3=pd.Series(sdata)
```

```
# 根据标签索引查询数据
```

```
s2['a']
```

```
5.2
```

```
s2[['b','a']]
```

```
b      a
a      5.2
dtype: object
```

DataFrame

```
data={
    'state':['Ohio','Ohio','Ohio','Nevada','Nevada'],
    'year':[2000,2001,2002,2001,2002],
    'pop':[1.5,1.7,3.6,2.4,2.9]
}
df=pd.DataFrame(data)
```

DataFrame查询方式与功能

查询一列，结果是一个pd.Series

```
df['year']
```

```
0    2000  
1    2001  
2    2002  
3    2001  
4    2002
```

```
Name: year, dtype: int64
```

```
type(df['year'])
```

```
pandas.core.series.Series
```

查询多列，结果是一个pd.DataFrame

```
df[['year', 'pop']]
```

	year	pop
0	2000	1.5
1	2001	1.7
2	2002	3.6
3	2001	2.4
4	2002	2.9

```
type(df[['year', 'pop']])
```

```
pandas.core.frame.DataFrame
```

DataFrame查询方式与功能

查询一行，结果是一个pd.Series

```
df.loc[1]
```

```
state    Ohio  
year     2001  
pop       1.7  
Name: 1, dtype: object
```

```
type(df.loc[1])
```

```
pandas.core.series.Series
```

查询多行，结果是一个pd.DataFrame

```
df.loc[1:3]
```

	state	year	pop
1	Ohio	2001	1.7
2	Ohio	2002	3.6
3	Nevada	2001	2.4

```
type(df.loc[1:3])
```

```
pandas.core.frame.DataFrame
```

DataFrame任务实施

数据标注员小张对目标检测样本进行了标注，并将各类别的标注数量填写在Samples.csv 文件中。由于一时疏忽，他遗漏了卡车类别的记录。本任务使用Pandas从 Samples.csv文件中读取数据，对数据表进行补充，并统计相关的标注信息，任务要求如下。

- 1.增加一条记录(卡车, 4000)。
- 2.查找标注数量超过1000的类别。
- 3.按照标注数量从低到高排序。
- 4.统计类别的平均标注量与标注总量。

DataFrame任务实施

```
import pandas as pd
```

```
data = pd.read_csv("Samples.csv")  
data
```

	样本类别	标注数量
0	行人	10000
1	公交车	200
2	轿车	500
3	电瓶车	1000
4	自行车	6000

```
dit={'样本类别':'卡车','标注数量':4000}  
s=pd.Series(dit)  
s.name=5  
data=pd.concat([data, s.to_frame().T], ignore_index=True)  
data
```

	样本类别	标注数量
0	行人	10000
1	公交车	200
2	轿车	500
3	电瓶车	1000
4	自行车	6000
5	卡车	4000

DataFrame任务实施

```
data[data.标注数量>1000]
```

	样本类别	标注数量
0	行人	10000
4	自行车	6000
5	卡车	4000

```
data['标注数量'].mean()
```

3616.6666666666665

```
data['标注数量'].sum()
```

21700

Excel 应用



Excel简介



Excel在数据分析中的作用

虽然Python在数据处理方面更为强大，但在某些情况下，Excel的直观性和易用性也是不可或缺的。训练师可以结合使用Excel和Python，以提高工作效率。

Excel的数据处理技巧


Excel是一款广泛使用的电子表格软件，它在数据分析和可视化方面有着强大的功能。人工智能训练师可以通过Excel快速地进行数据整理和初步分析。

Excel与Python的结合使用

Excel提供了丰富的数据处理功能，如排序、筛选、查找等。训练师可以利用这些功能，对数据进行初步的处理和分析。

Excel任务实施

将数据集中“图像名列表”列中的图像文件名提取出来，存放在“效果”列。



	A	B
1	图像名列表	效果
2	[00]img001.jpg	img001.jpg
3	[11]img002.jpg	img002.jpg
4	[22]img003.jpg	img003.jpg
5	[33]img004.jpg	img004.jpg
6	[44]img005.jpg	img005.jpg
7	[55]img006.jpg	img006.jpg
8	[66]img007.jpg	img007.jpg
9	[77]img008.jpg	img008.jpg
10	[88]img009.jpg	img009.jpg

Excel任务实施

将数据集中“图像名列表”列中的图像文件名提取出来，存放在“效果”列。

C2 fx =RIGHT(A2,LEN(A2)-LEN("[00]"))		
	A	B
1	图像名列表	效果
2	[00]img001.jpg	img001.jpg
3	[11]img002.jpg	img002.jpg
4	[22]img003.jpg	img003.jpg
5	[33]img004.jpg	img004.jpg
6	[44]img005.jpg	img005.jpg
7	[55]img006.jpg	img006.jpg
8	[66]img007.jpg	img007.jpg
9	[77]img008.jpg	img008.jpg
10	[88]img009.jpg	img009.jpg

C2 fx =RIGHT(A2,LEN(A2)-LEN("[00]"))		
	A	B
1	图像名列表	效果
2	[00]img001.jpg	img001.jpg
3	[11]img002.jpg	img002.jpg
4	[22]img003.jpg	img003.jpg
5	[33]img004.jpg	img004.jpg
6	[44]img005.jpg	img005.jpg
7	[55]img006.jpg	img006.jpg
8	[66]img007.jpg	img007.jpg
9	[77]img008.jpg	img008.jpg
10	[88]img009.jpg	img009.jpg
11		

Excel任务实施

将数据集中“图像名列表”列中的图像文件名提取出来，存放在“效果”列。

D2			
=REPLACE(A2,1,4,"")			
	A	B	C
1	图像名列表	效果	RIGHT函数
2	[00]img001.jpg	img001.jpg	img001.jpg
3	[11]img002.jpg	img002.jpg	img002.jpg
4	[22]img003.jpg	img003.jpg	img003.jpg
5	[33]img004.jpg	img004.jpg	img004.jpg
6	[44]img005.jpg	img005.jpg	img005.jpg
7	[55]img006.jpg	img006.jpg	img006.jpg
8	[66]img007.jpg	img007.jpg	img007.jpg
9	[77]img008.jpg	img008.jpg	img008.jpg
10	[88]img009.jpg	img009.jpg	img009.jpg

D2			
=REPLACE(A2,1,4,"")			
	A	B	C
1	图像名列表	效果	RIGHT函数
2	[00]img001.jpg	img001.jpg	img001.jpg
3	[11]img002.jpg	img002.jpg	img002.jpg
4	[22]img003.jpg	img003.jpg	img003.jpg
5	[33]img004.jpg	img004.jpg	img004.jpg
6	[44]img005.jpg	img005.jpg	img005.jpg
7	[55]img006.jpg	img006.jpg	img006.jpg
8	[66]img007.jpg	img007.jpg	img007.jpg
9	[77]img008.jpg	img008.jpg	img008.jpg
10	[88]img009.jpg	img009.jpg	img009.jpg
11			

机器学习框架



scikit-learn库介绍



数据预处理

scikit-learn库中的数据预处理模块包括多种工具，用于数据标准化、归一化等，以提高模型训练效率和性能。例如，通过MinMaxScaler可以将特征缩放到[0, 1]区间，或使用StandardScaler进行Z分数标准化。




数据集处理

scikit-learn提供的数据集模块datasets允许用户轻松加载和使用各种标准数据集，如鸢尾花数据集和糖尿病数据集，这些数据集常用于测试和演示机器学习算法。



特征选择与降维

特征选择是提高模型性能的关键步骤。scikit-learn中的feature_selection模块提供多种方法，如SelectKBest和RecursiveFeatureElimination，帮助选择最相关的特征并去除噪声。



scikit-learn库功能

分类与回归模型

scikit-learn提供了多种分类和回归模型，如决策树、支持向量机和随机森林等，这些模型都经过了良好的封装，使得模型的训练和预测变得简单快捷。

聚类算法

模型评估是机器学习流程中不可或缺的一部分。scikit-learn提供了多种评估指标，如准确率、召回率和F1分数等，以及交叉验证工具，帮助用户全面评估模型性能。

模型评估

聚类是无监督学习的一个重要分支，scikit-learn中的cluster模块提供了K均值聚类、层次聚类等多种聚类算法，适用于不同的数据集和业务场景。

深度学习框架



TensorFlow

TensorFlow是一个由Google开发的开源机器学习框架，它提供了灵活的架构和丰富的API，支持多种深度学习模型的构建和训练。



PyTorch

PyTorch是由Facebook的AI研发团队开发的深度学习框架，它以动态计算图和强大的自动微分功能而闻名，特别适合于研究和开发复杂的神经网络模型。



Keras

Keras是一个高层神经网络API，它可以运行在多个后端上，如TensorFlow和Theano。Keras的设计哲学是让用户能够以最小的努力实现和训练深度学习模型。



01.

PaddlePaddle

PaddlePaddle是百度开发的深度学习平台，它提供了丰富的模型库和工具集，支持多种深度学习应用，如自然语言处理和计算机视觉。

02.

MindSpore

MindSpore是华为推出的深度学习平台，它支持多种硬件平台，并提供了从云到边缘的全场景AI计算能力，特别适合于需要高性能和安全性的AI应用。

谢谢大家

