

智能训练



数据处理规范



C O N T E N T S

目录

01

数据处理概述

02

数据处理规范

03

数据清洗工具

04

数据标注工具



数据处理概述--数据处理的重要性



数据处理是AI产品智能化的核心环节，为模型训练与测试提供高质量数据支持。



优质数据对人工智能企业至关重要，直接影响AI模型的性能和准确性。



数据处理概述--数据处理的基本流程



数据采集：收集文本、视觉、语音等多种类型和格式的数据。



数据清洗：处理数据集中的缺失值、噪声、重复等问题，提高数据质量。



数据标注：对清洗后的数据进行标注，根据不同需求划分不同的标注任务。



数据审核：审核员对标注数据进行核对和校验，确保标注的准确性。



数据质检：随机抽取数据进行核查，确保标注数据的有效性。



数据验收：对质检合格的数据进行抽检，确保数据的最终质量。



数据处理规范--数据清洗规范

01

数据清洗基本步骤：**数据分析、定义清洗规则、验证评估、数据清洗、干净数据回流。**


- ① **数据分析。**数据分析是数据清洗的前提和基础，通过数据清洗工具或编写程序对原始 数据进行检测分析，找到数据质量问题。
- ② **定义数据清洗的规则和方法。**根据“脏”数据类型，制定数据清洗规则，选择合适的 数据清洗方法。
- ③ **验证和评估。**对步骤②中定义的数据清洗规则的正确性和清洗效率进行验证和评估。一般在数据源中选择数据样本进行清洗验证，当测试结果不满足数据清洗要求时，需要对原 有的数据清洗规则进行调整和改进。
- ④ **数据清洗。**根据“脏”数据类型，利用数据清洗工具，按照清洗规则进行数据清洗。需要注意的是，数据清洗是一个反复的过程，需要不断地发现清洗过程中的各类问题，并解 决问题。数据清洗的过程中一定要做好对原始数据的备份，以防需要恢复原始数据。
- ⑤ **干净数据回流。**当数据被清洗后，干净的数据应该替换数据源中的原始数据，以避免 再次抽取数据时进行重复清洗。



数据处理规范--数据标注规范



数据标注规则：**贴边、独立、不越界、确定共同特征。**



- ①**贴边**。在画标注框时，标注框大小适当，不能太大或太小，需要紧贴标注对象的边缘。
- ②**独立**。每个标注对象都需要一个单独的标注框。例如，相邻的两辆汽车不能拉一个框，要拉两个框。
- ③**不越界**。标注框不能在图片的边界上，一旦超出边界，在程序运行中就会出现错误。
- ④**确定共同特征**。在制定标注规范时，需要对标注数据进行观察，找出标注对象的共同特征。



数据清洗工具--Smartbi



Smartbi的数据清洗功能非常强大，具有轻量级ETL(extract,抽取; transform,转换; load,加载)功能，可视化流程配置，简单易用。采用分布式计算架构，单节点支持多线程，可处理大量数据，具有强大的数据处理性能。



Smartbi不仅支持异构数据，还支持内置排序、去重、映射、行列合并、行列转换聚合、去空值等数据预处理功能。



数据清洗工具--Excel

Excel 是一种常用的数据分析工具，可以进行多种数据的处理及统计分析，包括数据清洗。但是在数据量较大的情况下，其数据处理性能较差。



数据清洗工具--Python



Python 是一种面向对象的计算机程序设计语言。Python 语言具有简洁性、易读性、可扩展性等优点，在数据分析、数据可视化等方面都有非常成熟的库，适合具有一定编程能力的人员进行数据处理。





数据清洗工具--VBA



是 Visual Basic的一种宏语言，是由微软开发并在其桌面应用程序中执行通用自动化任务的编程语言，主要用来扩展Windows的应用程序功能。VBA可以使现有的应用程序实现自动化，并可以通过自定义方法创建需要解决的问题方案。



数据标注工具--CVAT



CVAT 是一款免费、开源的交互式数据标注工具，适用于计算机视觉领域的 数据标注。CVAT具有以下功能。

- 1)对图像进行多边形、矩形、椭圆形、线段、多段线、点形式的标注。
- 2)支持3D图形标注，支持视频标注。
- 3)支持导出VOC 、COCO 、TFRecord等多种格式的数据集。



数据标注工具--Labelme



Labelme 是麻省理工学院的计算机科学和人工智能实验室研发的开源图像标注工具，该工具可以创建定制化标注任务或执行图像标注。Labelme 基于Python 和PyQT 开发，源代码可以安装在服务器上使用，是一个在线的JavaScript 图像标注工具，并可对其进行二次开发和优化。Labelme 具有以下功能。

- 1)对图像进行多边形、矩形、圆形、线段、多段线、点形式的标注。
- 2)对图像进行打标签形式的标注(可用于图像分类和清理任务)。
- 3)支持3D图形标注，支持视频标注。
- 4)支持生成VOC、cOCO格式的数据集。



数据标注工具--Label Studio

Label Studio是一个开源的、可配置的数据标注工具，具有以下特点。

1)可配置。使用JSX 标签配置，自定义配置标注页面，具有丰富的可标注格式和自定义样式。

2)协作标注。由多人标注同一任务，支持结果比较。

3)多种数据类型。具有不同的标注类型，如图像、语音、文本、HTML等，有大量模板，可直接使用接口。

4)支持导入格式。支持JSON,CSV,TSV,RAR 和 ZIP文件，支持API导入数据。

5)机器学习模型集成。Label Studio与机器学习模型集成，以提供标签(预标签)的预测或执行持续的主动学习，可视化并比较来自不同模型的预测。

6)提供预标记标签功能。支持用训练的模型预标注数据。




数据标注工具--Doccoano



Doccoano 是一个开源文本标注工具，提供了文本分类、序列标注、序列到序列的标注功能。用户可以为情绪分析、命名实体识别、文本摘要等创建标记数据。




总结



智能训练案例



目录



01

人工智能训练基础

03

MNIST手写数字分
类案例


02

波士顿房价预测案
例

人工智能训练基础--人工智能训练的定义与重要性

人工智能训练的概念

人工智能训练指的是通过大量数据对AI模型进行训练，使其能够学习并模拟人类智能行为的过程。



人工智能训练的挑战

数据质量、模型选择、计算资源和过拟合问题是人工智能训练中的主要挑战。

人工智能训练的重要性

训练是AI模型开发的核心环节，直接影响模型的性能和应用效果，是实现智能化的关键步骤。

人工智能训练基础--人工智能训练的基本流程

数据准备

收集和预处理训练数据，确保数据的质量和多样性。

模型选择

根据任务需求选择合适的模型架构，如RNN、CNN等。

训练执行

使用训练数据对模型进行训练，并调整超参数。

评估优化

评估模型性能并进行调优，使用准确率、召回率等指标。

人工智能训练基础--人工智能训练的应用场景

01

自然语言处理

情感分析、机器翻译、文本摘要等。

02

计算机视觉

图像识别、目标检测、图像分割等。

03

推荐系统

个性化推荐、广告投放、内容推荐等。

波士顿房价预测案例--项目背景



项目价值

房价预测对于房地产市场分析、投资决策具有重要意义。



数据来源与特点

数据集包含波士顿地区房屋的多个属性，如人口数、家庭数、收入、临海情况、房屋平均房间数等。



预测模型的选择

线性回归、决策树、随机森林、SVM和神经网络等模型可用于房价预测。

波士顿房价预测案例--数据处理与模型训练



数据预处理

数据清洗、特征选择、数据标准化等步骤。

模型训练

使用多种模型对数据进行训练，调整模型参数。



模型评估

使用均方误差、决定系数等指标评估模型性能。



波士顿房价预测案例--数模型应用与结果分析



模型应用

将训练好的模型应用于实际房价预测。



结果分析

分析模型预测结果的准确性和稳定性。



模型优化

根据预测结果对模型进行优化，提高预测精度。



MNIST手写数字分类案例--项目背景



MNIST数据集简介

MNIST是计算机视觉领域中最基础的手写数字识别数据集。



数据集构成

数据集包含6万张训练图像和1万张测试图像，每张图像为28x28像素的手写数字。



分类模型的选择

卷积神经网络(CNN)是手写数字分类的首选模型。

MNIST手写数字分类案例--数据处理与模型训练

01

数据预处理

图像归一化、数据增强等步骤。

02

模型训练

使用CNN对数据进行训练，调整网络结构和超参数。

03


模型评估

使用准确率、混淆矩阵等指标评估模型性能。

MNIST手写数字分类案例--模型应用与结果分析


模型应用

将训练好的模型应用于手写数字的识别。




模型优化

根据识别结果对模型进行优化，提高识别准确率。



结果分析

分析模型识别手写数字的准确性和鲁棒性。



谢谢大家

