

《智能训练》备考指南

数据清洗和处理

填空和选择

查看

```
1 data.info      #查看数据的规模，查看大小
2 data.shape     #查看数据的形状[6,6]
3 data.dtypes()  #查看数据类型
4 data.head()    #默认预览前5行数据
5 data.tail()    #默认预览后5行数据
```

缺失值

```
1 data.isnull()      #判断数据是否缺失
2 data.dropna()       #去除包含缺失值的数据(行)
3 data.dropna(axis = 1) #去除有缺失值的列
4 data.fillna(0)      #用0填充缺失值
```

重复值

```
1 data.duplicated()      #判断数据是否重复
2 data.duplicated(['aa','bb']) #判断aa列、bb列的数据是否重复
3 data.drop_duplicates()  #删除重复的行
4 data.drop_duplicates(['aa','bb']) #删除aa列、bb列重复的行
```

机器学习

读取数据与划分

读取数据

划分特征变量和标签

划分训练集和测试集

```
1 from sklearn.model_selection import train_test_split
2 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = ?, random_state = 42)
```

一维转二维

模型的搭建与使用

模型搭建

题意要求不同模型

5个模型

模型搭建

导入朴素贝叶斯模型，这里选用高斯分类器

```
14 from sklearn.naive_bayes import GaussianNB
15 model = GaussianNB()
16 model.fit(X_train, y_train)
```

```
from sklearn.linear_model import LogisticRegression
model = LogisticRegression()
model.fit(X_train, y_train)
```

导入逻辑回归模型

```
from sklearn.ensemble import RandomForestClassifier
model = RandomForestClassifier()
model.fit(X_train, y_train)
```

导入随机森林模型

```
from sklearn.tree import DecisionTreeClassifier
model = DecisionTreeClassifier()
model.fit(X_train, y_train)
```

导入决策树模型

```
from sklearn.neighbors import KNeighborsClassifier
model = KNeighborsClassifier()
model.fit(X_train, y_train)
```

导入K近邻模型

```
1 from xxxxxx import aaa
2 model = aaa()
```

```
3 model.fit(X_train,y_train)
```

模型预测与评估

使用训练集拟合的模型对测试集进行预测，并输出

```
1 y_test_pred = model.predict(X_test)
2 print(y_test_pred)
```

使用测试集计算出模型的准确度/精确度，并输出

```
1 accuracy = model.score(X_test , y_test)
2 print(accuracy)
```