

某汽车公司推出了新款的豪华汽车，并收集了用户的预估薪资，预测用户是否会购买这款汽车。数据表如下，请在考试系统上用Python语句完成下述要求并保存。

序号	预估薪资	是否会购买
1	43000	0
2	150000	1
3	57000	0
...	...	...

(1) 数据处理规范制定 (10分) ——选择题

- ①读取"data.csv"的数据集 (2分)。
- ②显示前十五行数据 (2分)。
- ③显示描述性统计信息 (2分)。
- ④对数据集数据进行预处理，处理缺失值 (2分)。
- ⑤对数据集数据进行预处理，删除重复行 (2分)。

答：

```
In [33]: import pandas as pd

# ①读取 "data.csv"的数据集
data = pd.read_csv("data.csv") #注意：双引号中的文件路径要按照实际题目给的来填

# ②显示前十五行数据
print(data.head(15)) #注意：括号内的数字决定行数，比如前20行，就是data.head(20)

# ③显示描述性统计信息
print(data.describe())

# ④处理缺失值
data = data.dropna()
```

```
# 删除重复行
data = data.drop_duplicates()
```

	序号	预估薪资	是否会购买
0	1	141958.0	0.0
1	2	166867.0	1.0
2	3	151932.0	1.0
3	4	123694.0	NaN
4	5	139879.0	0.0
5	6	130268.0	0.0
6	7	74886.0	0.0
7	8	157337.0	1.0
8	9	188266.0	1.0
9	10	107498.0	0.0
10	11	132727.0	0.0
11	12	146324.0	1.0
12	13	195203.0	1.0
13	14	36023.0	0.0
14	15	61090.0	0.0

	序号	预估薪资	是否会购买
count	210.000000	200.000000	205.000000
mean	101.333333	111412.685000	0.439024
std	57.567961	50975.944934	0.497483
min	1.000000	20769.000000	0.000000
25%	52.250000	70968.500000	0.000000
50%	101.500000	114408.000000	0.000000
75%	150.000000	150116.500000	1.000000
max	200.000000	199997.000000	1.000000

(2) 绘制图形 (8分) ——要手写代码

- ①绘制预估薪资直方图，尺寸为6*4 (4分)。
- ②绘制预估薪资与是否会购买的散点图，透明度为0.7 (4分)。


答:

```
In [42]: import matplotlib.pyplot as plt
```

```
# @绘制预估薪资直方图，尺寸为6*4
```

```
data['预估薪资'].hist(figsize=(6,4)) #注意：如果题目要求尺寸为10*10，那就把数值写成(10,10)
```


Out[42]: <Axes: >



In [43]: # @绘制预估薪资与是否会购买的散点图，透明度为0.7

```
plt.scatter(data['预估薪资'], data['是否会购买'], c=data['是否会购买'], alpha=0.7)
```

Out[43]: <matplotlib.collections.PathCollection at 0x197b8035af0>



(3) 算法测试 (17分) ——要手写代码

- ①划分特征X与标签y (字段名: 是否会购买) (2分)。
- ②按照8:2的比例, 随机划分为训练集和测试集 (4分)。
- ③将训练数据特征、测试数据特征分别转换成二维数组 (2分)。
- ④定义逻辑回归模型, 用划分后的数据在训练集上训练模型 (4分)。
- ⑤输出测试集的准确度 (3分)。
- ⑥输出测试集的预测值 (2分)。

答:

```
In [44]: # ①划分特征X与标签y (字段名: 是否会购买)
X = data['预估薪资']
y = data['是否会购买']
```

```

# ②按照8:2的比例，随机划分为训练集和测试集
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# ③将训练数据特征、测试数据特征分别转换成二维数组
X_train = X_train.values.reshape(-1,1)
X_test = X_test.values.reshape(-1,1)

# ④定义逻辑回归模型，用划分后的数据在训练集上训练模型
from sklearn.linear_model import LogisticRegression
model = LogisticRegression()
model.fit(X_train, y_train)

# ⑤输出测试集的准确度
accuracy = model.score(X_test, y_test)
print(accuracy)

# ⑥输出测试集的预测值
y_pred = model.predict(X_test)
print(y_pred)

```

0.6578947368421053

```

[1.  0.  1.  0.  0.  0.  1.  0.  0.  1.  0.  1.  1.  1.  0.  0.  1.  0.  1.  0.  0.  1.  1.  1.
 0.  1.  0.  0.  0.  0.  0.  0.  0.  0.  0.  0.  1.  1.]

```