

鸢尾花数据集包含150个鸢尾花样本，均匀分为山鸢尾、变色鸢尾和维吉尼亚鸢尾三个类别，每个样本测量了花萼长度、花萼宽度、花瓣长度和花瓣宽度四个连续数值特征。请在考试系统上使用Python语句完成下述要求，并保存。

(1) 数据处理规范制定 (10分) ——选择题

- ①加载鸢尾花数据集 (2分) 。
- ②显示前十五行数据 (2分) 。
- ③查看数据集概况 (2分) 。
- ④检查数据集是否存在空值 (2分) 。
- ⑤检查数据集是否存在重复行 (2分) 。

答：

```
In [55]: import pandas as pd
from sklearn.datasets import load_iris

# ①加载鸢尾花数据集
iris = load_iris()

# sklearn库中的鸢尾花数据集是Bunch对象，要转为DataFrame才能调用head()、isna()等
data = pd.DataFrame(iris.data, columns=iris.feature_names)
data['target'] = iris.target

# ②显示前十五行数据
print(data.head(15)) #注意：括号内的数字决定行数，比如前20行，就是data.head(20)

# ③查看数据集概况
print(data.info())

# ④检查数据集是否存在空值
print(data.isna())

# ⑤检查数据集是否存在重复行
print(data.duplicated())
```

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	\
0	5.1	3.5	1.4	0.2	
1	4.9	3.0	1.4	0.2	
2	4.7	3.2	1.3	0.2	
3	4.6	3.1	1.5	0.2	
4	5.0	3.6	1.4	0.2	
5	5.4	3.9	1.7	0.4	
6	4.6	3.4	1.4	0.3	
7	5.0	3.4	1.5	0.2	
8	4.4	2.9	1.4	0.2	
9	4.9	3.1	1.5	0.1	
10	5.4	3.7	1.5	0.2	
11	4.8	3.4	1.6	0.2	
12	4.8	3.0	1.4	0.1	
13	4.3	3.0	1.1	0.1	
14	5.8	4.0	1.2	0.2	

	target
0	0
1	0
2	0
3	0
4	0
5	0
6	0
7	0
8	0
9	0
10	0
11	0
12	0
13	0
14	0

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 150 entries, 0 to 149
```

```
Data columns (total 5 columns):
```

#	Column	Non-Null Count	Dtype
0	sepal length (cm)	150 non-null	float64
1	sepal width (cm)	150 non-null	float64
2	petal length (cm)	150 non-null	float64

```
3  petal width (cm)  150 non-null  float64
4  target            150 non-null  int32
```

```
dtypes: float64(4), int32(1)
```

```
memory usage: 5.4 KB
```

```
None
```

```
      sepal length (cm)  sepal width (cm)  petal length (cm)  petal width (cm)  \
0                False                False                False                False
1                False                False                False                False
2                False                False                False                False
3                False                False                False                False
4                False                False                False                False
..                ...                ...                ...                ...
145              False                False                False                False
146              False                False                False                False
147              False                False                False                False
148              False                False                False                False
149              False                False                False                False
```

```
      target
0        False
1        False
2        False
3        False
4        False
..         ...
145      False
146      False
147      False
148      False
149      False
```

```
[150 rows x 5 columns]
```

```
0        False
1        False
2        False
3        False
4        False
..         ...
145      False
146      False
147      False
```

```
148     False
149     False
Length: 150, dtype: bool
```

(2) 绘制图形 (8分) ——要手写代码


- ①绘制花萼长度的直方图，尺寸为6*4（4分）。
- ②绘制花萼长度、花萼宽度的散点图，透明度设置为0.7（4分）。

答：

```
In [56]: import matplotlib.pyplot as plt
sepal_length = data['sepal length (cm)']
sepal_width = data['sepal width (cm)']


# ①绘制花萼长度的直方图，尺寸为6*4
sepal_length.hist(figsize=(6,4)) #注意：如果题目要求尺寸为10*10，那就把数值写成(10,10)
```

```
Out[56]: <Axes: >
```



```
In [57]: # @绘制花萼长度、花萼宽度的散点图，透明度设置为0.7  
plt.scatter(sepal_length, sepal_width, c=sepal_width, alpha=0.7)
```

```
Out[57]: <matplotlib.collections.PathCollection at 0x1a482b0f4a0>
```



注意：（3）算法测试 这块可能抽到简单的那套题，也可能抽到难的那套题，我在下面都分别写出来：

（3）算法测试（17分）——简单题

- ①划分特征X与标签y，X只取前两个特征（4分）。
- ②按照8:2的比例，随机划分为训练集和测试集（4分）。
- ③定义逻辑回归模型，用划分后的数据在训练集上训练模型（4分）。
- ④输出测试集的准确度（3分）。
- ⑤输出测试集的预测值（2分）。

答：

```
In [58]: # ①划分特征X与标签y，X只取前两个特征
X = data.iloc[:, 0:2]
```

```

y = data['target']

# ②按照8:2的比例，随机划分为训练集和测试集
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# ③定义逻辑回归模型，用划分后的数据在训练集上训练模型
from sklearn.linear_model import LogisticRegression
model = LogisticRegression()
model.fit(X_train, y_train)

# ④输出测试集的准确度
accuracy = model.score(X_test, y_test)
print(accuracy)

# ⑤输出测试集的预测值
y_pred = model.predict(X_test)
print(y_pred)

```

0.9

[1 0 2 1 2 0 1 2 1 1 2 0 0 0 0 2 2 1 1 2 0 1 0 2 2 2 2 2 0 0]

(3) 算法测试 (17分) ——难题

- ①划分特征X与标签y (2分)。
- ②按照8:2的比例，随机划分为训练集和测试集 (2分)。
- ③对数据集特征做标准化处理 (2分)。
- ④定义SVR模型，用划分后的数据在训练集上训练模型，模型迭代次数1000 (4分)。
- ⑤输出测试集的准确度 (保留2位小数)、预测值 (4分)。
- ⑥输出测试集的分类报告 (3分)。

答：

```

In [59]: # ①划分特征X与标签y
X = data.drop(columns=['target'])
y = data['target']

# ②按照8:2的比例，随机划分为训练集和测试集
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

```

```

# ③对数据集特征做标准化处理
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# ④定义SVR模型，用划分后的数据在训练集上训练模型，模型迭代次数1000
from sklearn.svm import SVC
model = SVC(max_iter=1000, random_state=42)
model.fit(X_train_scaled, y_train)

# ⑤输出测试集的准确度（保留2位小数）、预测值
accuracy = model.score(X_test_scaled, y_test)
print(f'准确度: {accuracy:.2f}')

y_pred = model.predict(X_test_scaled)
print(f'预测值: {y_pred}')

# ⑥输出测试集的分类报告
from sklearn.metrics import classification_report
report = classification_report(y_test, y_pred)
print(report)

```

准确度: 1.00

预测值: [1 0 2 1 1 0 1 2 1 1 2 0 0 0 0 1 2 1 1 2 0 2 0 2 2 2 2 0 0]

	precision	recall	f1-score	support
0	1.00	1.00	1.00	10
1	1.00	1.00	1.00	9
2	1.00	1.00	1.00	11
accuracy			1.00	30
macro avg	1.00	1.00	1.00	30
weighted avg	1.00	1.00	1.00	30

(3) 算法测试 (17分) ——难题变形

- ①划分特征X与标签y (2分)。
- ②按照8:2的比例，随机划分为训练集和测试集 (2分)。

- ③对数据特征进行标准化处理，使用SVR模型进行训练，创建Pipeline管道，将特征标准化处理和SVR模型训练串联起来（9分）。
- ④输出测试集的准确度、预测值（4分）。

答：

```
In [60]: # ①划分特征X与标签y
X = data.drop(columns=['target'])
y = data['target']

# ②按照8:2的比例，随机划分为训练集和测试集
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# ③对数据特征进行标准化处理，使用SVR模型进行训练，创建Pipeline管道，将特征标准化处理和SVR模型训练串联起来
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
from sklearn.pipeline import Pipeline

pipe = Pipeline([
    ('scaler', StandardScaler()),
    ('svc', SVC(max_iter=1000, random_state=42))
])

pipe.fit(X_train, y_train)

# ④输出测试集的准确度、预测值
accuracy = pipe.score(X_test, y_test)
print(f'准确度: {accuracy}')

y_pred = pipe.predict(X_test)
print(f'预测值: {y_pred}')
```

准确度: 1.0

预测值: [1 0 2 1 1 0 1 2 1 1 2 0 0 0 0 1 2 1 1 2 0 2 0 2 2 2 2 2 0 0]