

智能系统设计



智能系统设计和 优化



学习单元1

单一智能产品/系统 的设计



目录

CONTENTS

01

智能系统设计基础

02

智能产品设计流程

03

任务实施

04

单元总结

05

案例拓展



智能系统设计基础

智能系统设计的涵盖范围很广，包括算法和模型设计。

数学基础

首先，智能系统设计涉及数学方面的知识，包括线性代数、概率论与数理统计、最优化理论、信息论、形式逻辑、离散数学等，这些知识蕴含着处理人工智能问题的基本思想与方法，也是理解复杂算法的基础。

代码基础

其次，智能系统设计需要一定的计算机专业能力，尤其是能够使用合适的计算机编程语言进行编程。编程语言很多，每种语言各有其擅长的应用领域，Python 语言在人工智能领域应用非常广泛，通常是开发人工智能相关程序的首选。互联网上有大量基于Python的人工智能开发包和开发框架，学会如何使用这些框架和调用开发包的应用程序接口(API)，能使开发人员不必从头开始，而是“站在他人的肩膀上”，可以为开发节省大量的时间和精力，并且降低错误率，提高开发速度和效率。

专业基础

最后，如果想更进一步设计出好的算法和模型，必须对人工智能领域的相关知识(如数据处理和机器学习等)有深入的了解。这方面的工作目前通常由人工智能科学家和算法工程师来完成。

人工智能训练师，其工作核心并非自行设计算法和模型，所以本学习单元及后续学习单元聚焦的智能设计，主要是指利用适当的AI开发框架和平台，在已有的算法和模型中进行甄选，或对已有算法和模型加以改进，在此基础上为智能产品设计合适的解决方案。



智能产品设计流程--应用AI技术设计智能产品/系统的一般步骤

- (1)明确所设计的智能产品/系统所要达到的商业目标。
- (2)收集与该产品/系统设计相关的各类数据。
- (3)清洗和预处理数据，使其准确并易于AI 模型分析和处理。
- (4)选择 一个适当的AI 算法。
- (5)使用经过预处理的数据训练AI模型。
- (6)测试并优化 AI 模型，以保证其符合该产品/系统设计所要求达到的性能。
- (7) 将AI 模型部署到所设计的智能产品/系统中。
- (8)监视 AI 模型的性能，并作必要的调整使其能持续符合预定的设计目标。

应用AI 技术设计智能产品/系统，必须对设计过程中要解决的问题作细致的分析，如 目前可用或缺少的资源、所使用数据的规模和复杂度等。针对具体问题作具体分析，制订有 针对性的解决方案。



智能产品设计流程--智能产品/系统设计过程中的关键点

(1)智能产品构思

在智能产品开发早期会对其商业模式进行细致的考量，在构思和规划新的智能产品时，需要基于对行业的深刻理解与洞察，对产品进行价值分析和评估，重点关注产品的行业属性与产业价值，研判产品能否给用户真正带来价值并为用户所认可(即用户愿意为该产品买单)。一个AI产品成功的关键往往并不在于其使用了多么先进的AI技术，而是在于其抓住了用户的痛点，能切实为用户提供创新价值。



(2)数据准备

在智能产品设计和开发阶段，数据准备是AI开发所特有的极其重要的环节。AI技术离不开数据，正是依赖大量的数据作导向，才让机器获得智能。该阶段通过聚焦需求、分析业务，确定需要哪些数据来支撑和满足这些需求。这些数据有些已经被积累，缺少的则可以通过自行采集、购买等方式获取。最后对收集到的数据进行整理和预处理，将其作为算法模型的输入。





智能产品设计流程--智能产品/系统设计过程中的关键点

(3)模型训练和结果评价

在智能产品开发阶段，需要根据行业经验选择合适的人工智能算法和模型，用收集和整理得到的数据对模型进行训练。训练完成后需对模型的性能进行评估，不断迭代优化，直到符合设计要求。这样新模型才能用于智能产品。

(4)产品化

若智能产品最后是以硬件形式呈现，需对产品进行工业设计、结构设计、硬件设计等。工业设计的主要工作是外观设计，包括外形、颜色、材料、表面处理的设计。结构设计是针对产品内部结构、机械部分的设计。设计者既要构想一系列关联零件来实现各项功能，又要考虑产品结构紧凑、外形美观；既要安全耐用、性能优良，又要易于制造、降低成本。硬件设计主要包括电路分析、设计，PCB(printed circuit board,印制电路板)设计，电子元件的焊接，以及最后环节的整体测试、调试。



任务实施--任务背景

传统上企业一般采用人工识别信息录入的方式，由专门的数据录入人员将票据上的信息录入计算机存储和处理。但随着企业规模的扩大和销售业务的拓展，审票的工作量日渐增长，这种手动录入的方式会带来以下挑战。

(1)人工录入方式存在瓶颈，影响业务快速扩张。

人工识别信息录入的方式耗时耗力，增加录单人员和设备等则会导致办公成本的增加，因此这种方式无法支撑业务快速扩张。

(2)高强度工作下容易出错，录入错误率高。

传统的录单任务繁重、工作强度大，录单人员在高强度重复工作状态下极易疲劳出错，而录入数据的差错则可能影响到后期工作，给企业造成损失。

(3)机密信息难以管理，存在泄密风险。

传统录入模式每张单据或证件都需要人员干预，存在客户信息泄露的风险，所以对机密或敏感信息必须有相应的安全措施。

(4)人工录入时间长，影响数据分析时效。

基础数据采集效率低下，难以迅速采集企业关联数据并进行及时分析，会引起综合统计数据滞后，影响企业正确决策。



任务实施--任务背景

为了解决上述问题，业界一直在探索用计算机来自动识别票据的方法，OCR 就应运而生。**OCR(optical character recognition,光学字符识别)**是指电子设备(例如扫描仪或数码相机)检查纸上打印的字符，通过检测暗、亮的模式确定其形状，然后用字符识别方法将形状 翻译成计算机文字的过程。OCR的目的是从图片中提取文字信息，供计算机进行进一步处理。近年来，随着深度学习等技术的发展，OCR 技术取得了突破性进展，在票据识别等落地应用上已达到很高的识别率。

OCR可分为**手写体识别**和**印刷体识别**两类。因为印刷体大多是规则的字体，相对手写体识别要略微简单些，但仍然会面临一些问题，如在印刷过程中字体很可能断裂或者墨水粘连，这增加了OCR的难度(这里假设票据中的文字为印刷体)。

早期OCR一般采用特征提取方法，要对字符进行特征设计(可以是字符本身的结构特征或者人工设计的方向特征、轮廓特征、孔洞特征等),对需要识别的字符进行特征提取，之后将提取到的特征输入分类器中做分类，才可以得到最终的识别结果。这类方法在特征设计阶段要花费大量的时间与精力，同时模型泛化能力较差，不能灵活适应字体变化及背景干扰。随着深度学习技术的不断发展，**卷积神经网络**开始取代特征提取器和分类器的角色。直接输入包含大量单个字符的图像，训练神经网络进行字符的特征提取，可以省略特征设计的阶段，直接得到识别结果。



任务实施--任务内容

某公司决定开发一款票据OCR 功能产品，可以帮助公司员工快速导入票据信息，节省录单时间，提高录单准确率，增加公司效益。

为简单起见，假设票据的文字只包含大写英文字母(26个)、阿拉伯数字(10个),共 计36个符号(即样本种类),且全部为印刷体。要求利用AI技术，设计出符合业务要求的票据OCR系统产品，并给出相应智能系统的设计方案。



任务实施--实施环境

(1)硬件设备。计算机一台。

(2)软件配置。Python开发环境、TensorFlow框架、Numpy等模块。



任务实施--实施方案


(1)技术路线。基于深度学习的算法模型通常将OCR分为两个阶段：**文本检测**和**文本识别**。先检测出图片中包含的文本，正确标注出文本框的位置；再对文本框中的文本进行识别。

纸质的票据用OCR设备扫描后，得到数字化的图像。第一步是图像预处理。由于扫描得到的图像很可能有倾斜，或者部分文字扭曲、缺失或有污渍，所以首先需要进行角度矫正和去噪，从而得到矫正和去噪后的图像文本。

第二步是用文本检测算法定位票据中的文本，并用矩形框框出。早期的算法还需对矩形框内的文本进行分隔，分隔出单个字符。改进后的算法则可省略这个步骤，后续可直接处理矩形框内的整行文本。

第三步是将经过第二步处理后的文本送入训练好的OCR模型进行识别，得到识别结果。如需要，还可以进行识别结果矫正等后续处理。

这三步是票据OCR的基本流程。这里有两个关键模型：**文本检测模型(票据中文本的定位和分隔)**和**文本识别模型(识别分隔出来的字符是什么)**。设计和训练这些模型是产品设计的重点。





任务实施--实施方案

(2)实施步骤

1)创建模型。文本检测和识别已有一些较成熟的模型，将在后面介绍。为帮助了解模型设计的完整过程，作为演示实例，这里先从零开始自行设计一个简单的深度学习模型用于票据识别。

一般进行模型设计时可根据企业实际情况，选择合适的人工智能框架和模型。有些企业选择TensorFlow、PyTorch 等主流开源框架，也有企业使用自研的AI框架和集成化的AI云平台，如百度飞桨 PaddlePaddle开源深度学习框架和EasyDL开发平台、华为ModelArts AI 开发平台、商汤的SenseParrots AI训练框架等。

2)模型训练和测试

3)模型应用。模型训练好以后，就可以应用模型来进行文字识别。



任务实施--实施方案

(2)实施步骤

1)创建模型。

下面以开源的TensorFlow框架为例，说明如何训练和创建一个能完成上述任务的简单模型。

假设前面文本检测的工作已完成，最后得到分隔后单个字符的图像，该图像为灰度图像 (256级灰度),图像尺寸已调整为统一的尺寸(如28×28像素)。因为文本只包含大写英文 字母和阿拉伯数字共计36个符号(即样本种类),由于样本种类不多，可以用一个只包含2 个卷积层的简单的卷积神经网络(ConvNet)来进行分类和识别。

① 导入依赖项

```
# 导入依赖项
import tensorflow as tf
import numpy as np
...
```

先导入依赖项，即后面代码需用到的 python包、类或函数。上面代码只是一个示例。



任务实施--实施方案

(2)实施步骤

1)创建模型。

② 数据获取和预处理

```
# 数据获取和预处理
# 假设 load_data() 方法提供已标注好的图像数据集，含训练集和测试集
(X_train, y_train), (X_test, y_test) = load_data()
# 利用 reshape 函数转换数字图像
X_train_reshape = X_train.reshape (X_train.shape[0], 28, 28, 1)
X_test_reshape = X_test.reshape (X_test.shape[0], 28, 28, 1)
# 对数字图像进行归一化
X_train_norm, X_test_norm = X_train_reshape / 255.0, X_test_reshape / 255.0
...
```

因为数据集中每个样本对应的是 28×28 像素的灰度图像，假设load_data() 方法得到的 数据集的属性集 (X_train/X_test)中每个样本对应的是包含784个0~255间无符号数的向量 ($28 \times 28 = 784$ 像素点，每像素点用一个字节来表示)。因为总共只有36种符号类型，标签值的范围在0~35之间。



任务实施--实施方案

(2)实施步骤

1)创建模型。

② 数据获取和预处理

程序调用样本集的reshape方法将原来的一维向量形状改变为4维张量，第1维为样本数，第2、3维对应图像水平、垂直方向像素点数，第4维中的“1”表示灰度图像的通道数为1(用一个字节表示)。这4维张量中每个数的数值均在0~255之间(因为灰度图像的每个像素点用8位二进制表示，转为整数即0~255)。reshape方法一般可用于改变样本集(数组或矩阵)的形状，参数是重组后样本集各维度的尺寸。接着对数据进行归一化，数组中各数均除以255,将所有数据点归一化为0~1范围的浮点数，以便作为模型的输入。数据归一化常用于机器学习的预处理阶段，当数据集的特征间具有不同的值范围时，通过归一化可使特征具有相同的度量尺度，提高训练效果。类似的数据规格化措施还有标准化和正则化。



任务实施--实施方案

(2)实施步骤

1)创建模型。

② 数据获取和预处理

程序调用样本集的reshape方法将原来的一维向量形状改变为4维张量，第1维为样本数，第2、3维对应图像水平、垂直方向像素点数，第4维中的“1”表示灰度图像的通道数为1(用一个字节表示)。这4维张量中每个数的数值均在0~255之间(因为灰度图像的每个像素点用8位二进制表示，转为整数即0~255)。reshape方法一般可用于改变样本集(数组或矩阵)的形状，参数是重组后样本集各维度的尺寸。接着对数据进行归一化，数组中各数均除以255,将所有数据点归一化为0~1范围的浮点数，以便作为模型的输入。数据归一化常用于机器学习的预处理阶段，当数据集的特征间具有不同的值范围时，通过归一化可使特征具有相同的度量尺度，提高训练效果。类似的数据规格化措施还有标准化和正则化。



任务实施--实施方案

(2)实施步骤

1)创建模型。

③ 模型创建

```
# 模型创建
# 利用 Sequential 模型简单地线性堆叠网络层来构建神经网络模型
model = tf.keras.Sequential ( )
# 添加第 1 个卷积层
model.add (tf.keras.layers.Conv2D (32, kernel_size= (3, 3), activation='relu', input_shape=
(28, 28, 1)))
```

这里利用model.add()函数，将“输入层”和“隐藏层”添加到模型中。Conv2D()构造函数构建一个二维的卷积层，常用于图像识别。其中第一个参数32表示“隐藏层”的神经元个数为32个；参数kernel_size指定卷积核尺寸；参数activation='relu'表示该层的激活函数为ReLU函数，该函数为非线性函数，函数式为 $f(x)=\max(0,x)$ ；input_shape则指定输入层的神经元个数，当前为 $28 \times 28 \times 1 = 784$ (个)。



任务实施--实施方案

(2)实施步骤

1)创建模型。

③ 模型创建

```
# 在卷积层之后插入最大池化层  
model.add (tf.keras.layers.MaxPooling2D (pool_size= (2, 2)))
```

添加最大池化层。MaxPooling2D()构造函数的参数pool_size指定池化窗口大小为 2×2 。池化层可以有效缩小神经网络中参数矩阵的尺寸，从而减少最后连接层中的参数数量。所以 加入池化层可以起到加快计算速度和防止过拟合的作用。



任务实施--实施方案

(2)实施步骤

1)创建模型。

③ 模型创建

```
# 插入 dropout 层  
model.add (tf.keras.layers.Dropout (0.25))
```

添加dropout层。dropout层会随机关闭上一层的一小部分神经元(本例随机概率设为 0.25)。这样做是为了防止任何特定的神经元变得过于强大，导致模型与数据过拟合，从而影响模型对测试数据度量的准确性。



任务实施--实施方案

(2)实施步骤

1)创建模型。

③ 模型创建

```
# 添加第 2 个卷积层
model.add (tf.keras.layers.Conv2D (64, (3, 3), activation='relu'))
# 卷积层之后均插入了最大池化层和 dropout 层
model.add (tf.keras.layers.MaxPooling2D (pool_size= (2, 2)))
model.add (tf.keras.layers.Dropout (0.25))
```

添加第2个卷积层(神经元数64,卷积核 3×3)、最大池化层和dropout层。



任务实施--实施方案

(2)实施步骤

1)创建模型。

③ 模型创建

```
# 通过一个 flatten 层将卷积层的输出展平为一维向量  
model.add (tf.keras.layers.Flatten ( ))
```

添加 flatten层。这里 flatten层接收 28×28 像素的二维图像输入，并生成一个由784个 像素点组成的 一维向量，即下一个dense 层为一维。



任务实施--实施方案

(2)实施步骤

1)创建模型。

③ 模型创建

```
# 接一个一维全连接层 ( 同样使用 ReLU 激活函数 )  
model.add (tf.keras.layers.Dense (128, activation='relu'))  
# 最后是一个 dropout 层和一个 36 单元的 softmax 层  
model.add (tf.keras.layers.Dropout (0.5))  
model.add (tf.keras.layers.Dense (36, activation='softmax'))
```

添加一个一维全连接层[通过Dense()构造函数构造, 单元数128,并使用ReLU激活 函数];接着是一个dropout层; 最后是一个包含36个单元的softmax层。全连接层如果输出 值采用softmax逻辑回归进行分类, 该层也称为softmax 层。softmax函数可将实数范围的自 变量值映射到0~1之间的输出值, 并且输出值的总和是1,因此可以将softmax 函数的输 出解释为“概率”。一般而言, 神经网络只把输出值最大的神经元所对应的类别作为识别结 果。所以 softmax层输出单元实现了对输入符号图像的分类(即识别)。




任务实施--实施方案

(2)实施步骤

1)创建模型。

③ 模型创建





任务实施--实施方案

(2)实施步骤

2)模型训练和测试。

①模型编译

```
# 模型编译
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
```

模型构建完成后，必须对模型进行编译后才可以训练模型。其中，参数 `optimizer` 指定用于训练模型的优化器，这里的 `adam` 是一种常见的优化器，它可以让模型快速收敛并提高准确率；`loss` 指定损失函数，这里使用 `crossentropy`(交叉熵)作为损失函数；`metrics` 指定模型的评价指标，这里使用准确率(`accuracy`)来评价模型。



任务实施--实施方案

(2)实施步骤

2)模型训练和测试。

②模型训练

```
# 模型训练  
history = model.fit (X_train_norm, y_train, validation_split=0.2, epochs=10, batch_size=32,  
verbose=1)
```

通过fit 方法使用训练数据集对模型进行训练。前2个参数是训练集的特征集和标签集。 epochs 指定需要执行的训练周期数(迭代次数),默认为1。 batch_size 指定每批次的数据数目, 默认为32。 verbose 指定显示日志的模式, 0表示不输出日志信息, 1表示输出包含进度 条的日志信息, 2表示每个训练周期(epoch) 输出一条信息, 默认为1。 validation_split 则指 定训练样本用于验证数据集的比例, 取值范围为0 ~ 1。这里0.2表示取20%的数据集作为 验证集。验证集中的数据将不参与训练模型, 而是用于验证训练后的模型, 以增强其泛化 能力。



任务实施--实施方案

(2)实施步骤

2)模型训练和测试。

③模型评估

```
# 模型评估  
score = model.evaluate (X_test_norm, y_test, verbose=1)  
print ('Test loss:', score[0])  
print ('Test accuracy:', score[1])
```

可用evaluate 方法查看模型的效果，该方法返回损失值(预测值和实际值之间的差距) 和准确率。注意这里evaluate 方法参数用的是测试集。



任务实施--实施方案

(2)实施步骤

3)模型应用。

③模型评估

假设前面已得到分隔后单个字符的图像，且所有字符图像的尺寸已统一调整为 28×28 像素，构成测试集数据(X_newdata)。接着采用跟训练集相同的方法进行预处理和规格化，再用模型的predict_classes方法，对规格化后的数据进行预测，预测的结果识别字符的类型（36种字符中的一种）。

```
# 利用 reshape 函数转换数字图像
```

```
X_newdata_reshape = X_newdata.reshape (X_newdata.shape[0], 28, 28, 1)
```

```
# 对数字图像进行归一化
```

```
X_test_new = X_newdata_reshape / 255.0
```

```
# 模型预测
```

```
prediction=model.predict_classes (X_test_new)
```

这里X_newdata为需识别的测试集(只含属性集),最后的预测结果为标签集，即测试集中字符图片的识别结果(字符的编号)。



单元总结

从上面的例子可以看出，自行设计一个即使是较简单的AI模型也不是一件容易的事，需要有人工智能和编程方面的专业知识。后面的学习单元将主要以使用已有的模型为主进行介绍。





案例拓展

前面是用开源的TensorFlow 框架自行编写代码来创建模型。这需要掌握相当的AI领域的专业知识和一定的编程技巧。对于缺乏相应技能的普通用户，已有一些支持AI 开发的云 平台可供使用，这些平台向用户隐藏了模型和复杂的操作，提供给用户是一个简单的操作接 口，基本可以零门槛操作。典型的如百度飞桨EasyDL开发平台(<https://ai.baidu.com/easydl>)、阿里云AI平台(<https://ai.aliyun.com/index>) 和华为云(以华为ModelArts 为核心)([https://www huaweicloud.com/](https://www.huaweicloud.com/))。以 EasyDL 开发平台为例，官网首页有一栏 “EasyDLOCR”，可以使用平 台内 置 的OCR 技术来识别图片中的文字信息。

这些AI开发平台通常已将模型内置，即平台已将模型训练好，其结构对用户是透明的。 平台允许用户根据自己的需要从已有模型中进行选择，通常可根据任务类型适当调整参数， 以提高模型的性能。

学习单元2

单一智能产品/系统 的优化



目录

CONTENTS

01

智能系统优化的含义

02

智能系统优化流程

03

任务实施

04

单元总结



智能系统优化的含义

智能系统的优化含义很广，这里主要指设计方案和模型的优化。优化AI模型是机器学习过程中的重要步骤。优化有两种情况：一种是在设计过程中边设计边优化，另一种则是对已有模型进行优化。

如果从无到有建立一个新的AI 模型，涵盖其生命周期的较完整的优化策略一般包括：

- 1.针对需解决的问题选择合适的算法。不同的问题有着不同的数据集，而不同类型的 数据集适合的算法也不相同。
- 2.对数据进行预处理。预处理一方面可保证数据的准确性，另一方面可使其易于后续 处理。通常的预处理手段包括数据清洗、缺失值处理和数据规格化。
- 3.将全体数据分隔为训练集、验证集和测试集。其中，训练集用于训练模型的参 数，验证集用于检验模型的性能，并可以根据检验结果反过来调整模型参数(主要是超参 数，即模型启动学习前输入的配置参数)。测试集则用于检验已经训练好的最终模型的泛化 性能。
- 4.调整模型的超参数。
- 5.使用正则化(regularization) 避免过拟合。正则化是一种技术，通过在损失函数中增 加惩罚项来防止模型变得太复杂。
- 6.使用整合(ensembles) 来改善模型的性能。整合通过组合多个模型的预测能力来产生 一个更准确的预测输出。

对已有AI 模型进行优化则可根据需要选择上述部分步骤。较简单的优化是改善训练数据的质量。前面所设计的AI 模型，需要用大量合乎规范的数据进行训练，如果发现训练后 的模型效果不理想，可以先从改善训练数据入手，如删除不合要求的、低质量的数据，或增 加新的、高质量的数据，或增加迭代次数。复杂一点的优化包括改进或变更模型、算法或处理流程，甚至进行全新的设计。

因为前一学习单元已介绍了AI 模型的设计，这一学习单元主要介绍已有模型的优 化。



智能系统优化流程

设计优化是个系统工程，是一项创造性的劳动。优化一般可遵循从简单到复杂的原则，先考虑比较容易的优化内容，如果优化结果不能令人满意，再考虑比较复杂的优化方案。

通常来说某项对原设计的变更常常会有正、反两方面的影响，例如某项改动提高了模型的识别准确率，但会大大增加时间开销。所以优化时一定要作全面考虑，只有某项变更带来的正面收益明显超过负面损失时，才有必要去做。

对已有模型进行优化的一般步骤有以下三步。

1. 模型评价
2. 数据分析
3. 模型调整



智能系统优化流程

模型评价

用测试数据集对模型进行测试, 查看模型的效果(如准确率、召回率等), 如评价指标的数据不理想, 或明显低于行业均值, 就要考虑对模型进行优化。

数据分析

可以先对训练数据和测试数据进行分析。查看训练数据中是否存在错误或无效的数据 (如标注错误或标注不清楚的数据), 有的话应删除或替换。如训练的样本数太少, 可考虑增加有效的样本数量。测试数据则要检查数据是否正常或合乎规范, 测试数据应与要预测的真实数据规格相同。

模型调整

模型调整可考虑下面两种方法。
(1) 在原来的模型上进行局部改进。
(2) 采用其他类型的网络模型。



智能系统优化流程

模型调整可考虑下面两种方法。

(1)在原来的模型上进行局部改进。

如果模型是卷积神经网络(CNN). 可通过增加网络层数的方法。一般来说, 神经网络层数越多, 对输入特征抽象的层次越深, 对其理解的准确度相对来说也就越高。但层数太多除了计算开销大外, 也容易导致过拟合问题。除了增加卷积层外, 还可增加其他类型的层(如加入池化层, 用来减少网络参数量, 加快计算; 加入dropout层, 随机关闭上一层的一小部分神经元, 防止数据过拟合等)。

其他优化措施还包括调整模型中的各个参数、改变损失函数、激活函数等。

(2)采用其他类型的网络模型。

除了前面提到的卷积神经网络, 新的神经网络模型不断涌现, 如循环神经网络(RNN)、长短期记忆网络(LSTM)、Transformer等, 这些网络模型各有其特长。如CNN较适合图像处理, 而RNN、LSTM则较适合文字和语音处理。

Transformer 是Google团队在2017年提出的一种算法模型, 使用Self-Attention(自注意力)机制, 内部由encoder(编码器)和decoder(解码器)构成, 支持更快的并行计算, 并且在长距离依赖问题上性能更好。Transformer最初应用于NLP(自然语言处理)并取得较好的效果, 后来又逐步推广到其他领域, 目前引起轰动的GPT模型(生成式的预训练模型)就是基于Transformer 的。所以在优化时, 如果在原模型上改进的效果不理想, 可以考虑更换更合适的网络模型。



任务实施--任务背景

前面在票据OCR 系统的设计中，训练的模型只能识别大写英文字母和阿拉伯数字共计 36种字符，但国内日常使用的票据中包含大量的汉字，如果需要识别票据中的汉字，该模 型需要怎么改进？

中文识别与英文识别相比，面临着巨大的挑战。其挑战主要包括以下方面：

(1)汉字字符数量多。

目前国标码收录了6763个汉字，其中一级汉字(最常用) 3755个，二级汉字3008个；而英文只有26个字母。将每个汉字看作一个类别的话，要识 别的汉字种类远远超过了英文字母的种类。

(2)存在着很多形近汉字的组合

数量庞大的汉字字符集中间又存在着很多形近汉字的组合，这些形近汉字之间仅存 在细微的结构差异，容易造成识别出错的结果，例如“乌”和“鸟”、“日”和“曰”等。形近汉字为汉字的识别增加了不小的挑战。

(3)汉字字形复杂度较高

区别于拉丁字母的简单结构，汉字字形复杂度较高，有一些左右结构的汉字容易被 错误识别为两个汉字，如“鹏”字。

综上所述，汉字本身存在数量繁多、部分字形接近的特点。为了较好识别包含汉字的票 据，需要找到合适的算法和模型去解决汉字检测与识别的问题。



任务实施--任务内容

对票据OCR系统的设计进行优化，其核心内容是解决票据中汉字的识别问题。



任务实施--实施环境


(1)硬件设备。计算机一台。

(2)软件配置。Python开发环境、TensorFlow框架、Numpy等模块。



任务实施--实施方案

(1)任务流程。





任务实施--实施方案

(2)模型和框架

1)OCR 第一阶段的任务是文本检测(前例跳过了这个步骤)。文本检测任务是要定位图片中的文本框坐标，对检测图片进行包含文字部分的和不包含文字部分的分类。虽然这可以看作目标检测任务的一个分支，理论上可以使用经典的 Faster R-CNN 目标检测网络来进行文本检测，但是文本目标和普通目标之间存在着一定的差异。首先文本外接矩形框的长宽比一般大于1,而普通目标的检测框长宽比接近1。其次，文本框是没有闭合的边缘的，一般一个文本框中会包含多个文字，文字之间又会存在一定的间隔，这为文本框的定位标注带来了很大的挑战。所以将经典的目标检测算法直接移植到文本检测上效果并不理想。

文本检测已有一些较成熟的模型，其中，CTPN 和 EAST 是近些年新提出的两种得到广大学者认可并被广泛应用于文本检测的算法模型。CTPN是一个深度神经网络，使用多个卷积层，将文本检测任务转化为一连串小尺度文本框的检测，即将文本框拆分，分别去检测小文本框是否为同一文本的一部分，检测完后将同一个文本里的所有小文本框合并得到完整的大文本框；同时引入RNN 利用文本的连续上下文信息对整个序列进行预测来提升文本检测效果；另外还通过边界优化来提升文本框边界预测精准度。EAST则是另一个效果较好的文本检测模型，它对之前流程烦琐的文本检测算法进行简化，只需要两个阶段即可完成：第一个阶段是通过全卷积神经网络直接进行文本框的预测，第二阶段则是对生成的文本预测框进行非极大抑制处理产生最终结果，最终在词粒度和文本行粒度上都可以实现文本框预测。预测的文本框形状可以是常规的水平矩形框或是旋转的文本框。

在 Transformer模型提出以后，一些新的算法如DETR采用Transformer的解码层并行输出结果，输出的检测框更少，且不需要进行非极大抑制处理也可以达到理想的效果。



任务实施--实施方案

(2)模型和框架

2)OCR 第二阶段的任务是文本识别。前例中假设要识别的文字只有大写英文字母和阿拉伯数字，所以用了一个简单的卷积神经网络。但如果要识别汉字，这个模型就过于简单，效果较差，需要引入新的较复杂的模型。

目前主流的文字识别算法均采用基于深度学习的方法，如CRNN 算法，采用卷积神经网络和循环神经网络，并使用CTC函数进行序列特征翻译。CRNN 算法借鉴了语音识别中的解决不定长语音序列的思路，把字符识别问题看作时序依赖的词汇或者短语识别问题。CRNN把卷积神经网络在图像特征提取方面的应用和循环神经网络在序列化识别上的应用有机地结合在一起，既能够提取鲁棒的特征，又通过序列化识别避免了传统算法中的单字符切割与识别。这里的序列化识别是依赖于时序的，识别结果利用了上下文的特征信息。




任务实施--实施方案

(2)模型和框架

2)OCR 第二阶段的任务是文本识别。

如图所示，CRNN 的网络结构分为三部分：
第一部分通过卷积神经网络从输入的图 像中提取出特征，以序列的形式输出；第二部分将特征序列输入循环神经网络，输出这个特 征序列的标签分布；第三部分使用CTC 损失函数，将循环神经网络获取的标签特征分布通 过一系列的 计算操作转换为真实的预测值。

自行创建AI模型是一项高技术含量且复杂、耗时的 工作，一些AI企业通常将自己已经 创建并训练好的模型向外界开放，外界可以通过指定的API接口来调用模型。





任务实施--实施方案

(3)实施步骤。下面以百度飞桨(PaddlePaddle)提供的模型接口为例，用代码来实现票 据 OCR。

1)实施环境准备

硬件设备：计算机一台。

软件配置：Python开发环境、TensorFlow框架、Numpy等模块。 其他还需安装PaddlePaddle开发包。

小贴士

PaddlePaddle 开发包安装步骤

1. 确认计算机中已安装Anaconda软件，如未安装，先安装该软件。
2. 以管理员身份运行 “Anaconda Prompt” 。
3. 在命令行窗口运行下列命令，安装PaddlePaddle 开发包。

```
pip install paddlepaddle
```

如果网络超时，可以通过如下命令修改为国内的安装源，然后执行前述批处理命令。

```
pip config set global.index-url https://pypi.tuna.tsinghua.edu.cn/simple
```

4. 再运行以下命令，安装 paddlehub 模块。

```
pip install paddlehub
```



任务实施--实施方案

(3)实施步骤。

2)代码实现。PaddlePaddle开发包安装成功后启动Jupyter Notebook,输入下列代码运行。

```
# 导入依赖项
import paddlehub as hub # 导入飞桨开发包 paddlehub
import cv2 # 导入 OpenCV2 计算机视觉库
from operator import itemgetter

# ----- 可更改测试数据 ----- #
img_path = 'd:\\test\\sample1.png' # 指定图像文件的路径，可以是单张图片，也可以是图
片数据集
img_path_list = [img_path]
# 指定识别 OCR 图片文件的保存路径（可变更）
output_path = 'd:\\test\\tmp'
# 读取测试文件夹中的图片路径
np_images = [cv2.imread(img_path)] # 读入图片转为 3 维数组
```

```
# 加载预训练模型
ocr = hub.Module(name='chinese_ocr_db_crnn_server')
# 进行 OCR 识别
ocr_results = ocr.recognize_text (
    images=np_images, # 图片数据，为该图片对应的 3 维数组
    use_gpu=False, # 是否使用图形处理单元 (GPU); False 表示未使用; 若使用 GPU,
    请先设置 CUDA_VISIBLE_DEVICES 环境变量
    output_dir=output_path, # 识别结果图片文件的保存路径
    visualization=True, # 是否将识别结果保存为图片文件
    box_thresh=0.0001, # 检测文本框置信度的阈值，越小识别的内容越多，但也更可能
    识别出不相关的内容，不可设置为 0
    text_thresh=0.5) # 识别中文文本置信度的阈值，是指将内容识别为中文字符的阈值参
数，由于也需要对英文和数字进行识别，该值不宜过小
```



任务实施--实施方案

(3)实施步骤。

2)代码实现。PaddlePaddle开发包安装成功后启动Jupyter Notebook,输入下列代码运行。

```
# 这里得到的 ocr_results 是一个由字典构成的列表，每个字典对应一幅图片的信息。键
# 包括 'save_path' 和 'data'。'data' 键对应的值则包括所有识别出来的文本信息（列表类型），
# 每个文本对应其中的一项（字典类型），包括文本内容（text）、文本框位置（text_box_
# position）、置信度（confidence）
# 过滤识别结果
data = ocr_results[0]['data'] # ocr_results[0] 对应第一个图片对应的字典，此例仅放了一张
# 图片。'data' 键对应的值则包括识别出来所有文本信息
data.sort (key=itemgetter ('confidence'), reverse=True) # 按照置信度对所有识别出来的文本
# 进行排序，置信度高的排在前面
for information in data: # 遍历全部识别结果、置信度（即识别结果正确的可能性）、识别框
# 的位置（四个角点的坐标）
    print (information)
```



任务实施--实施方案

(3)实施步骤。

3)结果输出。代码将输出图片的识别结果信息(支持中文),如图所示。

安徽省政府 财政厅 安徽省财政厅 票据 (电子)

票据代码: 34010120
票据金额: 0800000101
付款人: 中煤新集能源股份有限公司
收款人: 中煤新集能源股份有限公司
开票日期: 2020-09-01

项目编码	项目名称	单位	数量	税率	金额 (元)	备注
10714050 2	矿业权占用费收入 (分派)	元	1		43,500.00	

金额合计 (大写): 肆万叁仟伍佰元整 (小写): 43,500.00

票据号码: 34120020000160598656

收款单位 (章): 阜阳市自然资源和规划局 收款人: 01501

安徽省政府 财政厅 安徽省财政厅 票据 (电子)

票据代码: 34010120
票据金额: 0800000101
付款人: 中煤新集能源股份有限公司
收款人: 中煤新集能源股份有限公司
开票日期: 2020-09-01

项目编码	项目名称	单位	数量	税率	金额 (元)	备注
10714050 2	矿业权占用费收入 (分派)	元	1		43,500.00	

金额合计 (大写): 肆万叁仟伍佰元整 (小写): 43,500.00

票据号码: 34120020000160598656

收款单位 (章): 阜阳市自然资源和规划局 收款人: 01501

a) b)



任务实施--实施方案

(3)实施步骤。

3)结果输出。代码将输出图片的识别结果信息(支持中文),如图所示。

1: 安徽省 0.969
2: 票据代码: 34010120 0.996
3: 票据号码: 0800000101 0.990
4: 交款人统一社会信用代码: 0.983
5: 校验码: 0.899
6: 45bb6c 0.972
7: 交款人: 中煤新集能源股份有限公司 0.958
8: 开票日期: 2020-09-07 0.999
9: 项目编码 0.912
10: 项目名称 0.989
11: 单位 0.999
12: 数量 0.999
13: 标准 1.000
14: 金额(元) 0.989

15: 各注 0.896
16: 元 1.000
17: 10714050矿业权占用费收入(分成) 0.958
18: 43.500.00 0.980
19: 金额合计(大写)肆万叁仟伍佰元整 0.994
20: (小写)43.500.00 0.993
21: 缴款识别码: 34120020000160598656 0.996
22: 然资 0.994
23: 白 0.568
24: 市 0.999
25: 阜阳市自然 0.998
26: 资源和规划局 0.996
27: 复核人: 0.992
28: 收款单位 0.999

29: 收款人: 07501 0.999



任务实施--实施方案

(3)实施步骤。

3)结果输出。程序的输出(部分):

```
{'text': '元', 'confidence': 0.9999363422393799, 'text_box_position': [[306, 149], [323, 149],  
[323, 166], [306, 166]]}  
{'text': '标准', 'confidence': 0.9996994733810425, 'text_box_position': [[416, 129], [442, 129], [442,  
144], [416, 144]]}  
{'text': '收款人: 07501', 'confidence': 0.9993292689323425, 'text_box_position': [[531, 441], [600,  
440], [600, 455], [531, 456]]}  
{'text': '开票日期: 2020-09-07', 'confidence': 0.9990979433059692, 'text_box_position': [[453,  
106], [572, 104], [572, 122], [453, 124]]}  
{'text': '收款单位', 'confidence': 0.9990181922912598, 'text_box_position': [[47, 443], [91, 441],  
[91, 455], [47, 457]]}  
{'text': '单位', 'confidence': 0.9987016916275024, 'text_box_position': [[305, 129], [327, 129], [327,  
145], [305, 145]]}  
...
```



任务实施--实施方案

另一种文本识别算法的思路是在卷积循环神经网络提取特征的基础上引入加入注意力机制的编解码模型，典型的如Attention-OCR 算法。该算法的核心思想是使用编码-解码模型并加入注意力机制来实现特征对齐。所谓的注意力，可以理解作为一种权重或矩阵，对于一个词根据其上下文的关系赋予不同的权重，然后使用该权重向量来表示这个词。注意力机制的优点是可以获得较长的依赖，捕获局部与全局的关系，并且每一步的计算都是独立的，可以实现并行加速。Attention-OCR算法不需要标注文本框的位置，适应文字排版分布不均匀的情况，但是由于循环神经网络记忆功能有限，该算法更适合短文本的识别。



单元总结



人机交互流程设计



学习单元1

人工和智能交互方式



目录

CONTENTS

01

学习情景

02

交互式人工智能系统

03

智能客服机器人

04

任务实施

05

单元总结



学习情景

当前，伴随着数字化、智能化的浪潮，客户交互与服务的形态和内涵有了深刻的改变，以规模化、精准化、多通路化、智能化和普适化为特征的“新客服”应运而生。随着人工智能技术的介入，人工与智能服务共协同、多形态和多方式大融合，深刻改变着客户交互与服务的介质、效率和体验，与客户互动的人机耦合方式将会是未来很长一个阶段的客服运营常态。

人工与智能系统之间存在多种交互方式，如可以借助计算机、手机、平板等智能终端上的软件或应用以文字方式进行交互，也可以使用语音、视觉、触屏等其他交互方式。在设计智能产品或系统时，需通过周密的调查、研究和分析，选出最合适的交互方式。



交互式人工智能系统

交互式人工智能(conversational AI, CoAI)是指通过对话、交互体现出来的智能行为。通常智能系统通过与用户或环境进行交互,并在交互中实现学习与建模。

人工与智能系统有文字、语音、视觉、触屏、脑机接口等多种交互方式。其中视觉交互包括人脸识别、手势识别、表情识别、姿态识别等以图像识别为特征的交互方式。脑机接口则指在人或动物大脑与外部设备之间创建的直接连接以实现脑与设备的信息交换。脑机接口的信号直接来自中枢神经系统,允许计算机接受脑传来的命令或实现脑和外部设备间的双向信息交换,常用于辅助、增强、修复人体的感觉-运动功能或提升人机交互能力。这些不同的交互类型,实际对应的是智能系统不同类型的输入、输出接口。一个智能产品可以有一种或多种这样的接口,如手机包含文字、语音、视觉、触屏等交互方式。设计智能产品或系统时,需要通过细致的调研和分析,找到人工和智能系统交互的最优的方式。

交互式人工智能系统不仅仅以自然语言为载体,而是能综合应用图像、语音等多媒体信息,使机器能够适应自身所处的环境,表现出符合情境的智能行为。



交互式人工智能系统

交互式人工智能系统从应用领域来看，主要有以下三类。

(1) 泛问答系统

泛问答系统通常包括自动问答、阅读理解等，其目的是从结构化存储内容(如数据库、表格等)和非结构化存储内容(如文件形式的文档)中寻找精确答案来回 答用户提问，这属于单轮次的对话系统。

(2) 任务或目标型的对话系统

这种对话系统需要通过多轮交互实现一个特定的任务或 目标，如各种智能助理、订票、订餐系统等。

(3) 开放领域的闲聊系统

如近来引起广泛关注的ChatGPT(全名: chat generative pre- trained transformer),是美国OpenAI公司研发的聊天机器人程序，于2022年11月30日发布。它采用深度学习技术，能够通过学习和理解人类的语言来进行对话，还能根据聊天的上 下文进行互动，真正像人类一样来聊天交流，甚至能完成撰写邮件、视频脚本、文案、代 码、论文以及翻译等任务。

从技术上看，人机交互是人工智能最具挑战性、最综合性的技术之一，涵盖了语义理 解、知识表示、语言生成、逻辑与推理等各个方面。



智能客服机器人

人工与智能系统交互有多种方式，智能客服机器人就是其中一种典型的应用。随着移动互联网的普及和消费升级，用户数量激增，传统服务体系的人海战术已经很难满足现今数量庞大的用户需求。人工智能技术中，包括自然语言处理、数据挖掘、语音识别、图像识别、机器学习等在内的感知及认知智能技术的高度成熟，为语音和文本交互方式带来全新的改变。传统服务前端的人工客服，已经逐渐被智能语音门户和智能客服机器人所代替。智能客服机器人能通过识别理解用户意图，将用户的需求进行合理分类、传递，从知识库中寻求答案，或者直接回答用户问题，或者辅助人工客服智能应答。使用智能客服机器人不仅能倍增效率，更能提升用户的体验。

智能客服机器人引进的目的是降低运营人力成本，分担人工客服咨询流量。当用户在线咨询时，简单重复的问题由智能客服机器人回答，对于复杂的、机器人难以胜任的用户需求，则引导至人工服务。这将人工客服从单一、重复的机械工作中解放出来，使他们能去做更多有价值的工作。



任务实施--任务内容

案例：某校园招聘会邀约机器人设计(交互方式)

某学校打算近期举办一场校园招聘会。学校虽然人手、经费有限，但招聘机会难得，希望能通知到尽可能多的学生，并及时、准确地答复学生的问题，因此，学校准备开发一个校园招聘会的邀约机器人来完成这个任务。

邀约机器人的工作内容主要是：通过电话或App回答学生的提问，如招聘会的时间、地点、参会公司的情况等；如遇学生当天时间有冲突，能根据情况安排其他场次进行邀约等；如遇无法解答的问题或用户主动要求，则转人工服务。

下面将任务内容分为两部分。本学习单元先设计用户与邀约机器人的交互方式，下一学习单元再介绍交互过程的实现。





任务实施--任务分析

要设计一个校园招聘会邀约机器人，首先必须考虑该机器人与用户的交互方式。本案例中机器人与用户的交互方式有两种：语音和文字。一般打电话咨询的，是语音方式；通过在App中输入文字进行交互的，是文字方式。



任务实施--交互流程

邀约机器人与用户的交互流程可设计如下。


1)**用户输入**。用户通过在App中输入文字或电话语音的方式将提问信息传递到邀约机器人的用户界面。如果是语音方式，需有一个语音识别模块将用户的语音转化为文字。

2)**机器人处理和回复**。当邀约机器人收到用户提出的问题后，通过自然语言处理技术和算法模型理解用户表达的含义，然后从知识库中找出与该问题匹配的答案并将其发送给用户。如果该问题找不到合适的答案或用户主动要求，则转人工服务。

3)**性能优化和提示**。完成这一轮问答互动后，机器人通过自主学习技术对问答过程进行深入学习，自动扩展知识库内容，提高下一次回答的准确性。



单元总结



学习单元2

人工和智能交互过程 的实现



目录

CONTENTS

01

学习情景

02

背景知识

03

任务实施

04

单元总结

人工与智能系统之间的交互方式不同，交互流程也会有所差异。以智能客服机器人为例，如果交互方式单纯为文字，其交互流程一般包括用户文字输入、AI 语义理解、知识库检索、回答生成并返回用户、服务完成后机器人自我学习和完善等几个阶段。如果交互方式还包括语音，则在用户语音提问后需增加语音识别环节，识别完成后再进行语义理解，另外，在机器人回答生成后还需有一个语音合成的环节，最后返回给用户的是合成的语音信息。



背景知识

智能客服机器人的原理是提前准备大量与客服信息相关的问答，建立机器人知识库，当客服机器人收到用户提出的问题后，通过自然语言处理技术和算法模型理解用户表达的含义，然后在知识库中找出与该问题匹配的答案并将其发送给用户。因此，智能客服机器人的工作原理主要包括四个部分：知识库构建、语义理解、问答匹配和机器人深度学习。



背景知识--知识库构建

收集问答和建立知识库是实现智能客服的基础。知识库中存储的问答信息越多，涉及的知识越广泛，客服机器人能回答的问题越多，用户问题的解决率就越高。

智能客服机器人知识库的问答集可以手动添加或批量导入。无论哪种方式，一般都需要扩展标准问题的相似性问法。一般来说，标准问题需要增加几十个类似的句子，客服机器人 才可以正常使用，如图所示。

我还要多少钱^A88	余额还有多少。^A265
话费还有多少啊^A91	有多少钱^A1729
我还余多少钱^A31	朕还有多少钱^A207
余额有多少钱^A120	话费还有多少?^A4371
还有多少费^A131	我钱还有多少^A35
套餐还有多少^A141	.还有多少钱^A28
还有多少钱^A60909	卡上还有多少钱^A208
余额还有多少^A11767	请问我还有多少钱^A330
我还多少钱^A883	还有多钱^A185
我还有多少元^A153	我的话费还有多少.^A23
现在还有多少^A103	还有多少钱阿^A19
余额还有多少啊^A30	我还有多少话^A28
还有多少话^A32	余款还有多少?^A18






背景知识--语义理解

在智能客服机器人出现之前，客户服务系统中经常有一个叫作“自动回复”的功能。它的原理是使用关键词匹配来回答，然而，同一个关键词在不同句子中的含义可能完全不同，这可能会导致出现答非所问的情况。这种方式下回答的准确性自然较低且不够智能。

智能客服机器人采用自然语言处理技术和深度神经网络算法模型，通过分析整个句子的结构和上下文内容信息来理解句子表达的真实意思，如图所示。

语义理解部分包括自然语言理解、语义分析和结果处理三个步骤。其中的技术要点包括：过滤和纠错(非法词、停用词、前后缀过滤及英文纠错),词法分析(分词、词性标注、实体识别),上下文处理(上下文替换、自动推理、上下文反问),知识点匹配(模板匹配和相似度计算)。





背景知识--问答匹配

在智能客服机器人正确理解用户提出的问题后，下一步操作是从构建的知识库中选择最匹配的问题和答案。

传统的LIKE 语言查询准确率低，不适合自然语言查询。现在一般使用全文搜索引擎扫描问答数据库中的每条记录，并对单词进行划分以创建索引。索引记录一个单词在每个问答记录中出现的位置和次数。

机器人系统收到用户的问题后，会使用检索、匹配技术在知识库中寻找相应问题的答案。如计算用户的问题与知识库中保存的问答记录之间的相似性，选择相似性最高的答案进行回答。



背景知识--自主深度学习

以强化学习为代表的深度学习技术出现后，智能客服机器人能够通过与用户互动和互联网数据挖掘自动进行学习，不断积累新知识，完善知识库。随着时间的推移，智能客服机器人将变得越来越强大和智能，回答的准确性也会越来越高。目前在传统的售前咨询和售后服务中，智能客服机器人已经能够帮助人工客服处理大多数常规问题。



任务实施--任务内容

案例：某校园招聘会邀约机器人设计(交互过程实现)

前一学习单元已经对校园招聘会邀约机器人的交互方式作了介绍。本学习单元的任务则是实现具体的交互过程。





任务实施--系统构成

完整的邀约机器人系统一般由以下几个模块构成：**语音识别、自然语言理解、对话管理、回答语音合成**四部分组成。其中，语音识别和回答语音合成仅在交互方式为语音时才需要。

(1)语音识别。语音识别模块自行设计颇为复杂，需要熟悉和掌握许多模型和框架，如常见的语言模型[N-gram(N元模型)、RNN(循环神经网络)等]、声学模型及主流语音识别框架[HMM-GMM(隐马尔科夫-高斯混合模型)、ASRT(自动语音识别工具)等]、LSTM(长短期记忆网络)、CNN(卷积神经网络)、Transformer等。有降噪等其他要求的，还需熟悉抑制、降低噪声干扰的降噪技术及语音增强技术，包括传统单通道语音增强技术和麦克风阵列语音增强技术。目前已有成熟的、已训练好的相关模型可供使用。

(2)自然语言理解。这一步就是要理解用户提问信息的含义。对于用户的提问，首先必须进行分词处理，将非结构化的用户提问分成一个个词语，并对每个词语赋予权重，然后结合用户的基本信息和行为信息，构成用户提问向量，从而获取用户提问标签。知识库中的问题也用同样的方法设置标签。最后将用户提问标签与知识库中的问题标签进行对比，从而确定如何答复用户。

用户的提问和知识库问题都属于非结构化数据，一般用向量空间模型(vector space model,VSM)将非结构化的问题结构化。通常可用词频-逆文档频率(term frequency-inverse document frequency,TF-IDF)算法将非结构化的用户提问和知识库问题用结构化的向量表示出来。

(3)对话管理。用户提出问题时，系统通过检索、匹配技术从知识库中找出答案来进行回复。因此，知识库的质量对答复的有效性和准确性有很大的影响。然而，知识库规模再大，质量再好，也不可能实现持续性完美答复，因为对话的场景日新月异，人们的表达方式也随着时间不断变化，这些变化都需要对知识库进行更新和补充。近年来，深度学习方法在自然语言、语音、图像、视频等领域发展迅猛。使用图神经网络构建推荐算法逐渐成为当今推荐算法的研究热潮。这个方法恰好可以解决客服机器人自动更新和扩充知识库的需求。

(4)回答语音合成。如果交互方式是语音，则最后一步是将生成的回答合成语音后反馈给用户；如果交互方式是文本则不需要这一步。



任务实施--交互过程实现

(1)**设计或选择算法模型**。智能客服机器人的功能是接收文字输入，反馈能与输入文字匹配的答案或回答。如果交互方式是语音，则先通过前面的语音识别模块将用户的问题或咨询转换为文字。智能客服机器人算法模型的设计是一项高深的、复杂的工作，如ChatGPT聊天机器人的模型就用到了Transformer网络并用海量的数据对网络进行训练；国内大多数智能客服机器人一般采用知识库的方式(如淘宝客服机器人),回答用户问题时通常都从知识库中寻求答案。



任务实施--交互过程实现

(2)**知识库配置**。使用知识库的智能客服机器人，对用户输入的文字进行解析和理解后，会从知识库中寻求答案或回答，因此知识库的配置十分重要。

智能客服机器人的知识库通常由三层架构组成，如图所示，具体分为专属知识库、领域知识库和通用知识库三部分。通常后两部分由客服机器人的生产厂家构建并提供，而专属知识库则由产品用户根据业务内容自行搭建。搭建专属知识库一般也属于人工智能训练师的工作内容。





任务实施--交互过程实现

如设计校园招聘会邀约机器人时，可在专属知识库中可添加条目。

知识库条目	问题描述	回答
1	询问是不是机器人	你真聪明，我是校招智能助手
2	询问其他招聘场次	这样吧，我把您的情况记录下来反馈给同事，让他帮您看下有没有合适的场次。 请关注校园招聘网站

这里的问题描述是一个语义上的描述，在实际的知识库中，一般都需要扩展标准问题的相似性问题并存放知识库。如第一条询问是不是机器人，可以设置多条表达同一含义的不同问法，如“你是机器人吗”“你是谁”“你是哪位”“你是智能客服吗”“你不是真人吧”“你是人工客服吗”“Who are you”“Are you a robot”等。第二条也是如此。一般来说，标准问题需要扩展多个类似的句子，机器人才可以正常使用。

收集问答和建立知识库是实现智能客服机器人应用的基础。知识库中存储的问答信息越多，涉及的知识越广泛，客服机器人能回答的问题越多，用户问题的解决率就越高。。



任务实施--交互过程实现

客服机器人给出准确答案的过程主要包括三个步骤。

第一步，数据采集。数据采集包括用户基本信息、用户行为信息、用户提问信息以及常见用户历史问题及对应回复信息等。第二步，数据处理。数据处理主要是进行用户提问标签提取。首先，对用户当前提问进行分词处理，抽取出可以代表其含义的属性词，用具体的词向量来表示用户的抽象提问，每个词对应的权重由信息检索算法TF-IDF来决定，然后利用客户购物、浏览、咨询及评价等历史信息特征数据，以及用户的年龄、性别、地域等来分析出此用户的提问特征，最终提取出用户提问标签。第三步，答复推荐。通过对比用户提问标签和知识库中问题标签，为用户推荐相关性最大的回复信息。




任务实施--交互过程实现

(3)系统优化。如果用户的问题在各层级知识库中均未找到匹配，则转人工处理。“转 人工”和“未解决榜”里的问题及解答，后面可添加到自定义知识库，使机器人的知识不断拓展。



单元总结



谢谢大家

