

人工智能训练师 理论知识点讲解02

深圳市南山区华必达学校

2024-10



目录

CATALOGUE

- 人脸识别
- OpenCV数据采集
- 车辆数据采集
- 街景数据采集
- 语音数据采集
- 文本数据采集
- 网络数据采集

目录

CATALOGUE

- 常见的数据采集设备
- 数据不完整与数据格式错误的原因及解决方案
- MySQL 数据库
- 中位数、众数、均值
- 数据标注与人工智能的相互促进关系
- 对语音标注、图像标注和文本标注的解释
- 分类标注等
- 数据标注的主要应用领域

目录

CATALOGUE

- 语音标注的主要应用领域
- 文本标注的主要应用类型
- 自动驾驶

01

人脸识别

深圳市南山區必达培训学校


人脸识别

人脸识别技术

人脸识别是一种生物识别技术，通过分析和比对人脸特征进行身份识别或验证。

影响因素

采集人脸数据时，光照条件、遮挡物、拍摄角度和表情变化等因素可能影响数据质量和准确性。



02

OpenCV数据采集

OpenCV数据采集

归一化例如，有一组学生的考试成绩，分别是 60 分、75 分、80 分、90 分、45 分。如果进行归一化到 0 到 1 的范围，可以先找出最高分 90 分和最低分 45 分。然后对于每个成绩，用 $(\text{成绩} - \text{最低分}) / (\text{最高分} - \text{最低分})$ 来计算归一化后的值。比如 60 分归一化后就是 $(60 - 45) / (90 - 45) = 0.33$ 。这样就把所有成绩都归一化到了 0 到 1 之间，方便进行比较和分析。



OpenCV 检测人脸信息

使用 OpenCV 技术可检测并采集人脸数据，为后续分析提供基础。

数据预处理

采集到的数据进行**清洗、归一化**等处理，提高数据质量和分析准确性。

特征提取

从人脸数据中提取具有代表性和区分性的特征，如眼睛、鼻子、嘴巴等部位的形状和位置特征。

OpenCV数据采集

数据加密

对采集到的数据进行**加密**处理，
以保护用户隐私和数据安全。

数据存储管理

在**数据库**中合理地组织和存储人脸数据，便于后续的查询、更新和分析。

数据传输

将处理后的数据安全、稳定地传输到数据库中，确保数据完整性和传输效率。

合规性检查

确保整个采集和存储过程符合相关的法律法规和隐私政策，**保障**
用户权益。



03

车辆数据采集

车辆数据采集



车辆数据采集内容

车辆数据采集通常包括车辆基本信息（车型、车辆颜色等）、行驶数据、位置信息、能耗数据、故障和维修记录，以及传感器数据。

车辆传感器数据

车辆传感器数据包括轮胎压力、油温、水温等，这些数据可以提供关于车辆状况的更多信息，有助于及时发现潜在问题。

04

街景数据采集

街景数据采集的常用工具

01

车载全景相机

能够拍摄**360度**的街景图像，为城市规划、交通监控等提供全方位的视觉信息。

02


高精度GPS设备

用于**定位**拍摄位置，确保图像的准确地理信息，为后续分析提供有力支持。

03

激光雷达

用于获取三维空间信息，能够扫描周围环境，生成**点云数据**，为后续建模提供基础。



可能导致街景数据采集质量不高的原因

- 01 天气条件不佳**：在阴天、雨天或雾天等天气条件下，图像清晰度和色彩会受到影响，导致数据质量下降。
- 02 采集设备的精度和性能不足**：如果相机分辨率低或GPS定位不准确，会影响图像质量和地理信息准确性。
- 03 采集路线规划不合理**：如果采集路线规划不合理，可能导致某些区域重复采集或遗漏，影响数据完整性。
- 04 数据传输和存储过程中的错误或丢失**：在数据传输或存储过程中，可能会出现错误或丢失，导致数据不完整。
- 05 采集时的车速过快**：如果采集时的车速过快，可能会导致图像模糊或数据不完整，影响数据质量。
- 06 外界干扰**：建筑物遮挡、电磁干扰等外界因素可能影响采集设备的正常工作，导致数据质量下降。

05

语音数据采集

语音数据采集



● 语音数据采集技术

语音数据采集技术可用于多种领域，包括语音识别、智能客服、语音合成、医疗和教育等。

● 采集方式

采集语音数据的方式包括专业录音设备、移动设备等，根据需求和场景选择合适的采集方式。

● 语音数据的作用

语音数据在科技、服务、医疗、教育等多个领域都发挥着重要作用，为相关技术和应用的发展提供了基础支持。

06

文本数据采集

文本数据和骨骼识别

自然语言处理

文本分类、情感分析、机器翻译、问答系统等任务涉及对文本内容的标注。

语音处理

语音识别、语音合成、语音情感分析等任务需要对语音数据进行标注。

医疗保健

病历分析等任务对医疗文本进行标注。

金融

风险评估、欺诈检测、客户分类等任务中对金融文本数据进行标注。

骨骼识别

关键点标注，标注出人体骨骼的关键节点位置，为模型提供准确的训练数据。

07

网络数据采集

网络数据采集

网络数据采集原理

网络数据采集利用互联网搜索引擎技术的原理和方法实现数据抓取。



网络爬虫

写网络爬虫来采集网络数据是常见的方式之一。

数据归类

在采集到数据后，按照一定的规则和筛选标准进行数据归类，形成数据库文件。



法律法规与道德规范

在进行网络数据采集时，必须遵守法律法规和相关网站的使用规则，**不得进行非法或未经授权的数据采集。**

08

常见的数据采集设备

常见的数据采集设备

传感器

传感器是一种能够感知并采集物理环境中各种数据的设备，如温度传感器、湿度传感器、压力传感器等。

01

数据采集卡

数据采集卡是一种将模拟信号转换为数字信号的设备，常用于工业控制和测量领域。

02

扫描仪

扫描仪是一种将纸质文档、纸质图片等转换为数字数据的设备，它通过扫描文档或图片，将其转换为计算机可读取的格式。

03

智能仪表

智能仪表是一种能够自动采集和记录相关数据的设备，如智能电表、智能水表等。

04

摄像头

摄像头是一种用于采集图像和视频数据的设备，它通过记录光线投影到图像传感器上的信息，生成图像或视频文件。

05

麦克风

麦克风是一种用于采集声音数据的设备，它通过将声波转换为电信号，实现声音的采集和记录。

06



09

数据不完整与数据格式错误的原因及解决方案

数据不完整与数据格式错误的原因及解决方案



数据不完整的原因

数据不完整可能是由于采集设备故障、传输中断、采集范围设定不当等原因导致。

数据格式错误的原因

数据格式错误可能是由于不同数据源的格式差异、采集过程中的编码错误、数据转换失误等引起。

解决方案

为避免这些问题，需要在采集前做好规划和设置，采集过程中进行监控和校验，采集后进行数据清洗和验证。

数据清洗等

不一致的例子：对于年龄字段，有的记录是以周岁为单位，比如“25”，而有的记录是以虚岁为单位，比如“26”。

01

数据清洗

数据清洗是指发现并纠正数据文件中可识别的错误，包括检查数据一致性，处理无效值和缺失值等，以提高数据质量的过程。

02

抽取数据

抽取数据的工作可以由数据仓库工具来完成，不过具体使用哪种工具取决于数据的来源、格式、规模以及处理需求等多种因素。

03

增量数据获取

对于含有标准时间戳的字段，且应用环境适合表数量较少的情况，适合采用时间戳比较的方式来获取增量数据。

04

数据挖掘第一步

数据挖掘的第一步通常是数据收集，即获取所需的数据集，才能进行进一步的数据分析和挖掘工作。

```
SELECT * FROM orders
WHERE creation_time >
'last_fetch_timestamp';
```

10

MySQL 数据库

在 MySQL 数据库中

01

创建用户：在 MySQL 数据库中，创建用户的命令为 `CREATE USER 'username'@'localhost' IDENTIFIED BY 'password'`。

02

修改用户：修改用户的命令为 `ALTER USER 'username'@'localhost' IDENTIFIED BY 'new_password'`。

03

查看数据库：查看数据库的命令为 `SHOW DATABASES;`。

04

插入数据：插入数据的命令为 `INSERT INTO table_name (column1, column2, column3,...) VALUES (value1, value2, value3,...)`。


05

删除数据：删除数据的命令为 `DELETE FROM table_name WHERE condition`，其中 condition 是指定的删除条件。

11

中位数、众数、均值

中位数、众数、均值等



中位数

把一组数据从小到大或从大到小排序后，位于中间位置的数值。如果数据个数是奇数，中位数就是中间的那个数；如果数据个数是偶数，中位数则是中间两个数的平均值。

众数

在一组数据中出现次数最多的数值。一组数据可能有一个众数，也可能有多个众数，还有可能没有众数。

均值

也称为平均数，是指一组数据中所有数值的总和除以数据的个数。

Z 分数（标准分数）

是一个数值与平均数的差再除以标准差所得的值。Z 分数可以反映一个数据点在数据集中的相对位置。

其计算公式为： $Z = (X - \mu) / \sigma$ ，其中 X 是数据点的值， μ 是平均数， σ 是标准差。

成绩情况如下：

平均分是 80 分，标准差是 10 分。

同学 A 的成绩是 95 分。

那么同学 A 的成绩对应的 Z 分数（标准分数）计算如下：

$$Z = \frac{X - \mu}{\sigma} = \frac{95 - 80}{10} = 1.5$$

这意味着同学 A 的成绩比平均分高出 1.5 个标准差。

又比如同学 B 的成绩是 70 分，计算其 Z 分数为：

$$Z = \frac{70 - 80}{10} = -1$$

这表示同学 B 的成绩比平均分低 1 个标准差。

12

数据标注与人工智能的相互促进关系

数据标注与人工智能的相互促进关系



数据标注促进人工智能发展

数据标注为人工智能发展提供基础和支撑，高质量标注数据有助于模型学习和训练，提高准确性、泛化能力和性能。

人工智能创新数据标注方法

人工智能发展推动数据标注进步，创新标注方法、工具和技术，提高标注效率和质量，优化数据标注过程。

数据标注与人工智能协同进步

数据标注和人工智能相互依赖、共同发展，协同进步将推动人工智能技术在更多领域的应用和突破。

13

对语音标注、图像标注和文本 标注的解释

语音标注



语音标注定义

语音标注是对语音数据进行标记和注释的过程，包括转录语音内容、标记说话人特征等。

语音标注应用

语音标注常用于语音识别、语音合成、情感分析等人工智能应用，帮助模型学习语音模式和特征。




图像标注

图像标注定义

图像标注是指对图像中的各种元素进行标记和描述，包括物体分类、定位和像素级标注等。

图像标注作用

图像标注为计算机视觉模型提供训练数据，使其能够识别、理解 and 处理图像中的信息。



文本标注



文本标注定义

文本标注是对文本数据进行标记和注释的操作，包括文本分类标注、情感标注、命名实体标注等。

文本标注作用

文本标注有助于自然语言处理模型学习语言的结构、语义和语法规则，从而实现文本分类、情感分析等信息抽取任务。



14

标注类型

深圳市南山區必达培训学校

分类标注




01 分类标注定义

分类标注是将数据按照不同的类别进行划分和标记，例如图像中的物体分类和文本中的文章类型分类。




(a) Image classification



(b) Object localization



(c) Semantic segmentation



(d) This work

02 类别体系

分类标注通常是基于预定义类别体系，为每个数据样本分配一个或多个类别标签。

标框标注



标框标注定义

标框标注也称为边界框标注，主要用于图像数据。通过在图像中围绕目标对象绘制矩形框，来标记出对象的位置和范围。



目标检测任务

标框标注常用于目标检测任务，让模型能够识别出图像中特定物体的位置和大小。


区域标注

区域标注


在图像数据中，不仅要标记出目标对象的范围，还要对其内部的区域进行详细的划分和标注。

语义分割任务

在语义分割任务中，需要为图像中的每个像素分配所属的类别标签，从而精确地分割出不同的物体或区域。



锚点标注



锚点标注应用

锚点标注通常用于一些特定的场景，例如在对人体姿态估计、图形变形等任务中，通过标记**关键的锚点**来描述对象的形态或变化。

VS

锚点位置

锚点可以是人体关节点、图形的顶点等关键位置，为人工智能模型的训练提供准确和有价值的信息，有助于模型更好地理解 and 预测对象的形态或变化。

15

数据标注的主要应用领域

数据标注的主要应用领域

计算机视觉

图像和视频中的物体、场景、动作等进行标注，用于自动驾驶、图像识别、视频监控等。

自然语言处理

文本内容进行标注，涉及文本分类、情感分析、机器翻译、问答系统等。

语音处理

语音数据进行标注，包括语音识别、语音合成、语音情感分析等。

医疗保健

医疗图像和文本进行标注，用于医学影像诊断、疾病预测、病历分析等。

金融

金融数据进行标注，用于风险评估、欺诈检测、客户分类等任务。

骨骼识别

关键点标注，标注出人体骨骼的关键节点位置，用于模型学习和理解人体骨骼结构及运动模式。

16

语音标注的主要应用领域

语音标注的主要应用领域

语音识别

使计算机能够理解和转换人类的语音为文字。

智能客服

通过识别用户的语音需求，提供快速准确的回答。

语音助手

如手机、智能家居中的语音控制功能。

音频内容分析

例如对广播、有声读物等的分析和理解。

呼叫中心

对电话通话内容进行自动分析和处理。

17

在客服行业中，文本标注的主要应用类型

在客服行业中，文本标注的主要应用类型



情感标注

判断客户的文本所表达的情绪是积极、消极还是中性。



意图标注

明确客户咨询或投诉的目的和意图。



问题分类标注

将客户的问题归为不同的类别，以便快速分配给相应的处理人员。

18

自动驾驶中的标注

在自动驾驶中，以下类型的标注对于训练感知系统特别重要



目标检测标注

准确标注出道路上的车辆、行人、障碍物等目标的位置和类别。

车道线标注

清晰标记出车道的位置和形状。



语义分割标注

对图像中的道路、建筑物、植被等进行像素级的分类标注。

交通信号标注

标注红绿灯的状态和位置。

THANKS

感谢观看

