

人工智能训练师 理论知识点讲解05

刘老师

2024-10



目录

CONTENTS

- 决策树归纳
- 异质语料库
- 中文分词
- TF-IDF
- 层次聚类分析
- 聚类方法分类
- 逻辑回归是分类模型


目录

CONTENTS



- 数据质量评估
- 软件配置管理
- 问题控制
- 专家系统
- 自主无人系统
- 人机协同系统

01

决策树归纳



决策树归纳



决策树归纳

决策树归纳是构建决策树的过程，决策树是一种类似于流程图的树结构。

决策树作用

决策树从一个根节点开始，通过一系列的分支和节点逐步对数据进行分类或预测。

天气决定出去玩

如果要根据天气情况决定是否出去玩，根节点就是“天气”，然后可能的分支有“晴天”“阴天”“雨天”。

温度影响出去玩

对于“晴天”这个分支，可能进一步有分支，比如“温度高”和“温度低”，每个节点代表一个属性的测试，而分支则表示测试的结果。

决策树归纳

决策树优点

决策树的优点在于它易于理解和解释，可以直观地展示决策的过程。而且它能够处理数值型和分类型的数据。

决策树缺点


决策树也有一些缺点，比如容易过拟合，对噪声数据较为敏感等。

决策树应用广泛


总的来说，决策树是一种简单而有效的数据分类和预测工具，在许多领域都有广泛的应用。

02

异质语料库



异质语料库



异质语料库介绍

异质语料库是最简单的语料收集方法，没有事先规定和选材原则，由多种不同类型、领域、风格、语言变体等组成的语料集合。



异质语料库的优点

异质语料库能够更全面地反映语言的多样性和复杂性，对于一些需要广泛了解语言使用情况的研究和应用具有重要价值。




异质语料库的挑战

由于异质语料库内部的多样性，在处理和析时可能会面临更多的挑战 and 复杂性，需要采用更加先进的技术和方法来处理。

03

中文分词




缺乏天然分隔符

英文单词间隔


英文单词之间通常有空格作为天然分隔，而中文句子中字与字紧密相连，没有明显的分隔标志。

中文词边界确定

由于中文中没有明显的分隔标志，需要通过算法和规则来确定词的边界。



歧义性更复杂




中文歧义现象普遍

中文中存在大量歧义现象，由于中文词汇组合灵活，往往同一个句子有不同的理解方式。

“学生会组织活动”歧义

以“学生会组织活动”为例，它可以理解为“学生会”作为一个整体名词组织活动，也可以理解为“学生”和“会”分别组织活动。

词汇组合灵活



中文词语组合灵活

中文词语的组合方式非常灵活，新的词汇和用法不断涌现，给分词带来了更大的挑战。



词汇变化与分词挑战

随着新的词汇和用法的出现，分词技术需要不断更新和优化，以应对更大的挑战。


未登录词处理困难

命名实体识别

人名、地名、机构名、网络词汇等命名实体，由于缺乏常规词典的匹配，难以通过常规分词方法进行准确识别。

上下文理解

理解上下文对于处理未登录词至关重要，通过构建上下文模型，可以更好地识别和处理未登录词，提高分词的准确率。



语义理解要求高

结合上下文语义

为了更准确地分词，需要结合上下文的语义信息，这对语义的理解和分析要求较高。

理解分析语义

对语义的理解和分析要求较高，需要结合上下文的信息来更准确地分词。



多义字和多音字

中文分词挑战

中文存在一字多义、一字多音的情况，导致分词具有复杂性，为自然语言处理带来挑战。

jieba分词三种模式

结巴分词 (jieba 分词) 提供精确、全和搜索引擎三种模式，适应不同需求。

精确模式

默认模式，通过全词匹配找出所有可能的词语，依据词典频率计算最可能结果。

搜索引擎模式

智能分词，在精确模式基础上对长词再次切分，适用于搜索引擎等场景。

全模式

宽松分词，将文本中所有可能的词语都分出来，速度快但可能冗余，适用于高速场景。



比如对于“中国传统文化源远流长”这句话：

精确模式：('中国','传统','文化','源远流长')


全模式：('中国','国传','传统','统文','文化','源','源远','远流','流长','源远流长')

搜索引擎模式：('中国','传统','文化','源远','源远流长','源','流','长')

在这个例子中，全模式几乎把所有可能的字和组合都分出来了，非常冗余。而搜索引擎模式在精确模式基础上，对“源远流长”这个词做了更细的分割，同时保留了完整的词，更符合搜索引擎中可能的查询需求。

04

TF-IDF



TF-IDF



● TF-IDF方法介绍

TF-IDF是一种在文本处理中常用的方法，用于评估一个词在一篇文章中的重要性。

● 词频 (TF) 介绍

词频 (TF, Term Frequency) 指的是一个词在某一篇文章中出现的次数，是评估词在文章中重要性的一种指标。比如说，“苹果”这个词在一篇文章里出现了 5 次，那它在这篇文章中的词频就比较高。

● 逆文档频率 (IDF) 介绍

逆文档频率 (IDF, Inverse Document Frequency) 衡量的是一个词在整个文档集中的普遍程度，是评估词在文档集中重要性的一种指标。

如果一个词在很多文章里都出现，那它就不那么重要；如果一个词只在少数文章里出现，它就比较重要。

TF-IDF




TF-IDF的优点

TF-IDF方法结合了词频和逆文档频率两个指标，用于评估一个词在一篇文章中的重要性。



词的语义关系

TF-IDF方法没有考虑词的语义关系，只是基于词的出现频率和文档分布来计算重要性。



短文本效果不佳

TF-IDF方法对短文本效果不佳，因为短文本中词的出现次数少，导致计算的TF-IDF值可能不准确和缺乏代表性。

TF-IDF

位置因素影响

TF-IDF方法没有考虑特征词的位置因素对文本的区分度，生僻词常会被认为是文档的关键词。

特征项的分布情况

TF-IDF方法忽略了特征项在一个类别中不同类别间的分布情况，是该方法的一个局限。


新词处理不佳

TF-IDF方法对于新出现的词处理不好，新的流行词或者特定领域新出现的术语可能会被低估其重要性。



05

层次聚类分析



层次聚类分析

01

全联动距离定义

在层次聚类分析中，全联动（Complete Linkage）的距离指的是两个聚类簇之间的距离，定义为两个簇中距离最远的两个点之间的距离。

02

全联动距离考量

全联动距离在计算两个簇的距离时，考虑的是两个簇中相距最远的那一对点，相当于把两个簇中所有点的最大距离都考虑进去了。

03

单联动距离定义

单联动（Single Linkage）距离指的是两个聚类簇之间的距离，定义为两个簇中距离最近的两个点之间的距离。


04

平均联动距离定义

平均联动（Average Linkage）距离则是计算两个聚类簇中所有点对之间的距离的平均值作为两个簇之间的距离。

06

聚类方法分类



聚类方法分类

01

聚类方法

聚类方法是数据挖掘和机器学习领域中一种重要的无监督学习方法，主要包括基于层次的、基于划分的、基于密度的、基于网格的和基于模型的等。

02

层次聚类

基于层次的聚类方法又有凝聚型层次聚类和分裂型层次聚类两种类型，凝聚型层次聚类从每个数据点作为一个单独的簇开始，然后逐步将距离较近的簇合并。分裂型层次聚类则从包含所有数据点的一个簇开始，逐步将其分裂为更小的簇，直到每个簇只包含一个数据点或者满足其他终止条件。DIANA (Divisive Analysis) 是一种分裂型的层次聚类算法。

03

划分聚类

基于划分的聚类方法常见的算法有 K-Means 算法、K-Medoids 算法等，K-Means 算法是先随机选择 K 个点作为初始聚类中心，然后进行数据点的分配和中心计算。



聚类方法分类

密度聚类

基于密度的聚类方法，比较典型的是 DBSCAN 算法，它能发现任意形状的聚类，将密度足够大的区域划分为簇，并能有效处理噪声点。OPTICS (Ordering Points To Identify the Clustering Structure) 是为解决 DBSCAN 算法对参数敏感的问题而提出的，它为聚类分析生成一个基于密度的聚类顺序。DENCLUE (Density-Based Clustering) 是一种基于密度分布函数的聚类算法。

网格聚类


基于网格的聚类方法，如 STING 算法，将空间量化为有限数目的单元，基于这些单元进行聚类分析，有效地降低了聚类问题的复杂性。

模型聚类

基于模型的聚类方法常见的有 Gaussian 混合模型 (GMM) 聚类等，它假设数据是由多个高斯分布混合而成，通过最大似然估计等方法进行参数估计和模型训练。

07

逻辑回归是分类模型



逻辑回归是分类模型

逻辑回归的判断依据

逻辑回归会赋予每个特征一个“重要程度”（权重），然后综合这些特征和权重来计算分数。

逻辑回归的作用

逻辑回归就像一个聪明的裁判，能够根据水果的特征判断出水果的种类。

逻辑回归的转化过程

逻辑回归会将计算出的分数转化为一个介于 0 到 1 之间的数字，帮助我们判断事物的类别。

逻辑回归的预测能力

如果数字接近 0，那就很可能是香蕉，如果接近 1，那就很可能是苹果。


逻辑回归的应用范围

逻辑回归通过分析各种特征，来帮助我们事物分成不同的类别。



08

数据质量评估



数据质量评估

准确性

01

指数据是否正确反映了所描述的对象或事件，例如年龄的数值应该是真实且准确的。

02

完整性

意味着数据是否涵盖了应有的全部信息，没有缺失关键的部分，例如客户信息表不能缺少客户的重要联系信息。

一致性

03

主要是指数据在不同的地方或系统中是否保持一致，例如同一个客户在不同的数据库表中的信息应该是相同的。

04


可用性

关注数据是否易于理解、使用和获取，数据应该以清晰、易懂的格式呈现，并且能够被相关人员方便地访问和操作。



09

软件配置管理



软件配置管理



软件配置项定义

软件配置项包括需求文档、设计文档、源代码、测试用例等，是软件开发过程中的重要资产。

软件配置管理目的

软件配置管理旨在确保软件产品在整个生命周期中的完整性、一致性和可追溯性，提高开发效率和软件质量。

软件配置管理活动


软件配置管理包括标识和定义配置项，通过版本控制变更，追踪变更记录，建立配置管理库存储不同版本。

软件配置管理



制定策略和流程

制定策略和流程来规范配置管理活动，确保符合项目需求和组织标准，提高软件开发过程的管理效率。



协调团队工作

软件配置管理有助于协调不同开发人员之间的工作，避免重复劳动和冲突，提高开发团队的效率。



项目管理依据

软件配置管理为项目管理提供了重要的依据，通过对配置项的分析和监控，评估项目进度和风险。


软件配置管理

产品发布和维护

软件配置管理有助于软件产品的发布和维护，能够准确地确定软件的版本和包含的配置项。

快速定位问题

在维护阶段，能够快速定位和回滚到特定的版本，以便解决问题和进行更新，确保软件的稳定性和可靠性。



软件配置管理的流程

1 规划配置管理

明确项目的配置管理需求，确定配置管理的目标、策略和计划，确保项目能够按照预期的方式进行管理。

2 识别配置项

确定哪些元素应被视为配置项进行管理，对配置项进行清晰的定义和分类，以便进行有效的管理。

3 建立配置管理库

创建用于存储和管理配置项的集中式或分布式存储库，确保配置项的安全性和稳定性。

4 控制配置项的变更

制定变更管理流程，包括变更请求的提出、评估、审批和实施。确保只有经过授权和批准的变更才能被应用到配置项上，以维持系统的稳定性和一致性。

5 版本管理

对配置项的不同版本进行标识、存储和跟踪。记录每个版本的变更内容、变更者和变更时间，以便能够回溯和比较不同版本。


6 报告和审计

定期生成配置管理报告，提供配置项的状态、变更历史、版本信息等。进行配置审计，以验证配置管理的过程和结果是否符合预定的策略和标准。



10

问题控制



问题控制1

确认问题

确认和记录问题，准确识别问题表现和相关症状，详细记录关键信息，为后续分析提供基础。

问题分类

对记录的问题进行归类，如依据问题类型、所属领域或相关系统模块进行划分。

优先级确定

根据问题对业务的影响程度、紧急性和重要性等因素，评估并确定问题的优先级。



问题控制2

基于问题的诊断结果，制定并实施针对性的解决方案。在解决问题后，对方案的效果进行验证，确保问题已被完全消除。

通过问题控制流程，高效处理各类问题，保障系统和业务的正常运行。

问题调查

解决问题

关闭问题


形成知识储备

深入探究问题，收集相关数据和信息，如查看系统日志、与相关人员交流、尝试重现问题等，以精准找出问题产生的根源。

将问题标记为已解决状态并关闭，同时做好整个过程的记录，形成知识储备，为未来可能出现的类似问题提供参考。

11

专家系统



专家系统

专家系统

一种智能的计算机程序，装有领域专家的知识 and 经验，能像专家一样解决特定领域的问题。有专门诊断汽车故障的专家系统，有帮助农民判断农作物病虫害的专家系统。

推理机

专家系统中的“大脑”，负责根据输入的信息进行推理、判断，得出结论或给出建议。

知识获取困难

将专家知识转化为计算机可理解的形式复杂且耗时，部分专家知识难以用明确规则表达。

适应性差

专家系统中的知识和规则一旦确定，就难以快速适应新的情况和变化。

处理复杂问题的能力有限

对于一些非常复杂、涉及多个不确定因素的问题，专家系统可能无法灵活和全面地进行思考和判断。

技术进步的替代

随着机器学习和深度学习的兴起，新技术在处理大规模数据和复杂任务时表现出更强大的能力，一定程度上替代了专家系统在某些领域的应用。

有一位特别厉害的医生，他知道各种各样的病症和治疗方法，不管你跟他说什么症状，他都能很快给出诊断和治疗建议。这个特别厉害的医生就像是一个**专家系统**。

医生根据你说的头疼、发烧这些症状，在他脑子里进行思考、分析，最后得出你可能是感冒了这个结论，这个思考分析的过程就相当于**推理机**在工作。

比如说在汽车故障诊断的专家系统中，你输入汽车启动时有异常声音，推理机就会根据系统里存储的关于汽车各种故障的知识和规则，推断出可能是发动机出了问题还是其他部件的毛病。

专家系统目前有些没落，但并没有完全被淘汰

知识获取的困难

要把专家的知识准确完整地转化为计算机能够理解和处理的形式，是一个复杂且耗时的过程，而且有些专家的知识 and 经验难以用明确的规则来表达。

比如让一位医术高明的中医把他的诊断思路和经验准确无误地描述出来，形成一套能让计算机使用的规则，是非常有挑战性的。

适应性差

专家系统中的知识和规则一旦确定，就很难快速适应新的情况和变化。

就像如果突然出现了一种新型的疾病，之前建立的医疗专家系统可能就无法准确诊断和处理。

处理复杂问题的能力有限

对于一些非常复杂、涉及多个不确定因素的问题，专家系统可能无法像人类专家那样灵活和全面地进行思考和判断。

技术替代

随着技术的发展，如机器学习和深度学习的兴起，这些新技术在处理大规模数据和复杂任务时表现出了更强大的能力，一定程度上替代了专家系统在某些领域的应用。

两个专家系统的例子

医疗诊断领域


在一些较为细分和专业化的医疗诊断中，如特定疾病的早期筛查或特定类型的医学影像诊断，专家系统可以辅助医生进行判断。例如，针对某些罕见的心脏病或眼科疾病，专家系统可以根据输入的患者症状、检查数据等，提供初步的诊断建议和可能的治疗方案参考。

工业故障诊断

在复杂的工业生产环境中，如大型化工厂或电力系统，专家系统可以用于设备故障的诊断和预测性维护。通过监测设备的运行参数、历史故障数据等，专家系统能够及时发现潜在的故障迹象，并提供相应的维修建议，以减少停机时间和生产损失。

12

自主无人系统



自主无人系统



01 自主无人系统

自主无人系统是一个聪明能干，还不需要人时刻盯着的“小能手”，比如无人驾驶汽车，能自己感知周围环境，决定行走路线和避开障碍物。



02 自主无人系统构成

自主无人系统一般由控制器、被控对象、执行装置和测量装置几个部分构成，共同实现智能化自动控制。

自主无人系统

01 控制器

像是自主无人系统的“指挥官”，它接收各种信息，然后根据预设的规则和算法做出决策，告诉其他部分该怎么做。

02 被控对象

就是系统要控制和操作的东西。比如在无人驾驶汽车里，被控对象就是汽车本身。

03 执行装置


负责把控制器的决策转化为实际动作的部分。比如控制汽车加速、减速的引擎和刹车系统就是执行装置。

04 测量装置

如同系统的“眼睛”，它能测量和反馈被控对象的状态和相关信息给控制器，比如汽车的速度、位置等信息。

13

人机协同系统



人机协同系统的组成可以分为三大部分：人、机、交互

计算机的优势

计算机计算速度快、存储量大、信息处理能力强，可以高效地完成各种任务，提升整体工作效率。

人机协同

通过将人的创造力和判断力与计算机的计算、存储、处理能力相结合，可以实现更加高效、智能和协同的工作。

人机协同系统运行机制的四个步骤

♥ 1 人类输入观测与判断结果

人通过对观测到的数据进行分析、推理和判断，然后将得出的结果通过人机交互接口输入到计算机中。

🔥 2 计算机处理与分析

计算机接收到人类输入的信息后，运用其强大的计算能力和算法，对这些信息进行进一步的处理、分析和整合。

☁ 3 协同决策与规划

基于人类的判断和计算机的分析结果，人和计算机共同参与决策和规划，充分发挥各自的优势，制定出合理方案。

👍 4 执行与反馈调整

根据共同制定的方案，执行相应的操作。在执行过程中，持续收集反馈信息，评估执行效果，根据实际情况进行调整和优化。

人机协同系统的例子

案例中，医生的专业判断和经验与人机协同系统中手术机器人的高精度和稳定性相结合，提高了手术的成功率和安全性，充分体现了人机协同系统的优势。

♥ 1 医生是人这一方的关键角色

在进行一场复杂的心脏手术时，医生是人这一方的关键角色。手术前，医生会对患者进行详细的检查，包括查看病历、进行身体检查、分析各种影像资料等，凭借自己的专业知识和经验，对患者的病情做出判断和诊断。

☁ 3 协同决策与规划

在手术过程中，医生和手术机器人协同工作。医生根据实时情况做出决策，调整手术策略，而机器人则迅速、准确地执行医生的指令。例如，当医生决定在某个位置进行缝合时，他通过操作界面向机器人下达指令，机器人的机械臂会精准地完成缝合动作。

🔥 2 手术机器人则是计算机这一方的代表

手术机器人则是计算机这一方的代表。在手术中，医生通过人机交互接口，将自己对手术的规划和操作意图输入给手术机器人。手术机器人配备了高精度的传感器和先进的成像系统，能够为医生提供清晰、放大的手术视野，让医生更准确地看到患者体内的细微结构。同时，机器人的机械臂可以根据医生的指令，进行极其精确和稳定的操作，比如切割、缝合等，其精度远远超过人类的手。

👍 4 执行与反馈调整

手术后，医生会对手术效果进行评估，并根据手术中的情况和患者的恢复情况，总结经验，为未来的手术提供更好的方案。同时，手术机器人也会记录下手术中的各种数据，为后续的优化和改进提供参考。



◆ THANKS ◆
感谢您的观看

