

人工智能训练师 理论知识点讲解08

刘老师

2024-10



目录

CONTENTS

- 定比数据
- 哈希算法
- 数据规约及策略
- Word2Vec
- 基于机器学习的关键词提取方法


目录

CONTENTS

- PageRank 算法
- 语音标注质量评估的WER（词错误率）算法
- 行人重识别标注

01

定比数据



定比数据的定义



● 定比数据定义

定比数据是数据测量的一种高级形式，具有定距数据的所有特征（如数据间的差值有意义），还具有一个绝对的零值。

● 定比数据特征

定比数据表示的是绝对数值，零值表示“没有”或“不存在”，如身高、体重、年龄、收入等数据。不仅收入 1000 元和 2000 元的差值有意义，而且收入为 0 时，是真正的没有收入。

● 定比数据应用

在经济学、统计学和社会学等领域，定比数据被广泛应用于描述和分析各种现象和问题。

定比数据与定距数据的区别

定比数据与定距数据

定比数据和定距数据都表示绝对数值，但定比数据具有一个绝对的零值，而定距数据没有。温度不是定比数据。以摄氏温度为例，它的零点是人为设定的（在标准大气压下，冰水混合物的温度被定义为 0 摄氏度），而且 20 摄氏度并不是 10 摄氏度的两倍，数值之间的比例没有实际的数量意义。但温度可以被认为定距数据，因为它的数值间隔是有意义的，比如 20 摄氏度比 10 摄氏度高 10 度。

定比数据应用

定比数据在经济学、统计学和社会学等领域具有广泛应用，用于描述和分析各种现象和问题。



定序数据提供了更多的探索方法

定序数据探索

定序数据为我们提供了多种探索方法，
如有顺序之分，可研究等级分布、变化趋势及因素影响。

等级分布研究

通过研究不同等级之间的分布情况，
可以了解优秀、良好、中等和差别的比例。

变化趋势研究

通过分析随着时间的推移，等级的变化趋势，
可以了解成绩等级是越来越好还是越来越差。

探索方法好处

通过对定序数据的探索，我们可以获取更多有价值的信息，
以便做出更好的决策和改进措施。


因素影响研究

通过研究不同因素对成绩等级的影响，
可以了解学习方法、学习时间等因素如何影响成绩等级。





02

哈希算法



哈希算法的定义



哈希算法

哈希算法是一种将任意长度的数据映射为**固定长度值**的方法，被称为哈希值或散列值。

哈希算法应用

哈希算法广泛应用于数据检索、加密、验证和生成唯一标识符等场景，是计算机科学领域的重要工具。

哈希算法的应用

直接定址法：

假设我们要给一个班级的同学安排座位，座位号从1 到 50 。我们规定学号是 1 到 10 号的同学直接坐在 1 到 10 号座位，学号 11 到 20 号的同学直接坐在 11 到 20 号座位，以此类推。

哈希表

哈希表是一种基于哈希算法的数据结构，它通过将键映射到存储位置来快速查找和检索数据。

哈希函数

哈希函数是哈希算法的核心部分，它接受可变长度的输入并输出固定长度的哈希值。

哈希算法安全性

哈希算法在信息安全领域扮演着重要角色，如数字签名和身份验证，确保数据完整性和真实性。

数字分析法在哈希算法中的应用

01

数字分析法

数字分析法是一种预处理步骤，通过观察数据集的规律和模式，选择合适的哈希函数。

02

哈希函数选择


根据数据集的特点，选择不同的哈希函数，以确保哈希值的唯一性和计算的效率。

03

计算效率


对于大型数据集，通过数字分析法选择的哈希函数可以显著提高哈希计算的效率。

假设我们有一堆学生的学号，比如20210508、20220315、20230720等等。我们通过观察发现，学号的中间几位数字（比如第4到第6位）比较有规律。比如说，这3位是050的学号特别多。那我们在设计哈希函数的时候，就可以把学号中间三位是050的都放到一个特定的存储位置，比如存储位置50。这样，当我们要查找学号中间三位是050的学生信息时，就直接去50这个位置去找，会更快更方便。



03

数据规约及策略




数据规约的介绍

数据规约

数据规约是将复杂数据变得简洁、精炼，同时尽量保留重要信息。

衣柜比喻

数据规约如同整理衣柜，将常穿、重要衣服留下，不常穿先收起，使衣柜更清爽，找衣服更容易。



数据规约常见的策略

数据立方体聚集

将小积木拼成大积木，汇总相关数据，快速查看总体情况，但可能丢失细节。

01

维规约

描述一件事情的多个维度（如身高、体重、年龄、性别等），通过维规约，只留下最重要的几个维度。

02

数据压缩

将数据进行压缩，节省存储空间和传输时间，但压缩和解压缩可能需要一定的计算资源。

03

数值（数量）规约

对数值型数据进行简化，如用平均值或范围表示一大串数字，使数据更简洁，但可能损失一点精度。

04

离散化和概念分层

将连续数值分成区间或复杂概念分成层次，方便理解和处理，但可能使数据变得粗糙。

05

策略选择


根据需求和情况选择合适的方法，达到简化数据和满足分析目的的平衡。

06




04

Word2Vec



Word2Vec的概念



01

Word2Vec

Word2Vec是一种将单词或句子转化为数字序列（向量）的算法，通过计算每个单词的特定数字表示，将文本数据转化为计算机易于处理的数字形式（向量）。

02

单词的数字表示


Word2Vec为每个单词计算出一组特定的数字，称为词向量。这些词向量能够捕捉单词之间的语义和语法关系，从而使得计算机能够“理解”和处理文本数据。

03

文本分类

通过词向量，计算机可以判断一篇文章是讲美食的还是讲科技的，从而进行更准确的文本分类。

Word2Vec的概念



语义相关性

Word2Vec能够找出意思相近的单词，如“苹果”和“香蕉”，从而判断它们在意义上的相关性。

数字表示的优势

Word2Vec将文本转化为数字形式，使得计算机能够更容易地处理和理解文字信息，从而提升自然语言处理的效率和准确性。

Word2Vec的应用

Word2Vec应用于搜索推荐


Word2Vec可用于搜索推荐系统，通过计算用户搜索关键词与商品或服务描述的词向量的相似度，实现精准推荐。

词向量用于匹配

Word2Vec生成的词向量可用于匹配用户搜索意图与商品或服务类别，从而提供更个性化的搜索结果。


语义理解与生成

Word2Vec有助于实现更高级的语义理解和生成，例如生成描述商品或服务的文本广告，或回答用户关于商品或服务的询问。



05

基于机器学习的关键词提取方法



TF-IDF (词频-逆文档频率)

TF-IDF定义

TF-IDF (词频-逆文档频率) 是一种常用的关键词提取方法, 通过计算词频和文档频率的乘积来评估关键词的重要性。

01

02

词频 (TF) 计算

词频 (TF) 表示一个词在文档中出现的频率, 通过统计该词在文档中出现的次数来计算。

文档频率 (IDF) 计算


文档频率 (IDF) 表示一个词在整个文档集合中出现的稀有程度, 通过统计该词在文档集合中出现的次数来计算。

03

04

关键词提取

出现频率高但在其他文档中少见的词, 就可能被认为是关键词。



TextRank



TextRank定义

TextRank是一种基于图的算法，通过计算节点的重要性来提取关键词，适用于处理大型文本数据集。


文本数据集处理

TextRank将文章中的词看作节点（node），词之间的关系看作边（edge），通过计算节点的重要性来提取关键词。

关键词提取

在社交网络中，和很多重要人物有关系的人，自己也往往比较重要。在文章里，和很多重要词语有联系的词，就可能是关键词。

LDA（潜在狄利克雷分配）主题模型



LDA主题模型

LDA（潜在狄利克雷分配）是一种主题模型，通过发现文档中的潜在主题来提取关键词。



文档中的潜在主题

LDA主题模型能够分析文本数据，发现文本中的主题和关键词，对于理解文本内容和结构非常有帮助。

深度学习方法



深度学习提取关键词

深度学习方法，如卷积神经网络（CNN）和循环神经网络（RNN），能够提取关键词。



上下文信息与节点

深度学习网络能够学习词语之间的复杂关系和上下文信息，从而找出关键的词语。




准确关键词提取

深度学习方法根据具体需求和数据特点选择，以提取更准确的关键词。

06

PageRank 算法



PageRank算法概述

01

PageRank算法应用于搜索技术：
PageRank算法是一种用于搜索技术的算法，通过分析网页之间的链接关系，评估每个网页的**重要性得分**。

02

重要性得分高的网页排名靠前：
PageRank算法根据每个网页的重要性得分，确定其在搜索结果中的排名顺序，得分高的网页排名靠前。

03

链接数量与质量共同决定得分：
PageRank算法综合考虑了链接数量和质量，以及被链接网页的重要性，来计算每个网页的重要性得分。

04

权威新闻网站提升价值：如果一个权威的新闻网站链接到了一个其他网页，那么这个被链接的网页可能会获得更高的价值。

05

搜索技术发展：
PageRank算法是搜索技术发展的重要里程碑，它通过不断计算和更新每个网页的重要性得分，帮助用户更快地找到有用信息。

PageRank算法的原理与思路

01

蜘蛛网模型

将互联网想象成一个巨大的蜘蛛网，每个网页是蜘蛛网上的一个节点，PageRank算法计算每个节点在这张网上的重要程度。

02

节点重要程度计算

如果一个网页被很多其他重要的网页链接指向，那么它就比较重要，就像一个人被很多有威望的人称赞，那么这个人可能比较厉害。

03

链接网页重要性

那些指向被评估网页的链接网页本身越重要，被评估网页的重要性就越高，例如一个权威的新闻网站链接到一个其他网页，被链接的网页可能更有价值。

04

重要性得分更新

PageRank算法通过不断的计算和更新每个网页的重要性得分，帮助我们在搜索时更快地找到更重要、更有用的网页。

PageRank算法的应用与影响

PageRank算法的应用

PageRank算法主要用于评估网页的重要性和排名，通常并不直接用于提取关键词。

扩展与创新应用


通过分析网页中词语出现的位置、频率及与其他重要词语的关联等，结合PageRank思想评估词语重要性，辅助关键词提取。

专门设计提取关键词

PageRank算法本身不是专门为提取关键词而设计的，但其思想可应用于关键词提取，具有一定的辅助作用。

07

语音标注质量评估 的WER（词错误 率）算法



WER算法的过程

同时，我们有这段语音原本真正应该对应的准确文字，叫做“**参考文本**”。

计算不一样的单词数量，用不一样的单词数量除以参考文本里的单词总数，得到的这个比例就是WER。

语音标注

参考文本

单词拆分

错误单词计算

假设有一段语音，经过处理得到了标注的文字结果，我们把这个叫做“**识别结果**”。

识别结果和参考文本里的文字都拆分成一个个单词，**对比**这两组单词，看看哪些单词是完全一样的，哪些不一样。


WER算法的优点与缺点

WER算法的优点

WER算法很直接简单，容易计算和理解，能比较清楚地告诉我们语音标注和实际说的话之间有多大差别。

WER算法的缺点

WER算法对小的错误很敏感，只看词对不对，不太管意思是不是差不多，有时候可能有点太严格了。



WER算法在数据量大的时候性能比较差的原因



计算资源与时间

当数据量很大时，需要消耗很多的计算资源和时间，因为要对大量的单词进行对比和计算。

错误情况复杂


数据量大意味着可能出现的错误情况更加复杂多样，处理和统计这些错误会变得更加繁琐。

特殊情况与噪声

大规模数据中可能存在一些特殊情况或者噪声，这会增加算法处理的难度，影响其效率和准确性。

08

行人重识别标注



行人重识别标注的介绍

01

行人重识别标注

行人重识别标注是在图像或视频数据中，对出现的行人进行标记和特征描述，以便计算机能够识别和区分不同的行人个体。

02

重识别的意义


重识别中的重有再次、重新的意思，行人重识别标注的重点在于让计算机能够在不同的场景、不同的摄像头视角下，再次或重新准确识别出已经出现过的特定行人。

03

标注的准确性

行人重识别标注并不是第一次简单地识别出行人，而是在复杂多样的条件下，能够再次把这个人从众多行人中辨认出来。

行人重识别标注的重点



标注框的完整性

分裂框是指标注框出现了不应该的分裂，本该是一个完整的行人被框成了两个或多个部分。

标注框与行人的匹配

跑框是指标注框的位置偏离了行人的实际范围，比如框的一部分跑到了行人之外。

标注框的位置稳定性

跳框可能是指标注框在连续的图像或视频帧中出现位置跳动不稳定的情况。

标注框的准确性

错框一般是指标注框的大小、形状或者位置完全不符合行人的实际情况，导致标注错误。

影响行人重识别标注准确性的问题

遮挡问题

行人在行走过程中，可能会被其他行人或物体遮挡，导致标注框不完整或错误。

姿势变化

行人的姿势可能会发生变化，如弯腰、扭头等，导致标注框的位置不准确。

光照变化

光照条件的变化也会影响行人重识别标注的准确性，如光线昏暗或强烈阳光。

摄像头视角变化

不同摄像头的视角和焦距不同，可能导致行人形象变形或模糊，影响标注准确性。





◆ THANKS ◆
感谢您的观看

