

人工智能训练师 理论知识点讲解09

陈老师

2024-10




目录

CONTENTS

- 数据处理的基本步骤
- 处理机与通道的操作
- 光纤通信
- ETL
- 数据仓库和数据库的差异
- 分箱
- 数据集成
- 函数拟合和回归的对比
- 离群点分析
- 数据质量
- 数据交付和验收
- 埋点验证
- 独热编码
- 聚合和聚类的比较

01

数据处理的基本步骤



数据集 (Dataset)

➤ 又称为资料集、数据集合、资料集合或数据产品

- 是经过规范化整理、工程化标注的一组具有统一格式的数据集合
- 人工智能数据集主要分为

- 图像数据集
- 视频数据集
- 文本数据集
- 语音数据集



全景图·新视界


MNIST手写字符数据集

➤训练集

- 60,000张28x28像素灰度图像
- 10类数字标签

➤测试集

- 10,000张28x28像素灰度图像



数据


■ 结构化数据



age	sex	region	income	married	children	car	save_act	current_act	mortgage	pop	realincome
48	FEMALE	INNER_CITY	17546.0	NO	1	NO	NO	NO	NO	YES	17546.0
40	MALE	TOWN	30089.1	YES	3	YES	NO	YES	YES	NO	10028.4
51	FEMALE	INNER_CITY	16575.4	YES	0	YES	YES	YES	NO	NO	16575.4
23	FEMALE	TOWN	20375.4	YES	3	NO	NO	YES	NO	NO	6791.8
57	FEMALE	RURAL	50576.3	YES	0	NO	YES	NO	NO	NO	50576.3
57	FEMALE	TOWN	37869.6	YES	2	NO	YES	YES	NO	YES	18934.8
22	MALE	RURAL	8877.07	NO	0	NO	NO	YES	NO	YES	8877.07
58	MALE	TOWN	24946.6	YES	0	YES	YES	YES	NO	NO	24946.6
37	FEMALE	SUBURBAN	25304.3	YES	2	YES	NO	NO	NO	NO	12652.1
54	MALE	TOWN	24212.1	YES	2	YES	YES	YES	NO	NO	12106.1
66	FEMALE	TOWN	59803.9	YES	0	NO	YES	YES	NO	NO	59803.9
52	FEMALE	INNER_CITY	26658.8	NO	0	YES	YES	YES	YES	NO	26658.8
44	FEMALE	TOWN	15735.8	YES	1	NO	YES	YES	YES	YES	15735.8
66	FEMALE	TOWN	55204.7	YES	1	YES	YES	YES	YES	YES	55204.7
36	MALE	RURAL	19474.6	YES	0	NO	YES	YES	YES	YES	19474.6
38	FEMALE	INNER_CITY	22342.1	YES	0	YES	YES	YES	YES	NO	22342.1
37	FEMALE	TOWN	17729.8	YES	2	NO	NO	NO	YES	NO	8884.9
46	FEMALE	SUBURBAN	41016.0	YES	0	NO	YES	NO	YES	NO	41016.0
62	FEMALE	INNER_CITY	26909.2	YES	0	NO	YES	NO	NO	YES	26909.2



■ 非结构化数据



通常，通过“特征工程/学习”转换到结构化数据，再进行模式挖掘。

数据处理的基本步骤



● 数据处理流程

数据处理的基本步骤包括数据采集、数据存储、数据清洗、数据集成、数据规约、数据变换和知识表示。

● 数据采集

数据采集是指从原始来源获取数据，并对其进行初步整理和存储，以便后续分析。

● 数据存储

数据存储是将采集到的数据保存到数据库或数据仓库中，以便长期保存和管理，等待后续处理。

数据处理的基本步骤

数据清洗

数据清洗是指去除数据中的噪声和异常值，纠正错误，以确保数据的准确性和可靠性。

数据集成

数据集成是将来自不同来源的数据合并成一个一致的数据集，以便进行后续分析。

数据规约

数据规约是指通过聚合、删除冗余特征等方式，将原始数据集缩减到所需规模，以便提高后续处理效率。



数据处理的基本步骤

数据变换

数据变换是指将数据转换为适合分析的格式或范围，例如通过缩放、归一化或标准化等方式。

知识表示

知识表示是指将处理后的数据转换为易于理解的形式，例如通过可视化或报告等方式。



数据从哪里来？



机器产生的数据

应用服务器日志、各类传感器数据、图像和视频监控数据、二维码和条形码（条码）扫描数据等

人产生的数据

推特、微博、通信软件、移动通信数据、电子商务在线交易日志数据、企业应用的相关评论数据等

企业应用产生的数据

关系型数据库中的数据、数据仓库中的数据等

数据采集

➤ 数据采集


- 互联网数据采集
- 众包数据采集
- 行业合作数据采集
- 传感器数据采集



图像采集区
VIDEO

数据采集示例

- 年龄分布：18-30岁
- 性别分布：男性：50%；女性：50%
- 人种分布：黑种人：10%；白种人：40%；黄种人：50%
- 表情类型：正常；挑眉；向左看；向右看；向下看；向上看；闭左眼；闭右眼；微张嘴；张大嘴；嘟嘴；微笑；大笑；惊讶；悲伤；厌恶
- 拍摄环境：光线正常；光线较强；光线较弱
- 图片尺寸：1600 * 1200
- 文件格式：JPG 样本数量：20,000
- 应用领域：人脸检测、人脸识别



数据采集示例

- 车型分布：小轿车；SUV；面包车；客车；货车；其他
- 车辆颜色：白；灰；黑；红；黄；绿；其他
- 拍摄环境：光线正常；光线较强；光线较弱
- 图片尺寸：1024 * 768
- 文件格式：JPG
- 样本数量：75,000
- 应用领域：车辆检测



数据采集示例

- 文字语料：中文、英文网络文字语料
- 语言分布：中文：50%；英文：50%
- 文件格式：txt
- 编码格式：UTF-8
- 样本数量：50,000,000条
- 应用领域：语言识别、文本分类、机器翻译



数据清洗

- > 数据格式标准化
- > 异常数据清除
- > 数据错误纠正
- > 重复数据的清除



数据清洗

> 处理缺失值

· 忽略元组

- 将含有缺失属性值的对象直接删除

· 数据补齐

- 人工填写
- 特殊值填充
- 平均值填充
- 最有可能的值填充

· 不处理

- 有很多方法在属性值缺失方面具有良好的鲁棒性



数据清洗

> 处理噪声

- 回归
 - 通过函数拟合数据
- 分箱
 - 考察相邻数据来确定最终值
 - 即按照属性值划分子区间(箱子)
- 孤立点分析
 - 通过聚类来检测

> 处理重复数据


- 合并
- 消除

数据可视化

> 人脑不同于计算机


· 对图形的印象更加深刻

> 数据可视化有助于分析数据，寻找规律




数据可视化

> 利用一些**数学和统计方法**从众多特征中寻找规律



数据转换



数据转换

数据转换主要是将抽取的数据进行标准化处理，使其符合目标系统和业务需求。

数据格式

对于结构化数据，转换的逻辑相对简单，主要是对表结构和字段进行标准化处理。对于半结构化数据和非结构化数据，转换的逻辑更为复杂，需要进行文本解析、数据提取、数据关联和数据格式转换等操作。

数据转换工具

在数据转换过程中，需要根据数据源的不同，针对性地选择合适的转换工具，例如数据仓库ETL（Extract-Transform-Load）工具、ELT

（Extract-Load-Transform）工具、自定义脚本等。同时，还需要根据业务需求和目标系统的要求，对转换规则进行定义和调整，以保证转换后的数据符合目标系统的要求。

特征规约：删除不重要或不相干的特征，或对特征进行重组来减少特征个数

特征规约步骤

- (1) 搜索过程：在特征空间搜索特征子集
- (2) 评估过程：输入一个状态，输出一个评估值，搜索算法的目的是使评估值达到最优
- (3) 分类过程：使用最终的特征子集完成最后的算法

特征规约处理的效果

- (1) 更少的数据和更高的挖掘效率
- (2) 更高的数据挖掘处理精度
- (3) 简单的数据挖掘处理结果
- (4) 更少的特征

特征转换

对特征进行缩放、编码或嵌入，以适应模型输入要求。



样本规约与先验知识构建



样本规约：从数据集中选出一个有代表性的样本子集



作用：使用样本子集进行数据分析，得到整体数据的基本分析，构成对整体数据的先验知识。



利用领域知识，构建先验模型，指导数据预处理。

特征值规约技术：特征值离散化技术

标准化

将数据按比例缩放，使之落入一个小的特定区间，如0到1之间。

归一化

通过一些数学变换方式，将原始数据映射到指定的范围，如 $[-1,1]$ 。

离散化

将连续型数据转换为离散型数据，便于进行数据处理和分析。

好处：简化数据描述，并易于理解数据和最终的挖掘结果

特征值规约技术

有参的特征值规约:


- (1) 回归: 包括线性回归和多元回归
- (2) 对数线性模型: 近似离散多维概率分布

无参的特征值规约:

- (1) 直方图
- (2) 聚类
- (3) 选样: 用数据较小的随机样本表示较大的数据集, 如简单选择 n 个样本、聚类选样、分层选样

02

处理机与通道的操作



处理机与通道的操作

并行与并发：在单处理机系统中，
处理机操作和通道操作通常被认为
是并行操作。

通道操作：通道操作不需要使用
CPU 资源，可以独立于 CPU 完
成输入输出(IO)操作，减轻 CPU
负担。

并行与并发区别：“并行”(同时
进行)和“并发”(分时)在单处
理机系统中区别在于任务执行方
式。


处理机定义：处理机（CPU）是
计算机系统的核心部件，负责执
行指令、处理数据和控制系统运
行。

处理机与通道并行工作：处理机
和通道的操作可以看作并行，因
为它们能够各自独立地、同时地
工作。






03

光纤通信



频率范围



频率范围

光的频率范围非常广泛，可见光的频率大约在 4.3×10^{14} 赫兹到 7.5×10^{14} 赫兹之间。常见的以太网电缆可以支持到 10GHz 左右，但与光的频率相比，仍然低很多。在网络传输介质中，**光纤的抗干扰能力最强。**

频率范围的定义

频率范围是指电磁波的频率高低差异，决定了光的基本性质和在介质中的传播特性。

带宽

带宽的定义（率）

带宽是指在通信和计算机领域中，单位时间内可传输的数据量，常用每秒传输的比特数（bps）来表示。

带宽的作用

带宽就像道路宽度，越宽则单位时间内可通过的数据越多，较宽的带宽能够允许更多的数据同时传输。

高低带宽的影响


高带宽的网络连接能够快速传输大量数据，如高清视频、大型文件等，而低带宽的网络连接则传输速度较慢，可能出现卡顿。

光纤的优势

光纤具有每秒数十万G甚至更高的数据传输能力，但具体数值会随着技术的进步和实际应用的不同而有所变化。

04

ETL



ETL 的定义与作用



Extract（抽取）

从各种数据源中获取需要的数据。

Transform（转换）

对抽取出来的数据进行处理和转换，使其符合后续处理和分析的要求。

Load（加载）

将经过转换后的数据加载到目标数据存储中，以便进行数据分析、报告生成或其他业务应用。

ETL 目的

整合和处理来自多个不同数据源的杂乱、不一致的数据，提供有力的数据基础。

ETL 的应用场景

企业数据模型

企业数据模型就像是一个整体的规划蓝图，描述了企业中各种数据的关系和结构。ETL 并非局限于对单个企业部门或应用系统数据的简单整理，而是涉及跨部门、跨系统的数据整合处理。

ETL 的作用

ETL 在企业数据模型的基础上，发挥其强大的作用，从各个系统中抽取、转换并存储数据。

例子：数据抽取

ETL 从生产、销售、财务等系统中抽取零部件产量、质量、客户订单、财务数据等信息。

01

02

03



数据转换

ETL 对抽取出的数据进行转换，包括统一数据格式、计算关键指标、清理重复或错误数据等。

04

数据存储模式构建

ETL 根据企业需求和分析重点，建立合理的数据存储模式，如按产品类别、时间周期分类存储。

05

数据交换平台建立

ETL 通过建立数据交换平台，使各个部门能够方便地获取和共享所需数据，提高数据利用效率和决策科学性。

06

常见的ETL工具

DataPipeline

提供实时数据集成平台，支持多种数据源和数据目标，具有高性能和易用性。有非常容易使用的 GUI，具有丰富的可视化监控，易用性低，难度低，不需要开发；

Informatica

企业级数据集成平台，提供强大的数据抽取、转换和加载功能，支持实时和批量数据处理。GUI+Coding，有GUI，但是要专门的训练，易用性低，难度高，需要开发；

Kettle

开源ETL工具，支持图形化设计和多种数据转换操作，GUI+Coding，易用性低，难度高，需要开发；

Oracle Goldengate

实时数据集成和复制解决方案，支持高可用性、数据一致性和灵活性。需要完全吃透源码才可以调用，学习成本高，没有图形开发界面和监控界面，易用性低，难度高，需要开发。



Kettle工具

Kettle

Kettle：是一款国外开源的ETL工具，纯java编写，可以在Windows、Linux、Unix上运行，数据抽取高效稳定。Kettle 中文名称叫水壶，该项目的主程序员MATT 希望把各种数据放到一个壶里，然后以一种指定的格式流出。C/S客户端模式，开发和生产环境需要独立部署，任务的编写、调试、修改都在本地，需要发布到生产环境，线上生产环境没有界面，需要通过日志来调试、debug，效率低，费时费力；



ETL 的执行过程

调度算法

采取条件驱动的策略进行任务调度，以优化资源利用和提高执行效率。

应对策略

制定处理成功或失败情况的应对策略，以确保ETL过程的稳定性和可靠性。

提示机制

对任务执行的成功或失败信息发出及时有效的提示，便于监控和问题排查。

任务流程的依赖关系


在ETL过程中，任务之间的依赖关系需要明确，确保数据处理的逻辑正确。

条件驱动的策略

根据特定条件触发任务调度，确保数据抽取、清洗、转换和加载的准确性和及时性。



ETL 的调度策略



条件驱动策略

通过条件驱动策略，可以更灵活、高效地调度 ETL 任务，避免不必要的资源浪费和错误操作。

避免资源浪费

条件驱动策略可以根据实际需求动态调整 ETL 任务的调度，从而避免不必要的资源浪费。

高效调度策略

通过条件驱动策略，可以根据实际需求快速调度 ETL 任务，提高整体处理效率。

一个电商公司的 ETL 流程

三个任务

从销售数据库抽取数据（任务 A）、对抽取的数据进行清洗和转换（任务 B）、将处理后的数据加载到数据仓库（任务 C）。

条件驱动的策略


条件 1：只有当销售数据库中的新数据量超过一定阈值（比如 1000 条记录）时，才启动任务 A 进行数据抽取。

条件 2：任务 A 成功完成后，且抽取的数据中没有缺失的关键字段（如订单号），才启动任务 B 进行数据清洗和转换。

条件 3：任务 B 成功完成，并且转换后的数据格式符合数据仓库的要求，才启动任务 C 进行数据加载。


高效灵活调度

某天，销售数据库中新产生了 1500 条数据记录，满足了条件 1，于是触发任务 A 开始抽取数据。任务 A 顺利完成，抽取的数据也没有关键字段缺失，满足条件 2，接着启动任务 B。任务 B 也成功完成，且数据格式正确，满足条件 3，最后启动任务 C 将数据加载到数据仓库。



05

数据仓库和数据库 的差异



数据仓库和数据库的差异




数据库

数据库就像一个存放日常业务数据的“小仓库”，主要支持企业日常业务操作，如记录订单、管理库存、处理客户信息等。它需要保证数据的实时性和准确性，能够快速处理频繁的写入和更新操作。

数据仓库

数据仓库则像是一个专门为了分析和决策准备的“大仓库”，它整合了不同数据库和数据源的大量数据，经过处理和转换，让数据变得更有条理、更适合分析。数据仓库不太关心实时的写入和更新，重点是能让人们从大量历史数据中发现趋势、规律和关系，帮助做出更好的决策。

数据仓库和数据库的差异



数据分析


超市的数据库会随时记录每一笔交易，而数据仓库可能会把几个月甚至几年的销售数据汇总起来，分析哪种商品在哪个季节卖得最好。

数据库与数据仓库的区别

数据库侧重于业务操作，数据仓库侧重于数据分析和决策支持。

06

分箱



分箱

分箱数据平滑技术

在噪声数据处理中，“分箱”是一种数据平滑技术，通过考察数据的周围值来光滑有序的数据值。

分箱划分数据范围

分箱的过程是将有序数据划分到不同的“箱子”中，每个箱子都包含了一定范围内的数据。

考虑周围值平滑数据

在确定某个数据值的最终表示时，通过综合考虑其所在箱子中其他数据值的情况来代表这个分数。

分箱减少数据波动

分箱处理可以消除数据中的噪声，使数据的趋势和特征更加明显和稳定，减少个别异常值或噪声导致的数据波动。

例子

假设我们有一组学生的考试成绩数据：85、88、90、92、80、95、100、78、86、98。

我们按照每 10 分为一个箱子进行分箱处理。

第一个箱子为 70 - 79，包含 78 这个数据；第二个箱子为 80 - 89，包含 85、88、80、86；第三个箱子为 90 - 99，包含 90、92、95、98；第四个箱子为 100 - 109，包含 100。

对于第一个箱子，我们可以用 78 作为代表值。


对于第二个箱子，我们可以用这些值的平均值 $(85 + 88 + 80 + 86) \div 4 = 84.75$ 来代表这个箱子内的数据。

对于第三个箱子，平均值为 $(90 + 92 + 95 + 98) \div 4 = 93.75$ 。

对于第四个箱子，就用 100 作为代表值。

07

数据集成



数据集成

数据集成的例子

假设有两个数据表，一个表记录了学生的基本信息，包括学号、姓名、年龄；另一个表记录了学生的考试成绩，包括学号、课程名称、成绩。

01

集成数据表

要将两个表集成在一起，形成包含学生基本信息和对应考试成绩的综合表。

02

数据匹配

在集成过程中，会根据学号这个**共同字段**，将两个表中的相关信息匹配起来。

03



数据集成

比如：学号为001的学生，在基本信息表中有姓名是张三，年龄是18岁。在成绩表中有数学成绩是90分，语文成绩是85分。

04

新表信息

经过数据集成，得到新表，其中包含学号001、姓名张三、年龄18岁、数学成绩90分、语文成绩85分等信息。

05


数据集成的优势

通过数据集成，能够更全面、系统地了解和
分析学生的情况。

06

08

函数拟合和回归的 对比



函数拟合和回归的对比

函数拟合的定义

函数拟合是找到一个函数，使得给定的数据点尽可能接近该函数曲线。例如，给定一组数据点 (1, 2)、(2, 4)、(3, 6)、(4, 8)，我们可以用线性函数 $y = 2x$ 来拟合这些点。

函数拟合的优点

函数拟合能得到与数据点非常接近的函数曲线，它不太强调变量之间的统计关系。



回归分析的定义


回归分析是找到变量之间的关系，并关注对预测结果的不确定性评估和统计显著性检验。

回归分析的优点

回归分析能提供更全面和准确的信息，包括关系式的可靠性、拟合的好坏以及各个系数的显著性等。

09

离群点分析



离群点分析

例如，我们有一组学生的考试成绩数据：75、80、85、90、95、100、20。在这组数据中，大多数成绩都在75到100之间，而“20”这个成绩与其他成绩相比差异极大，明显偏离了整体的分布模式。那么“20”这个数据点就可以被视为离群点。

离群点分析的意义

对离群点进行分析有助于发现数据中的异常情况、检测错误、深入理解数据的特征和规律。

离群点的识别

在给定的数据集中，离群点是指那些显著不同于其他数据点的值，它们可能偏离了整体的分布模式。

离群点的原因


离群点的出现可能是由于数据录入错误、特殊情况导致的异常表现，或者代表了一种罕见但真实的现象。

离群点分析的定义

离群点分析是在数据集中识别出与其他数据点显著不同或偏离常规模式的数据点的过程。

010

数据质量



数据质量

> 机器学习算法的训练效果很大程度依赖高质量的数据集

- 如果训练中所使用的标注数据集存在大量噪声

- 将会导致机器学习训练不充分

- 无法获得规律

- 在训练效果验证时会出现目标偏离，无法识别的情况

- 当数据集的整体标注质量只有80%的时候

- 机器学习的训练效果可能只有30%~40%



数据质量


> 数据质检

- 对标注的数据进行审核
- 是保证数据质量的重要环节


> 数据质量的六个核心维度

- ❖ 完整性: 数据信息是否存在缺失的状况, 常见于数据表中行、字段、码值的缺失;
- ❖ 有效性: 包括范围有效性、形式有效性等, 体现在数据记录的规范和数据是否符合逻辑
- ❖ 准确性: 数据记录的信息是否存在异常或错误;
- ❖ 及时性: 数据从开始处理到可以查看的时间间隔;
- ❖ 一致性: 相同含义信息在多业务多场景中是否具有 consistency;
- ❖ 唯一性: 数据集中数据不重复的程度。


数据质检的方法-实时检验




数据质检的方法-全样检验



数据质检的方法-抽样检验




数据质检的方法-混合式检验




011

数据交付和验收




数据交付和验收

- 将**质检合格**的数据及相关资料**交付**给需求方
 - 标注团队需对最终提交的数据量进行说明
 - 交付的内容应包括标注结果、交付和说明文档、关于标注数据的元数据、原始数据等
- 需求方对其进行**验收**
 - 若验收数据质量未达到期望值，数据需求方可要求数据服务提供商对数据进行修正



12

埋点验证



埋点验证

埋点验证的定义

在数据质检中，“埋点验证”是指对预先在系统或应用中设置的数据采集点进行检查和确认，以确保这些埋点能够准确、完整地收集到预期的数据。

埋点验证的例子

在新闻资讯应用中，设置了埋点来记录用户对不同类型新闻的点击次数和阅读时长，埋点验证时会检查数据是否准确记录，有没有丢失或出错等情况。

埋点验证的重要性

埋点验证是要检查埋点是否正常工作，数据格式是否正确，数据的传输和存储是否完整无误等，保证分析和决策的准确性和可靠性。

购物应用埋点验证

在手机购物应用中，设置了点击埋点、停留时间埋点和加入购物车按钮点击埋点，在进行埋点验证时，会检查数据记录是否准确，数据在传输过程中是否完整。

埋点验证例子

设置埋点

有一个手机购物应用。为了了解用户的行为和偏好，开发人员在应用中设置了以下埋点：

1. 首页商品推荐区的点击埋点：用于记录用户点击了哪些推荐商品。
2. 商品详情页的停留时间埋点：统计用户在每个商品详情页停留的时长。
3. 加入购物车按钮的点击埋点：记录用户将哪些商品加入了购物车。

埋点验证

首先，会检查首页商品推荐区的点击埋点。比如，当用户点击了某个推荐商品时，后台是否准确地记录下了这个点击动作，以及记录的商品信息是否正确无误。

接着，对于商品详情页的停留时间埋点，会验证停留时间的计算是否准确。比如，用户在一个商品详情页停留了 3 分钟，后台记录的时长是否确实是 3 分钟，而不是 2 分钟或者 4 分钟。

.....

埋点验证的执行主体

依靠人工

在一些简单的场景或者初期阶段，可能主要依靠人工来验证。比如开发人员或测试人员手动模拟用户操作，然后检查后台数据是否准确记录。


自动化工具和脚本

例如编写测试脚本，自动模拟一系列用户行为，并自动比对预期结果和实际采集到的数据。

此外，即使有了自动化的验证手段，人工的参与仍然是有必要的。人工可以对一些复杂的、特殊的情况进行判断和分析，也可以对自动化验证的结果进行抽检和复查，以确保验证的准确性和可靠性。

13

独热编码



独热编码

例如，我们有一个水果种类的数据集，包含“苹果”、“香蕉”、“橙子”这三种水果类别。

使用独热编码进行转换后：

“苹果”可以表示为 $[1, 0, 0]$ ，“香蕉”可以表示为 $[0, 1, 0]$ ，“橙子”可以表示为 $[0, 0, 1]$

再比如，对于一周中的七天，“星期一”可以编码为 $[1, 0, 0, 0, 0, 0, 0]$ ，“星期二”编码为 $[0, 1, 0, 0, 0, 0, 0]$ ，...

01

独热编码介绍

独热编码是一种将类别型数据转换为数字形式的编码方式，适用于处理分类问题。

02


独热编码的作用

在机器学习中，独热编码能够清晰地表示类别数据，方便算法进行处理和计算。

03


独热编码的缺点

如果类别数量很多，可能会导致数据变得稀疏，增加计算复杂性和存储压力。



14

聚合和聚类的比较



聚合和聚类的比较

例如，有一组学生的考试成绩：80 分、90 分、75 分、85 分、95 分。求这组成绩的平均分，就是一种聚合操作，最终得到的平均分 85 分就是聚合的结果

聚合例子

计算学生成绩的平均分，就是一种聚合操作，最终得到的平均分就是聚合的结果。

聚合（Aggregation）操作

聚合通常是指将多个数据点或元素按照某种规则进行合并或汇总，得到一个综合的结果。

聚类（Clustering）操作

聚类则是将数据集中相似的数据点归为一组或一个类，事先并不知道会分成哪些类以及每个类的具体特征。

聚类例子

根据学生的多门学科成绩、课外活动参与情况等综合信息，将学生分为不同的群体，就是聚类。

聚合特征构造

聚合特征构造是指通过聚合操作来创建新的特征，例如，有一个关于商品销售的数据集，包含每个商品的每日销售额。我们可以通过聚合计算每个商品的周销售额、月销售额，这些周销售额和月销售额就是通过聚合特征构造得到的新特征。有助于从不同的时间尺度来观察和分析商品的销售情况。



习题讲解：

1. ETL不仅仅是对一个企业部门、一个应用系统数据的简单整理，还是跨部门、跨（ ）的数据整合处理。

- A. 业务
- B. 流程
- C. 产品
- D. 系统

答案：D

2. 以下不属于数据整合解决方案的是（ ）。

- A. 数据爬虫
- B. ETL工具
- C. 数据仓库
- D. 数据虚拟化

答案：A

习题讲解：

3. 以下可视化分析工具不需要编程（ ）。

A. Tableau

B. Raw

C. Chart.js

D. Processing

E. Facets

答案：AB

ChartJS 使用HTML5元素的Javascript图形库；

Processing是一个开源开发工具，强调代码的可视化表示；

Facets 是 Google 开源的一款可视化工具，帮助理解、分析和调试 ML 数据集。

4. 在计算机内部，数据的表现形式不包括（ ）。

A. 二进制

B. 八进制

C. 十六进制

D. 十进制

E. 四进制

答案：BE

习题讲解：

5. 以下属于数据标注常用的分类方法（ ）。

- A. 根据数据标注的构造形式进行划分
- B. 根据数据标注者类型的不同进行划分
- C. 根据数据标注对象不同划分
- D. 根据数据标注难度划分
- E. 根据数据标注结构划分

答案：ABC

数据标注按照标注对象不同可以分为文本标注、语音标注和图像标注三大类；

根据标注方式方法不同进行区域划分：区域标注区、描点标注区、空间标注区、文本标注区、标框标注区、语音标注区；

按标注的构成形式分：结构化标注、非结构化标注、半结构化标注；

按标注者类型分：人工标注、机器标注；

习题讲解：

6. 对于语音标注的数据集，（ ）的设置一定范围内越高越好。

A. 采样率

B. 声波

C. 分贝

D. 振幅

E. 采样精度

答案：AE

采样率表示了每秒对原始信号采样的次数，单位为Hz。显然，在一秒内采样的点越多，获取的信息越丰富，数字化语音信号的保真度越高。

采样精度就是指存放一个采样值所使用的比特数目。当用8个比特（采样精度为8位）存放一个采样值时，对声音振幅的分辨等级理论上为256个，即0至255；当用16个比特（采样精度为16位）存放一个采样值时，对声音振幅的分辨等级理论上为65536个，即0到65536。

采样率和采样精度的设置以越高越好，采样率和采样精度越高则声音的质量越高。

习题讲解：

7. 半结构化标注对数据标注员而言，具有以下特点（ ）。

- A. 薪金高
- B. 工作量高
- C. 耗时
- D. 技术精湛
- E. 年龄高

答案：BC

结构化标注指集合内，标注者通过将标注对象与标签候选集合进行匹配，选出最合理的标签值作为标注结果。其优点是标签候选集能够将标注类别描述得很清晰，便于标注者选择；标签是结构化的，有利于存储和后期的统计查找。缺点是标注过程中遇到具有二义性标签时往往会影响最终的标注结果。

非结构化标注指标注者在规定约束内，自由组织关键字对标注对象进行描述。非结构化标注能够给标注者足够的自由，可以清楚地表达自己的观点。但同时给数据存储和使用带来困难，不利于统计分析。

半结构化标注指标签值是结构化标注，而标签域是非结构化标注。半结构化标注的灵活性较强，便于统计查找，但工作量较高，比较耗时。

习题讲解：

8. 目前数据采集主要分为以下采集方式（ ）。

答案：CE

A. 删除

B. 更新

C. 线下

D. 批处理

E. 线上

9. 以下选项是插补缺失值的常用方法（ ）。

答案：AC

常见的插补方法如下：均值/中位数/众数插补、固定值填充、最近邻插补、回归插补、函数插值法

A. 均值插补

B. 方差插补

C. 同类均值插补

D. 正态分布插补

E. 泊松分布插补

习题讲解：

10. 数据整合可分为使用（ ）方式，以下选项是正确的。

答案：AC

- A. 工具软件
- B. 设备
- C. 编程
- D. 代码
- E. 表格

答案：ABC

11. 下列选项中属于多媒体硬件的是（ ）。

- A. 光盘驱动器
- B. 视频卡
- C. 音频卡
- D. 加密卡
- E. 存储卡

光盘驱动器：包括可重写光盘驱动器（CD-R）、WORM光盘驱动器和CD-ROM驱动器、DVD。

音频卡：在音频卡上连接的音频输入输出设备包括话筒、音频播放设备、MIDI合成器、耳机、扬声器等。

图形加速卡

视频卡：可细分为视频捕捉卡、视频处理卡、视频播放卡以及TV编码器等专用卡，其功能是连接摄像机、VCR影碟机、TV等设备，以便获取、处理和表现各种动画和数字化视频媒体。

扫描卡：它是用来连接各种图形扫描仪的。

打印机接口：打印机现在已经是最常用的多媒体输出设备之一了。



◆ THANKS ◆
感谢您的观看

