

```
SELECT

r.m as "username",

r.lx as "type",

r.scrq as "date",

r.cs as "times"

FROM use_record r

WHERE r.lx IN ('娱乐时事','政治时事','民生时事');
```

案例

鸢尾花分类

```
from sklearn import datasets

from sklearn.model_selection import train_test_split

from sklearn.neighbors import KNeighborsClassifier(K 近 邻 分
类)(n_neighbors=3)

from sklearn.metrics(指标) import accuracy_score(准确率)

# 加载数据

iris = datasets.load_iris() 内部加载

# 提取特征数据和目标标签

X = iris.data

y = iris.target

或者

X = df.drop(columns=['target']) #column 选中指定的列
```

```
y = df['target']
```

```
# 划分训练集和测试集
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3,  
random_state=42)
```

```
# 标准化数据
```

```
scaler = StandardScaler()
```

```
X_train_scaled = scaler.fit_transform(X_train) # 拟合并转换训练集
```

```
X_test_scaled = scaler.transform(X_test)      # 转换测试集
```

```
# 创建模型并训练
```

```
model = KNeighborsClassifier(n_neighbors=3) 建模
```

```
model.fit(X_train, y_train) 训练
```

```
# 预测并评估
```

```
y_pred = model.predict(X_test) 预测
```

```
accuracy = accuracy_score(y_test, y_pred)
```

```
print(f"模型准确率: {accuracy:.2f}")
```

房价预测（回归问题）

```
from sklearn.datasets import fetch_california_housing
```

```
from sklearn.model_selection import train_test_split

from sklearn.ensemble import RandomForestRegressor( 随机森林回归)(n_estimators=100)

from sklearn.metrics import mean_squared_error(均方误差, MSE)

# 加载数据

data = fetch_california_housing()

X, y = data.data, data.target

# 划分数据集

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# 训练模型

model = RandomForestRegressor(n_estimators=100, random_state=42)

model.fit(X_train, y_train)


# 预测并评估

y_pred = model.predict(X_test)

mse = mean_squared_error(y_test, y_pred)

print(f"均方误差: {mse:.2f}")
```

波士顿房价预测（回归问题）

```
from sklearn.datasets import load_boston

from sklearn.model_selection import train_test_split
```

```
from sklearn.linear_model import LinearRegression(线性回归)

from sklearn.metrics import mean_squared_error(均方误差, MSE)

# 加载数据集

boston = load_boston()

X, y = boston.data, boston.target

# 划分训练集和测试集

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# 创建模型并训练

model = LinearRegression()

model.fit(X_train, y_train)

# 预测并评估

y_pred = model.predict(X_test)

mse = mean_squared_error(y_test, y_pred)

print(f"均方误差: {mse:.2f}")
```

手写数字识别（多分类问题）

```
from sklearn.datasets import load_digits

from sklearn.model_selection import train_test_split

from sklearn.svm import SVC(支持向量机分类)(kernel='linear')

from sklearn.metrics import classification_report(分类指标)

# 加载数据集
```

```
digits = load_digits()

X, y = digits.data, digits.target

# 划分训练集和测试集

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# 创建模型并训练

model = SVC(gamma=0.001)

model.fit(X_train, y_train)

# 预测并评估

y_pred = model.predict(X_test)

print("分类报告： \n", classification_report(y_test, y_pred))
```

```
X = data['预估薪资']

y = data['是否会购买']
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state = 2020)
```

```
X_train = X_train.values.reshape(-1,1) #训练转换为二维数组
```

```
X_test = X_test.values.reshape(-1,1) #测试转换为二维数组
```

```
model = LogisticRegression() #逻辑回归模型类
```

`model.fit(X_train, y_train)` #模型对象的训练方法，用于拟合数据

`accuracy = model.score(X_test, y_test)` #模型在测试集上的准确率

`print (accuracy)` #打印出模型的准确率

`y_test_pred = model.predict(X_test)`

`print(y_test_pred)` #打印出模型对测试集的预测结果

#查看数据

`data.info()` #查看数据概况

`data.describe()` #描述性统计信息

`data.shape` #获取数据规模

`data.dtypes` #各个字段的数据类型

`data.head()` #预览前 5 行的数据

`data.tail()` #预览后 5 行的数据

#数据清洗

`data.isnull()` #判断数据是否缺失

`data.dropna()` #丢弃所有包含缺失值的数据

`data.fillna()` #对缺失值进行填充

`data.duplicated()` #查询是否存在重复数据

`data.drop_duplicates()` #删除重复数据

`data.replace(old_value,new_value )` #将数据中的某些值替换为其他值

函数:

`count()`:计算表中记录的条数

`num_kids = df['Name'].count()`

`print(f"表格中有:{num_kids}个小朋友")`

`sum()`:计算字段值的总和

`total_allowance = df['Allowance'].sum()`

`print(f"名称: {total_allowance}元")`

`avg()`:计算字段值的平均值

`max()`:查询表中字段值的最大值

`max_allowance = df['Allowance'].max()`

`print(f"名称: {max_allowance}元")`

`min()`:查询表中字段值的最小值

FIRST() - 返回第一个记录的值

LAST() - 返回最后一个记录的值

```
SELECT stu.xh as “account” ,  
       stu.xm as “name” ,  
       stu.xb as “gender” ,  
       stu.csny as “birth” ,  
       stu.nj as “grade” ,  
       stu.xy as “department” ,  
FROM student stu;
```

查询年纪为 22 级和 23 级的学生记录

```
WHERE stu.nj IN ( ‘22’ , ‘23’ );
```

查询出生日期为 2002 年的学生记录

```
WHERE stu.csny LIKE ‘2002%’ ;
```

查询学院为” 计算机科学与技术” 的学生记录

```
WHERE stu.xy = ‘计算机科学与技术’ ;
```

“是否有效” 为” 是” 的记录

```
WHERE stu.valid = ‘是’ ;
```

“最近一次模拟考试成绩” 在 60-100 分之间的学生记录

```
WHERE stu.last_score BETWEEN 60 AND 100;
```

Sklearn 机器学习遵循一定的模式：1.数据加载、2.数据预处理、3.训练模型、4.评估模型、5.调优模型

数据集（Dataset）

1.数据加载

```
from sklearn.datasets（数据集） import load_iris
```

```
import pandas as pd
```

#使用 pandas 加载 CSV/excel 文件

```
data =pd.read_csv('路径名.csv')/pd.read_excel('.xls')
```

2.数据预处理

```
from sklearn.preprocessing（预处理） import StandardScaler
```

3.Sklearn 训练模型

*监督学习

分类（Classification）例如，鸢尾花

```
from sklearn.linear_model import LogisticRegression: 逻辑回归 (LR)

from sklearn.tree import DecisionTreeClassifier: 决策树(DT)

from sklearn.ensemble import RandomForestClassifier: 随机森林分类
(RF)
```

回归 (Regression) 例如, 预测房价、气温等

```
from sklearn.linear_model import Ridge: 岭回归
```

*无监督学习

聚类 (Clustering)

```
from sklearn.cluster import KMeans: K 均值聚类
```

```
from sklearn.cluster import DBSCAN: 基于密度的空间聚类
```

降维 (Dimensionality Reduction)

```
sklearn.decomposition.PCA: 主成分分析 (PCA)
```

```
sklearn.decomposition.NMF: 非负矩阵分解
```

#如果需要将结果保存到新的 csv 文件中, 可以使用一下代码:

#训练集

```
X_train.to_csv('文件名.csv',index=False)
```

```
X_train.to_csv('文件名.csv',index=False,header=[True])
```

#测试集

```
y_test.to_csv('文件名.csv',index=False)
```

```
y_test.to_csv('文件名.csv',index=False,header=[True])
```

4.模型评估

准确率 (Accuracy): 模型正确预测的样本数占总样本数的比例。(ACC)

```
from sklearn.metrics import accuracy_score
```

```
accuracy = accuracy_score(y_true, y_pred)
```

混淆矩阵 (Confusion Matrix): 显示模型在各个类别上的预测结果。

```
from sklearn.metrics import confusion_matrix
```

```
cm = confusion_matrix(y_true, y_pred)
```

精确率 (Precision) (PREC) 和 召回率 (Recall) (REC): 精确率衡量预测为正的样本中实际为正的的比例, 召回率衡量实际为正的样本中预测为正的的比例。

```
from sklearn.metrics import precision_score, recall_score
```

```
precision = precision_score(y_true, y_pred)
```

```
recall = recall_score(y_true, y_pred)
```

ROC 曲线与 AUC 值: ROC 曲线显示不同阈值下的真正率 (TPR) 与假正率 (FPR), AUC 值衡量模型区分正负类的能力。

```
from sklearn.metrics import roc_auc_score
```

```
auc = roc_auc_score(y_true, y_pred_proba)
```

Classification Report（分类报告）#提供精确率、召回率、F1 分数和支持度的综合报告

```
from sklearn.metrics import classification_report
```

```
report = classification_report(y_true, y_pred,  
target_names=target_names)
```

回归模型评估指标

MSE（均方误差）#预测值与实际值差的平方的平均值。

```
from sklearn.metrics import mean_squared_error
```

```
mse = mean_squared_error(y_true, y_pred)
```

业务分析：包括业务流程设计、数据采集流程设计、业务模块效果优化等。

智能训练：涉及数据处理规范制定、算法测试等。

智能系统设计：包括智能系统监控优化、人机交互流程设计等。

培训与指导：编写初级培训讲义。

课程名称：人工智能基础与实践

授课目的：学员将掌握人工智能训练师的基础知识，包括人工智能的基本概念、数据处理、模型训练与评估，以及智能系统的简单应用。

一、人工智能概述（1.人工智能关键技术，2.数据在人工智能中的作

用)

二、数据处理与标注 (1.数据采集, 2.数据标注, 3.数据处理)

三、模型训练与评估 (1.机器学习基础, 2.深度学习入门, 3.模型训练与优化, 4.模型部署)

四、智能系统应用 (1.智能客服系统, 2.图像识别系统, 3.语音识别系统)

课程名称: 数据标注基础与实践

授课目标: 使学生了解数据标注的重要性, 掌握基本的数据标注技能, 并能够应用到实际项目中。

一、数据标注概述 (1.数据标注的定义, 2.数据标注的重要性, 3.数据标注的类型, 4.标注工具介绍)

二、文本标注 (1.文本标注基础, 2.文本标注工具的使用, 3.文本标注的技巧, 4.案例分析)

三、图像标注 (1.图像标注基础, 2.图像标注工具的使用, 3.图像标注的技巧, 4.案例分析)

四、综合应用(1.数据标注项目流程,2.团队协作与标注管理,3.标注数据的应用,4.课程总结)

问题 1: 对数据标注的目的和重要性不理解。

解决方案: 通过实际案例和应用场景来解释数据标注的作用, 展示标注数据如何帮助机器学习模型学习和改进。

问题 2：主观性与一致性问题

解决方案：可以通过建立标注规范和标注指南，明确标注的标准和要求，以保证标注的一致性。

问题 3：对标注数据的用途理解不足

解决方案：通过讲解标注数据如何用于训练机器学习模型，以及这些模型的实际应用案例。

问题 4：数据标注的质量问题

解决方案：可以制定严格的标注标准和审核流程，进行定期的质量检查和反馈。

```
import matplotlib.pyplot as plt
```

```
import numpy as np
```

柱状图

```
categories = ['A', 'B', 'C', 'D']
```

```
values = [10, 15, 7, 12]
```

```
plt.bar(categories, values)
```

```
plt.xlabel('类别')
```

```
plt.ylabel('数值')
```

```
plt.title('柱状图示例')
```

```
plt.show()
```

折线图

```
x = [1, 2, 3, 4, 5]
y = [2, 4, 6, 8, 10]
plt.lineplot(x=x, y=y, marker='o', color='blue')
plt.xlabel('X 轴')
plt.ylabel('Y 轴')
plt.title('折线图示例')
plt.show()
```

饼图

```
sizes = [15, 30, 45, 10]
labels = ['A', 'B', 'C', 'D']
plt.pie(sizes, labels=labels, autopct='%1.1f%%')
plt.title('饼图示例')
plt.axis('equal') # 确保饼图为正圆形
plt.show()
```

散点图

```
# 创建数据
x = np.random.rand(50)
y = np.random.rand(50)
# 绘制散点图
```

```
plt.scatter(x=x, y=y, color='red', alpha=0.6)

plt.xlabel('X 轴')

plt.ylabel('Y 轴')

plt.title('散点图示例')

plt.show()
```

热力图（使用 seaborn 库）

```
import seaborn as sns

# 创建一个随机矩阵

data = np.random.rand(5, 5)

#使用 seaborn 绘制热力图

sns.heatmap(data)

plt.title('热力图示例')

plt.show()
```

直方图

```
data = np.random.randn(1000)

plt.hist(data, bins=30)

plt.xlabel('数值')

plt.ylabel('频数')

plt.title('直方图示例')

plt.show()
```

```
## 使用 matplotlib 绘制决策树

plt.figure(figsize=(12, 8))

plot_tree(clf,

          feature_names=feature_names,

          class_names=target_names,

          filled=True,

          rounded=True,

          fontsize=12)

plt.title("Decision Tree Visualization")

plt.show()
```

数据集相关变量

x: 通常用于表示特征数据（特征矩阵）。**x** 是一个二维数组，每一行是一个样本，每一列是一个特征。

y: 通常用于表示目标变量（标签）。**y** 是一个一维数组，包含每个样本的类别标签或回归目标值。

data: 用于表示完整的数据集，尤其是当你从 **Scikit-learn** 的内置数据集加载数据时，例如 `data = load_iris()`。

df: 如果你将数据转换为 **Pandas DataFrame**，通常使用 **df** 作为变量名。

模型相关变量

model: 通常用于表示模型实例，例如 `model = LogisticRegression()`。

clf: 在分类任务中，`clf` 是 “classifier”（分类器）的缩写，常用于表示分类模型。

reg: 在回归任务中，`reg` 是 “regressor”（回归器）的缩写，常用于表示回归模型。

pipeline: 用于表示 Scikit-learn 的 Pipeline 对象，它将多个预处理步骤和模型组合在一起。

模型训练和预测相关变量

y_pred: 表示模型的预测结果。

y_proba: 表示模型预测的概率（在分类任务中）。

accuracy 或 accuracy_score: 用于存储模型的准确率。

report: 用于存储分类报告（`classification_report`）。

数据预处理相关变量

scaler: 用于表示标准化或归一化工具（如 `StandardScaler` 或 `MinMaxScaler`）。

encoder: 用于表示特征编码工具（如 `LabelEncoder` 或 `OneHotEncoder`）。

imputer: 用于表示缺失值填补工具（如 `SimpleImputer`）。

使用 `x` 和 `y` 表示特征和目标变量。

使用 `model`、`clf` 或 `reg` 表示模型。

使用 `X_train`、`X_test` 等表示数据划分后的变量。

使用 `y_pred`、`accuracy` 等表示模型预测和评估结果。

使用 `scaler`、`encoder` 等表示预处理工具。

使用 `params`、`best_params` 等表示超参数和配置。

课程名称：数据标注基础和实践

授课目的：使学生了解数据标注重要性，数据标注工具，并能运用到实际项目中

数据标注概况

了解数据标注定义，数据标注重要性，标注工具介绍，数据标注类型

文字标注

文字标注基础，文字标注工具使用，文字标注技巧，案例分析

图像标注

综合应用

数据标注项目流程，团队协作和标注管理，数据标注应用，课程总结